

T M 4

# Eksplorasi Data

*Use Case: Dataset Iris*


---

Dr. Donny Maha Putra

# Konsep Data Mining

Apa itu Data Mining?

*Data Mining adalah proses menemukan pola bermakna dari data mentah menjadi pengetahuan yang berguna.*



Proses data mining tidak linear — setiap tahap dapat diulang hingga pengetahuan yang dihasilkan cukup akurat dan andal.

# Proses Data Mining (Siklus Penuh)

Data Mining Lifecycle

1

## Data Ingestion

Pengumpulan data dari berbagai sumber (database, file, API, web scraping).

2

## Exploratory Data Analysis

Eksplorasi awal: distribusi, outlier, korelasi sebelum modeling dilakukan.

3

## Preprocessing

Pembersihan, normalisasi, transformasi data agar siap untuk pelatihan model.

4

## Training

Pelatihan model machine learning menggunakan data yang telah diproses.

5

## Evaluation

Pengujian performa model dengan metrik seperti Accuracy, F1-score, RMSE.

6

## Tuning

Penyesuaian hyperparameter untuk meningkatkan akurasi model.

7

## Production

Model diterapkan pada sistem nyata untuk membuat prediksi secara otomatis.

8

## Maintenance

Pemantauan kinerja model dan pembaruan ketika data baru tersedia.

↓ Iterasi atau data baru memulai ulang siklus

# Orange Data Mining: Tool Overview

Fitur Utama Platform

*Orange adalah software data mining visual berbasis Python yang memungkinkan analisis data tanpa menulis kode secara manual.*



## Visualisasi Data

Grafik interaktif, chart, dan plot untuk memahami distribusi dan pola data.



## Text Mining

Analisis teks tidak terstruktur, ekstraksi kata kunci dan sentimen.



## Geospasial

Pemetaan data berdasarkan lokasi geografis menggunakan Geomap.



## Data Mining

Algoritma klasifikasi, regresi, dan clustering untuk analisis prediktif.



## Analisis Time Series

Analisis data deret waktu untuk menemukan tren dan pola temporal.



## Asosiasi

Menemukan hubungan antarvariabel dalam dataset (association rules).



## Analisis Citra

Pemrosesan dan klasifikasi gambar digital.



## Bioinformatika

Analisis data biologis seperti DNA sequence dan protein.



## Spektroskopi

Analisis data spektral untuk aplikasi kimia dan material.

## Apa itu EDA?

**EDA (Exploratory Data Analysis)** adalah tahap awal dalam analisis data yang bertujuan untuk:

- Memahami struktur dan distribusi data
- Mendeteksi anomali, outlier, dan nilai hilang
- Menemukan pola dan hubungan antarvariabel
- Membantu pemilihan algoritma yang tepat

**EDA dilakukan SEBELUM proses modeling dimulai.**



### Grafik

Visualisasi distribusi data dalam bentuk bar chart, histogram, dll.



### Plot

Scatter plot dan line plot untuk melihat hubungan antardua variabel.



### Distribusi

Melihat sebaran nilai data: normal, skewed, bimodal, dsb.



### Geomap

Visualisasi data dengan dimensi geografis/lokasi.



### Tabel

Tampilan data terstruktur untuk inspeksi langsung nilai setiap baris.

### Tentang Dataset Iris

**Dataset Iris** pertama kali diperkenalkan oleh statistikawan Ronald Fisher pada tahun 1936 dan menjadi salah satu dataset paling populer dalam dunia machine learning.

**Tujuan:** Membangun model klasifikasi spesies bunga iris berdasarkan ukuran kelopak bunganya.

150

Total Observasi

4

Fitur (Atribut)

3

Kelas / Spesies

50

Data per Kelas

### 4 Fitur Input:

- Sepal Length (cm) → panjang daun kelopak luar
- Sepal Width (cm) → lebar daun kelopak luar
- Petal Length (cm) → panjang mahkota bunga
- Petal Width (cm) → lebar mahkota bunga

### 3 Kelas Target (Spesies):

Spesies 1

**Iris Setosa**

Petal kecil, mudah dibedakan

Spesies 2

**Iris Versicolor**

Petal sedang, overlap dengan Virginica

Spesies 3

**Iris Virginica**

Petal terbesar di antara ketiganya

# Percobaan EDA: Apa yang Akan Kita Lakukan?

Dataset Iris di Orange Data Mining

Dalam percobaan ini, kita akan mengeksplorasi Dataset Iris menggunakan 8 metode EDA berikut:

## 01 Tabel

Melihat keseluruhan data secara baris dan kolom.

## 02 Tabel Pivot

Merangkum data dengan agregasi nilai per kelompok.

## 03 Rank

Mengurutkan variabel berdasarkan kontribusi terhadap klasifikasi.

## 04 Korelasi

Mengukur kekuatan hubungan linier antara dua variabel numerik.

## 05 Scatter Plot

Memvisualisasikan hubungan dua variabel dalam koordinat dua dimensi.

## 06 Distribusi

Melihat sebaran nilai setiap fitur: normal, skewed, atau bimodal.

## 07 Box Plot

Menampilkan median, kuartil, dan outlier setiap variabel.

## 08 Feature Statistics

Statistik deskriptif lengkap: mean, median, std, min, max per fitur.

# Langkah-Langkah EDA di Orange

Panduan Praktik Step-by-Step

1

## Buka Orange & Load Data

Jalankan Orange → klik "File" widget → pilih dataset "iris.csv" bawaan Orange atau upload file Iris.csv Anda.

3

## Cek Feature Statistics

Tambahkan widget "Feature Statistics" → hubungkan ke File. Amati mean, std, min, max untuk setiap fitur (petal/sepal).

5

## Lihat Distribusi

Tambahkan widget "Distributions" → pilih fitur yang ingin dilihat sebaran nilainya. Amati perbedaan distribusi per kelas.

7

## Tabel Pivot & Rank

Gunakan "Pivot Table" untuk agregasi per kelas → gunakan "Rank" untuk melihat fitur mana yang paling membedakan spesies.

2

## Hubungkan ke Data Table

Sambungkan widget "File" ke widget "Data Table". Klik dua kali widget Data Table untuk melihat 150 baris data Iris.

4

## Buat Scatter Plot

Tambahkan widget "Scatter Plot" → atur sumbu X = petal length, Y = petal width → warnai berdasarkan kolom "iris" (kelas).

6

## Analisis Korelasi

Tambahkan widget "Correlations" → hubungkan ke File. Perhatikan heatmap korelasi antara sepal/petal length dan width.

8


## Box Plot per Kelas

Tambahkan widget "Box Plot" → kelompokkan berdasarkan kelas "iris". Amati distribusi dan outlier tiap spesies.

# Intepreatsi Hasil EDA: Scatter Plot & Distribusi

Visualisasi Pola Dataset Iris

 Scatter Plot: Petal Length vs Width



## Temuan Kunci dari EDA

### Setosa Terpisah Jelas

Iris Setosa memiliki petal yang sangat kecil sehingga mudah diklasifikasikan secara linear.

### Versicolor & Virginica Overlap

Kedua kelas ini saling tumpang tindih pada nilai petal medium — butuh model non-linear.

### Petal > Sepal dalam Diskriminasi

Fitur petal (length & width) jauh lebih informatif dibanding sepal untuk membedakan kelas.

### Korelasi Tinggi: Petal L & W

Petal length dan petal width berkorelasi sangat tinggi ( $r > 0.96$ ), mengindikasikan multikolinearitas.

# Preprocessing Data

Mengolah Data Mentah Menjadi Data Siap Analisis

**Preprocessing** adalah serangkaian proses untuk mengolah data mentah sebelum dapat digunakan untuk melakukan data mining. Tanpa preprocessing yang baik, model machine learning akan menghasilkan prediksi yang tidak akurat: *"Garbage in, garbage out."*

## Penskalaan Data (Normalization/Scaling)

- Min-Max Normalization: skala 0–1
- Standardization (Z-Score): mean=0, std=1
- Digunakan sebelum algoritma jarak (KNN, SVM)

## Pembersihan Data (Data Cleaning)

- Mengisi nilai hilang (missing values)
- Menghapus duplikat
- Memperbaiki kesalahan format data

## Penghapusan Data (Data Reduction)

- Menghapus fitur tidak relevan
- Menangani outlier ekstrem
- Reduksi dimensi dengan PCA

## Transformasi Data (Data Transformation)

- Encoding variabel kategorik
- Binerisasi fitur numerik
- Agregasi data ke skala yang sesuai



Di Orange: Gunakan widget Preprocess, Normalize, Edit Domain, Select Columns, atau Impute untuk menjalankan preprocessing secara visual.

# Percobaan Preprocessing – Dataset Iris

7 Teknik yang Akan Dipraktikkan

*Dataset Iris termasuk dataset yang relatif bersih, namun percobaan preprocessing berikut penting untuk dipahami secara konseptual dan teknis:*

01

## Select Columns

Memilih fitur mana yang akan digunakan atau dikecualikan dari analisis.

02

## Normalize

Menskalakan nilai numerik ke rentang tertentu (0–1) agar semua fitur setara.

03

## Outliers

Mendeteksi dan menangani observasi yang menyimpang jauh dari rata-rata.

04

## Edit Domain

Mengubah nama variabel, tipe data, atau mendefinisikan ulang label kelas.

05

## Select Relevants

Memilih fitur berdasarkan skor relevansi terhadap variabel target.

06

## Data Sampling

Mengambil sebagian data secara acak untuk training/testing yang seimbang.

07

## Randomize

Mengacak urutan data agar tidak ada bias urutan saat proses pelatihan model.

# Langkah Preprocessing di Orange

Panduan Praktik Step-by-Step

1

## Load Data Iris

Buka Orange → File widget → load dataset iris.csv. Pastikan target variabel "iris" sudah diset sebagai "class".

2

## Select Columns

Tambahkan widget "Select Columns" → pindahkan fitur yang tidak relevan ke kolom "Ignored". Coba exclude fitur sepal width.

3

## Normalisasi Fitur

Tambahkan widget "Normalize" → pilih metode "Normalize by standard deviation" atau "Normalize to [0,1]". Amati perubahan nilai.

4

## Deteksi Outlier

Gunakan widget "Outliers" → setting parameter contamination. Hubungkan ke Scatter Plot untuk melihat titik yang dideteksi sebagai outlier.

5

## Edit Domain

Gunakan "Edit Domain" untuk mengubah nama variabel atau label kelas. Ini berguna untuk membuat visualisasi lebih mudah dibaca.

6

## Data Sampling & Randomize

Gunakan "Data Sampler" → atur proporsi 70:30 untuk training/testing. Aktifkan "Randomize" agar data tidak terurut berdasarkan kelas.

7

## Verifikasi Hasil Preprocessing

Sambungkan setiap output preprocessing ke "Data Table" dan "Feature Statistics" untuk memverifikasi bahwa data sudah berubah sesuai harapan.

8

## Simpan Pipeline Orange

Simpan workflow Orange (.ows) Anda — ini adalah "pipeline" preprocessing yang dapat digunakan ulang untuk data serupa di masa mendatang.

# Metrik Evaluasi Model

Mengukur Performa Model Machine Learning

**Metrik** (evaluation metrics) adalah ukuran kuantitatif yang digunakan untuk menilai seberapa baik suatu model dalam membuat prediksi.



## Metrik Klasifikasi

### Accuracy

$$(TP+TN) / Total$$

Proporsi prediksi benar dari seluruh prediksi. Cocok untuk data seimbang.

### Precision

$$TP / (TP+FP)$$

Dari semua yang diprediksi positif, berapa yang benar-benar positif?

### Recall

$$TP / (TP+FN)$$

Dari semua yang sebenarnya positif, berapa yang berhasil ditemukan?

### F1-Score

$$2 \times (P \times R) / (P + R)$$

Rata-rata harmonik Precision & Recall. Ideal untuk data tidak seimbang.



## Metrik Regresi

### MAE

$$\sum |y_{actual} - y_{pred}| / n$$

Rata-rata selisih absolut antara nilai aktual dan prediksi. Mudah diinterpretasikan.

### RMSE

$$\sqrt{\sum (y_{actual} - y_{pred})^2 / n}$$

Akar kuadrat rata-rata error kuadrat. Sensitif terhadap outlier.

### R<sup>2</sup>

$$1 - (SS_{res} / SS_{tot})$$

Proporsi variansi data yang dijelaskan model. Nilai 1 = sempurna.

Iris Dataset → masalah klasifikasi → gunakan Accuracy, Precision, Recall, dan F1-Score

**Uji statistik** dilakukan untuk mengetahui apakah terdapat perbedaan yang signifikan secara statistik dari sampel yang diamati, bukan hanya perbedaan kebetulan.

## Uji Normalitas

- Kapan digunakan:** Digunakan sebelum uji parametrik untuk memeriksa apakah data berdistribusi normal.
- Cara uji:** Gunakan uji Shapiro-Wilk ( $n < 50$ ) atau Kolmogorov-Smirnov ( $n \geq 50$ ).
- Interpretasi:** Jika  $p\text{-value} > 0.05 \rightarrow$  data normal  $\rightarrow$  lanjut ke uji parametrik (ANOVA, t-test).

## Uji Homogenitas

- Kapan digunakan:** Memeriksa apakah variansi antargrup yang dibandingkan relatif sama (homogen).
- Cara uji:** Gunakan uji Levene atau Bartlett sebelum ANOVA.
- Interpretasi:** Jika  $p\text{-value} > 0.05 \rightarrow$  variansi homogen  $\rightarrow$  asumsi ANOVA terpenuhi.

*Dalam konteks Iris Dataset: ANOVA satu arah dapat digunakan untuk menguji apakah rata-rata petal length berbeda signifikan di antara ketiga spesies.*

## ANOVA (Analysis of Variance)

- Kapan digunakan:** Membandingkan rata-rata tiga atau lebih kelompok sekaligus secara simultan.
- Cara uji:** Hitung F-statistic: rasio variansi antargrup vs. variansi dalam grup.
- Interpretasi:** Jika  $p\text{-value} < 0.05 \rightarrow$  ada minimal satu pasang kelompok yang berbeda signifikan.

# Confusion Matrix

Membaca Hasil Klasifikasi secara Detail

**Confusion matrix** adalah tabel yang merangkum hasil prediksi model supervised learning, membandingkan kelas aktual dengan kelas yang diprediksi.

## Metrik yang Diturunkan dari CM:

|        | Predicted Class →                       |                                        |
|--------|-----------------------------------------|----------------------------------------|
| Actual | POSITIF                                 | NEGATIF                                |
|        | TP<br>True Positive<br>(Benar Positif)  | FP<br>False Positive<br>(Error Tipe I) |
| Actual | FN<br>False Negative<br>(Error Tipe II) | TN<br>True Negative<br>(Benar Negatif) |
|        |                                         |                                        |

### Accuracy

$$(TP + TN) / (TP + FP + FN + TN)$$

Proporsi prediksi yang benar secara keseluruhan.

### Precision

$$TP / (TP + FP)$$

Ketepatan model saat memprediksi positif.

### Recall

$$TP / (TP + FN)$$

Kemampuan model menemukan semua kasus positif.

### F1-Score

$$2 \times (Precision \times Recall) / (P+R)$$

Keseimbangan antara Precision dan Recall.

# Proses Data Mining: Klasifikasi KNN

Alur: Load Data → Evaluasi

*K-Nearest Neighbors (KNN) adalah algoritma klasifikasi sederhana yang mengklasifikasikan data baru berdasarkan kesamaannya dengan K data terdekat.*

## 1 Load Data

Muat dataset Iris (150 obs, 4 fitur, 3 kelas) ke dalam Orange menggunakan widget File.

## 2 Split Data

Pisahkan data menjadi Training Set (70%) dan Testing Set (30%) menggunakan Data Sampler.

## 3 Scale Features

Normalisasi keempat fitur ke skala 0–1 agar jarak KNN tidak didominasi fitur dengan nilai besar.

## 4 KNN

Hubungkan ke widget KNN → atur K (default: 5) → KNN menghitung jarak Euclidean ke K tetangga terdekat.

## 5 Predictions

Gunakan widget Predictions → masukkan data testing → lihat prediksi kelas untuk setiap observasi.

## 6 Confusion Matrix

Hubungkan ke widget Confusion Matrix → baca nilai TP, FP, FN, TN → hitung Accuracy, Precision, Recall, F1.

**Target Akurasi Iris dengan KNN:** Umumnya > 95% dengan K=5. Jika lebih rendah, periksa preprocessing (normalisasi) atau coba nilai K yang berbeda (K=3 atau K=7).

# Langkah KNN di Orange: Panduan Praktik

Dari Load Data hingga Confusion Matrix

1

## Buka Orange dan Load Iris

File widget → cari dataset "iris" di bawaan Orange atau upload iris.csv. Periksa 150 baris, 5 kolom (4 fitur + 1 kelas).

3

## Normalize Fitur

"Preprocess" atau "Normalize" widget → pilih "Normalize features" → method: "Normalize to [0,1]". Hubungkan output ke KNN.

5

## Predictions Widget

"Predictions" widget → input: (1) model KNN, (2) data testing (30%) dari Data Sampler → widget akan menampilkan prediksi kelas.

7

## Evaluasi & Tuning K

Coba ubah  $K = 1, 3, 5, 7, 11$  → bandingkan akurasi di setiap konfigurasi. Catat nilai  $K$  yang menghasilkan akurasi tertinggi.

2

## Data Sampler (70:30)

Tambahkan "Data Sampler" → atur ke 70% training. Aktifkan "Replicable (fixed seed)" agar hasil konsisten. Hubungkan ke File.

4

## Konfigurasi KNN

Tambahkan widget "kNN" → atur Number of Neighbors = 5 → Metric: Euclidean → hubungkan data training dari Data Sampler.

6

## Confusion Matrix

"Confusion Matrix" widget → hubungkan dari Predictions → amati sel TP, FP, FN, TN → cek tab Summary untuk Accuracy, F1.

8

## Interpretasi Hasil

Diskusikan: Spesies mana yang paling sering salah diklasifikasikan? Mengapa? Apakah sesuai dengan temuan EDA (scatter plot)?

*Setelah menjalankan EDA dan KNN, diskusikan pertanyaan-pertanyaan berikut bersama kelompok:*

?

## Apakah temuan EDA konsisten dengan hasil klasifikasi KNN?

Perhatikan: Iris Setosa mudah diklasifikasikan (terlihat dari scatter plot). Apakah akurasi untuk Setosa mendekati 100%? Apakah Versicolor dan Virginica memiliki error lebih tinggi?

?

## Mengapa normalisasi fitur penting sebelum menjalankan KNN?

Coba bandingkan akurasi KNN dengan data yang belum dinormalisasi vs. yang sudah. Jika tidak dinormalisasi, fitur dengan skala besar mendominasi perhitungan jarak Euclidean.

?

## Fitur mana yang paling informatif untuk klasifikasi spesies Iris?

Gunakan hasil Rank widget dan Scatter Plot. Biasanya petal length dan petal width memiliki rank tertinggi. Ini disebut 'feature importance'.

?

## Bagaimana nilai K mempengaruhi bias-variance tradeoff model KNN?

K kecil ( $K=1$ )  $\rightarrow$  low bias, high variance (overfitting). K besar  $\rightarrow$  high bias, low variance (underfitting). K optimal biasanya ditemukan by cross-validation.

## Data Mining adalah Proses Berulang

Mulai dari data mentah hingga knowledge, setiap tahap dapat diiterasi sesuai kebutuhan analisis.

## EDA Wajib Sebelum Modeling

EDA membantu memahami data, mendeteksi anomali, dan menentukan strategi preprocessing yang tepat.

## Preprocessing Menentukan Kualitas Model

Prinsip "garbage in, garbage out" berlaku ketat, data yang kotor akan menghasilkan model yang tidak andal.

## Metrik adalah Bahasa Evaluasi Model

Accuracy saja tidak cukup, Precision, Recall, F1-Score, dan Confusion Matrix memberikan gambaran lebih lengkap.

## KNN: Sederhana tapi Efektif

KNN bekerja dengan logika kemiripan (jarak). Normalisasi fitur dan pemilihan K yang tepat sangat menentukan hasilnya.

## Orange: Data Mining Tanpa Coding

Orange memungkinkan eksplorasi data dan pemodelan secara visual, cocok untuk pemula dan eksplorasi cepat.

Tugas Latihan Mandiri:

# Sekarang Giliran Anda!

1. Buka Orange Data Mining di komputer masing-masing
2. Load Dataset Iris → eksplorasi EDA (scatter plot, distribusi, korelasi)
3. Lakukan preprocessing: normalisasi, select columns
4. Bangun model KNN (K=5) → lihat Confusion Matrix
5. Eksperimen: ubah K dan bandingkan akurasi

Waktu: 45 menit | Kerjakan secara individual atau berpasangan | Siapkan screenshot hasil untuk presentasi singkat