

PROGRAM STUDY AKUNTANSI — UPNVJ

Big Data Analytics

TM 5: Classification & Regression Methods



KNN

Naive Bayes

Decision Tree

Ensemble Methods

Linear Regression

Dr. Donny Maha Putra

Dosen Pengampu Mata Kuliah Big Data Analytics

Agenda Perkuliahan

01



K-Nearest Neighbor (KNN)

Konsep, Euclidean Distance, dan praktik di Orange

02



Naïve Bayes Classifier

Teorema Bayes, asumsi independensi, dan praktik di Orange

03



Decision Tree

Struktur pohon keputusan dan visualisasi di Orange

04



Ensemble Methods

Random Forest & AdaBoost: bagging vs. boosting

05



Linear Regression

Regresi linier, feature selection, dan praktik di Orange

06



Evaluasi Model

Cross Validation, Confusion Matrix, dan metrik akurasi

BAGIAN 01

K-Nearest Neighbor (KNN)

Metode Klasifikasi Berbasis Kedekatan Jarak



Apa itu K-Nearest Neighbor (KNN)?

Definisi

KNN adalah metode klasifikasi yang bekerja dengan cara mencari sejumlah **k data terdekat (tetangga)** dari data baru yang ingin diklasifikasikan.

Kelas (label) dari data baru ditentukan berdasarkan **mayoritas kelas** dari k tetangga terdekat tersebut.
Karakteristik Utama:

- ✓ Termasuk supervised learning (pembelajaran terarah)
- ✓ Lazy learner: tidak membangun model secara eksplisit
- ✓ Nilai k menentukan jumlah tetangga yang diperiksa
- ✓ Menggunakan ukuran jarak untuk menemukan tetangga

Cara Kerja KNN

- 1 Tentukan nilai k (jumlah tetangga)
- 2 Hitung jarak antara data baru dengan semua data training
- 3 Urutkan jarak dari yang terdekat ke terjauh
- 4 Ambil k data dengan jarak terdekat
- 5 Tentukan kelas berdasarkan voting mayoritas

Euclidean Distance



Pengertian

Euclidean distance adalah metode pengukuran jarak antara dua titik dalam ruang multidimensi. Ini merupakan metrik jarak yang paling umum digunakan dalam algoritma KNN untuk menentukan kedekatan antara data baru dengan data training.

Formula Euclidean Distance

$$d(p,q) = \sqrt{\sum (q_i - p_i)^2}$$

Contoh Perhitungan (2D)

Titik A = (1, 2) dan Titik B = (4, 6)

$$d = \sqrt{[(4-1)^2 + (6-2)^2]}$$

$$d = \sqrt{[9 + 16]}$$

$$d = \sqrt{25} = 5$$



Selain Euclidean, terdapat metrik jarak lain seperti Manhattan Distance, Minkowski Distance, dan Cosine Similarity.

Pengaruh Nilai K terhadap Klasifikasi

K = 1

Underfitting Risk

Sangat sensitif terhadap noise. Model hanya melihat 1 tetangga terdekat, sehingga rentan terhadap data outlier.

K = 5

Balanced

Cukup stabil dan umum digunakan. Memberikan keseimbangan antara bias dan variance.

K terlalu besar

Overfitting Risk

Terlalu banyak tetangga membuat boundary menjadi terlalu halus, kehilangan pola lokal penting.



Tips Memilih K: Gunakan angka ganjil untuk menghindari tie (seri). Uji beberapa nilai K menggunakan cross-validation untuk menemukan K optimal.

Studi Kasus 1: Dataset Iris



Dataset Iris

Dataset iris berisi pengukuran kelopak dan mahkota bunga iris dari tiga spesies: Setosa, Versicolor, dan Virginica.

Fitur	Keterangan
Sepal Length	Panjang kelopak (cm)
Sepal Width	Lebar kelopak (cm)
Petal Length	Panjang mahkota (cm)
Petal Width	Lebar mahkota (cm)
Species	Target: Setosa / Versicolor / Virginica

150

Total Observasi

4

Fitur Input

3

Kelas Target




Tujuan


Mengklasifikasikan spesies bunga iris berdasarkan ukuran kelopak dan mahkota bunga.

Praktik KNN di Orange Data Mining

Workflow: Klasifikasi Iris dengan KNN



KNN MODEL



BAGIAN 02

Naïve Bayes Classifier

Klasifikasi Probabilistik Berbasis Teorema Bayes



Apa itu Naïve Bayes Classifier?



Definisi

Naïve Bayes adalah metode klasifikasi probabilistik yang menghitung peluang suatu data masuk ke kelas tertentu berdasarkan teorema Bayes, dengan asumsi bahwa setiap fitur bersifat independen (tidak saling memengaruhi) satu sama lain.

"Naïve" karena mengasumsikan independensi antar fitur.

Teorema Bayes

$$P(A|B) = P(B|A) \times P(A) / P(B)$$

$P(A B)$	Posterior → peluang kelas A jika diketahui fitur B
$P(B A)$	Likelihood → peluang fitur B pada kelas A
$P(A)$	Prior → peluang awal kelas A
$P(B)$	Evidence → peluang fitur B secara umum

Keunggulan Naïve Bayes:

Cepat & Efisien

Waktu komputasi rendah, cocok untuk dataset besar

Sederhana

Mudah diimplementasikan dan diinterpretasikan

Performa Baik

Efektif untuk text classification dan spam filtering

Studi Kasus 2: Dataset Adult (Census Income)



Dataset Adult

Dataset Adult (UCI) berisi data sensus penduduk AS. Tujuannya adalah memprediksi apakah pendapatan seseorang di atas atau di bawah \$50.000/tahun.

Fitur	Tipe	Contoh
Age	Numerik	39, 50, 28
Education	Kategorikal	Bachelors, HS-grad
Occupation	Kategorikal	Tech-support, Sales
Hours/week	Numerik	40, 50, 60
Income	Target	≤\$50K / >\$50K

48,842

Total Observasi

14

Fitur Input

2

Kelas Target

Evaluasi Model: Cross Validation



Apa itu Cross Validation?

Cross validation (K-Fold) adalah teknik evaluasi model yang membagi data menjadi K bagian (fold). Pada setiap iterasi, satu fold digunakan sebagai data test dan sisanya sebagai data training. Proses diulang K kali sehingga seluruh data pernah menjadi data test.

Metrik Evaluasi Umum:

CA (Classification Accuracy)

Proporsi prediksi benar

AUC

Area Under ROC Curve

Precision

Ketepatan prediksi positif

Recall

Sensitivitas mendeteksi kelas positif

Ilustrasi 5-Fold Cross Validation


Iter 1	Test	Train	Train	Train	Train
Iter 2	Train	Test	Train	Train	Train
Iter 3	Train	Train	Test	Train	Train
Iter 4	Train	Train	Train	Test	Train
Iter 5	Train	Train	Train	Train	Test




Dengan K-fold cross validation, estimasi performa model lebih reliable karena setiap data mendapat kesempatan menjadi test set.

Praktik Naïve Bayes di Orange Data Mining

Workflow: Klasifikasi Adult Income dengan Naïve Bayes



NAIVE BAYES



BAGIAN 03

Decision Tree

Klasifikasi Berbasis Pohon Keputusan



Apa itu Decision Tree?



Definisi

Decision tree adalah metode klasifikasi prediktif yang membentuk struktur pohon. Setiap node internal merepresentasikan pengujian terhadap suatu fitur, setiap cabang merepresentasikan hasil pengujian, dan setiap leaf (daun) merepresentasikan kelas akhir.

Komponen Decision Tree

Root Node	Node paling atas, fitur pertama yang diuji
Internal Node	Node yang menguji kondisi fitur tertentu
Branch	Cabang yang menghubungkan hasil pengujian
Leaf Node	Kelas akhir (hasil prediksi)

Kriteria Pemisahan (Splitting Criteria):

Information Gain

Mengukur pengurangan entropi setelah pemisahan data. Semakin tinggi information gain, semakin baik fitur tersebut memisahkan kelas.

Gini Index

Mengukur probabilitas kesalahan klasifikasi. Nilai Gini yang lebih rendah menunjukkan pemisahan yang lebih murni.

Gain Ratio

Normalisasi information gain untuk mengatasi bias terhadap fitur dengan banyak nilai unik.

Studi Kasus 3: Dataset Seeds



Dataset Seeds

Dataset Seeds (UCI) berisi informasi ukuran biji padi dari 3 varietas: Kama, Rosa, dan Canadian. Tujuannya adalah mengklasifikasikan varietas berdasarkan karakteristik fisik biji.

Fitur	Keterangan
Area	Luas permukaan biji
Perimeter	Keliling biji
Compactness	Kekompakan bentuk
Kernel Length	Panjang kernel
Kernel Width	Lebar kernel
Asymmetry Coeff	Koefisien asimetri
Groove Length	Panjang alur biji

210

Total Observasi

7

Fitur Input

3


Varietas

Download data:

<https://www.kaggle.com/dongearge/seed-from-uci>

Praktik Decision Tree di Orange Data Mining

Workflow: Klasifikasi Seeds dengan Decision Tree



BAGIAN 04

Ensemble Methods

Random Forest & AdaBoost



Random Forest



Definisi

Random Forest adalah metode ensemble yang menggabungkan beberapa decision tree untuk meningkatkan akurasi dan mengurangi overfitting. Setiap tree dilatih menggunakan subset data dan subset fitur yang berbeda (bagging).

Prediksi akhir ditentukan melalui majority voting dari seluruh tree.

Cara Kerja Random Forest

1. Buat beberapa subset data secara acak (bootstrap sampling)
2. Untuk setiap subset, bangun decision tree dengan fitur acak
3. Setiap tree menghasilkan prediksi secara independen
4. Hasil akhir diambil dari voting mayoritas semua tree

Bagging

Bootstrap Aggregating melatih model paralel pada subset data berbeda

Feature Randomness

Setiap tree hanya melihat subset fitur yang acak

Robust

Tahan terhadap overfitting dan noise dalam data

AdaBoost (Adaptive Boosting)



Definisi

AdaBoost adalah metode ensemble yang melatih model secara sekuensial. Setiap model baru difokuskan pada data yang salah diklasifikasikan oleh model sebelumnya, sehingga secara bertahap memperbaiki kesalahan.


Memperkuat weak learner menjadi strong learner.

Cara Kerja AdaBoost

- 1 Latih weak learner pertama pada seluruh data
- 2 Identifikasi data yang salah diklasifikasikan
- 3 Tingkatkan bobot data yang salah untuk iterasi berikutnya
- 4 Latih weak learner baru pada data berbobot
- 5 Gabungkan semua learner dengan voting berbobot

Random Forest vs. AdaBoost

Aspek	Random Forest	AdaBoost
Pendekatan	Bagging (paralel)	Boosting (sekuensial)
Training	Non-sekuensial	Sekuensial, iteratif
Sensitivitas noise	Rendah (robust)	Tinggi (sensitif terhadap outlier)
Voting	Equal voting	Weighted voting



BAGIAN 05

Linear Regression

Metode Prediksi Nilai Kontinu



Apa itu Regresi Linier?



Definisi

Regresi linier adalah metode untuk memprediksi nilai kontinu (numerik) dengan cara menarik garis lurus yang paling mendekati pola hubungan antara variabel independen (X) dan variabel dependen (Y).

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \varepsilon$$

Komponen Formula

Y	Variabel dependen (yang diprediksi)
β_0	Intercept (konstanta)
$\beta_1, \beta_2, \dots$	Koefisien regresi (slope)
$X_1, X_2, \dots$	Variabel independen (prediktor)
ε	Error term (residual)



Perbedaan dengan Klasifikasi: Regresi memprediksi nilai kontinu (misal: harga rumah Rp 500 juta), sedangkan klasifikasi memprediksi kategori/kelas (misal: spam atau bukan spam). Metrik evaluasi regresi menggunakan MSE, RMSE, MAE, dan R^2 , bukan akurasi.

Studi Kasus 4: Dataset Boston Housing



Dataset Boston Housing

Dataset ini berisi data properti di wilayah Boston. Tujuannya adalah memprediksi harga median rumah (MEDV) berdasarkan kondisi lingkungan sekitar.

Fitur	Keterangan
CRIM	Tingkat kriminalitas per kapita
RM	Jumlah rata-rata kamar per rumah
LSTAT	% penduduk berpendapatan rendah
PTRATIO	Rasio murid-guru
NOX	Konsentrasi nitrogen oksida
MEDV	Target: Harga median (\$1000s)

506

Total Observasi

13


Fitur Input

Kontinu

Target Variable

Praktik Linear Regression di Orange Data Mining

Workflow: Prediksi Harga Rumah dengan Linear Regression



Metrik Evaluasi Regresi

MSE

Mean Squared Error

$$\Sigma(y_i - \hat{y}_i)^2 / n$$

Rata-rata kuadrat selisih antara nilai aktual dan prediksi. Sensitif terhadap outlier karena error dikuadratkan.

RMSE

Root Mean Squared Error

$$\sqrt{\text{MSE}}$$

Akar kuadrat dari MSE. Lebih mudah diinterpretasikan karena memiliki satuan yang sama dengan variabel target.

MAE

Mean Absolute Error

$$\Sigma|y_i - \hat{y}_i| / n$$

Rata-rata nilai absolut selisih antara aktual dan prediksi. Lebih robust terhadap outlier dibanding MSE.

R²

Coefficient of Determination

$$1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$$

Proporsi variansi yang dapat dijelaskan oleh model. Nilai 0-1, semakin mendekati 1 semakin baik.

BAGIAN 06

Evaluasi Model Klasifikasi

Confusion Matrix & Metrik Performa



Confusion Matrix (Matriks Kebingungan)

Confusion matrix adalah tabel yang menunjukkan perbandingan antara kelas aktual dan kelas yang diprediksi oleh model.

Confusion Matrix (Binary Classification)

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP True Positive	FN False Negative
Aktual Negatif	FP False Positive	TN True Negative

Metrik dari Confusion Matrix

Accuracy

$$(TP + TN) / \text{Total}$$

Proporsi seluruh prediksi yang benar

Precision

$$TP / (TP + FP)$$

Dari yang diprediksi positif, berapa yang benar

Recall

$$TP / (TP + FN)$$

Dari yang aktual positif, berapa yang terdeteksi

F1-Score

$$2 \times P \times R / (P + R)$$

Harmonic mean dari Precision dan Recall

Perbandingan Semua Metode

Aspek	KNN	Naïve Bayes	Decision Tree	Random Forest	Linear Reg.
Tipe	Klasifikasi	Klasifikasi	Klasifikasi	Klasifikasi	Regresi
Pendekatan	Instance-based	Probabilistik	Rule-based	Ensemble	Statistik
Training	Lazy (tanpa model)	Sangat cepat	Cepat	Sedang	Cepat
Interpretasi	Rendah	Sedang	Tinggi	Rendah	Tinggi
Handling Noise	Sensitif	Robust	Sensitif	Sangat Robust	Sensitif
Asumsi	Jarak bermakna	Independensi fitur	Tidak ada	Tidak ada	Linearitas
Dataset di Orange	Iris	Adult	Seeds	Seeds	Boston Housing

Tips Menggunakan Orange Data Mining

Mulai dari Data Exploration

Sebelum membangun model, selalu eksplorasi data terlebih dahulu menggunakan widget Data Table, Distributions, dan Scatter Plot untuk memahami pola dan distribusi data.

Gunakan Test and Score untuk Evaluasi

Jangan hanya melihat akurasi satu kali. Gunakan k-fold cross validation (10-fold) untuk mendapatkan estimasi performa model yang lebih reliable.

Perhatikan Preprocessing

Normalisasi fitur (Normalize Features) penting untuk KNN. Untuk Decision Tree dan Naïve Bayes, normalisasi tidak selalu diperlukan.

Hubungkan Widget dengan Benar

Perhatikan tipe koneksi antar widget. Garis hijau menunjukkan data mengalir dengan benar. Garis merah menunjukkan ketidakcocokan tipe data.

Bandingkan Beberapa Model

Hubungkan beberapa model (KNN, NB, Tree, RF) ke satu Test and Score widget untuk membandingkan performa secara langsung dan memilih model terbaik.

Simpan Workflow

Simpan workflow Orange Anda (.ows) agar dapat digunakan kembali. Workflow yang baik adalah yang terdokumentasi dan mudah dipahami.

Tugas Praktik Mandiri



Instruksi Penugasan

- 1 Buka Orange Data Mining dan muat dataset Iris dari widget Datasets.
- 2 Bangun workflow lengkap: Data → Preprocess → Model → Test and Score → Confusion Matrix.
- 3 Terapkan 3 metode klasifikasi: KNN ($k=5$), Naïve Bayes, dan Decision Tree.
- 4 Gunakan 10-fold cross validation pada Test and Score.
- 5 Bandingkan CA (Classification Accuracy), Precision, Recall, dan F1 dari ketiga model.
- 6 Screenshot workflow dan hasil evaluasi, kemudian buat laporan singkat yang menjelaskan model mana yang paling baik dan mengapa.
- 7 Eksplorasi: Coba ubah nilai K pada KNN ($k=1$, $k=3$, $k=7$, $k=11$) dan amati perubahan akurasi.

Referensi dan Sumber Belajar

Buku Referensi

Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques. 3rd Ed. Morgan Kaufmann.

Tan, P.N., Steinbach, M., & Kumar, V. (2019). Introduction to Data Mining. 2nd Ed. Pearson.

Online Resources

Orange Data Mining Documentation: <https://orangedatamining.com/docs/>

UCI Machine Learning Repository: <https://archive.ics.uci.edu/>

Scikit-learn Documentation: <https://scikit-learn.org/>

Video Pembelajaran

Crash Course Statistics #24: Bayesian Statistics

StatQuest: Decision Trees, Random Forest, AdaBoost

Terima Kasih

Dr. Donny Maha Putra

Program Studi Akuntansi UPNVJ

Big Data Analytics — TM 5