

DATA MINING

Regresi Linier • K-Means Clustering • Association Rule Apriori
menggunakan Orange Data Mining

Dr. Donny Maha Putra

Big Data Analytics Prodi SI Akuntansi UPNVJ

Agenda Hari Ini

Tiga studi kasus praktik data mining menggunakan Orange

01



Regresi Harga Rumah

Memprediksi harga rumah berdasarkan kondisi lingkungan

Linear Regression
Dataset: Boston Housing

02



Clustering Pelanggan

Segmentasi pelanggan toko berdasarkan perilaku belanja

K-Means Clustering
Dataset: Mall Customer

03



Asosiasi Barang Belanja

Menemukan pola pembelian barang yang sering dibeli bersamaan

Apriori Algorithm
Dataset: Groceries


TOPIK 1

Regresi Harga Rumah

Prediksi Harga Rumah Menggunakan Linear Regression

Apa itu Regresi Linier?

- Regresi Linier adalah teknik supervised learning yang memprediksi nilai numerik (kontinu) berdasarkan hubungan linier antara variabel independen (X) dan variabel dependen (Y).
- Rumus dasarnya mirip persamaan garis lurus: $Y = a + bX$, di mana a adalah intercept (konstanta), b adalah koefisien (slope), X adalah variabel prediktor, dan Y adalah variabel target.
- Pada kasus regresi berganda (multiple regression), model menggunakan lebih dari satu variabel independen: $Y = a + b_1X_1 + b_2X_2 + \dots + b_nX_n$.
- Model regresi bekerja dengan menarik garis lurus yang "paling pas" (best fit line) melalui titik-titik data, sehingga total jarak error antara prediksi dan nilai aktual sekecil mungkin.
- Metode yang digunakan untuk menemukan garis terbaik adalah Ordinary Least Squares (OLS) meminimalkan jumlah kuadrat error (Sum of Square Residuals).
- Evaluasi model regresi menggunakan metrik seperti R^2 (seberapa baik model menjelaskan variasi data), MAE (rata-rata error absolut), dan RMSE (akar rata-rata kuadrat error).



Semakin tinggi nilai R^2 (mendekati 1), semakin baik model menjelaskan variasi dalam data. Namun R^2 tinggi tidak selalu berarti model bagus, perlu diperiksa juga residual dan overfitting.

Sumber Data: Boston Housing

Dataset Boston Housing

Dataset berisi 506 observasi tentang informasi perumahan di wilayah Boston, Massachusetts. Tujuannya adalah memprediksi harga median rumah (MEDV) berdasarkan 13 variabel kondisi lingkungan.

Cara Mendapatkan Data

1. Buka Orange Data Mining
2. Gunakan widget Datasets
3. Cari "housing" di daftar dataset bawaan Orange
4. Klik untuk memuat dataset

Alternatif: Download dari Kaggle (Boston Housing Dataset) dalam format .csv, lalu load via widget File.

Variabel/Field Utama

Variabel	Keterangan
RM	Rata-rata jumlah kamar per rumah
LSTAT	% populasi dengan status ekonomi rendah
CRIM	Tingkat kriminalitas per kapita
TAX	Tarif pajak properti per \$10.000
AGE	Proporsi unit hunian dibangun sebelum 1940
MEDV	Nilai median rumah dalam \$1.000 (TARGET)



Proses di Orange: Regresi Linier

Tahapan Step-by-Step di Orange Data Mining

1

File / Datasets Muat dataset Boston Housing dari widget Datasets bawaan Orange → klik dua kali untuk melihat data

2

Data Table Periksa data: lihat jumlah baris, kolom, tipe data, dan ada tidaknya missing value — pastikan MEDV sebagai target

3

Select Columns Tentukan role variabel: pindahkan MEDV ke Target Variable, sisanya sebagai Features

4

Correlations Gunakan widget Correlations untuk melihat korelasi Pearson antar variabel — identifikasi fitur yang paling berkorelasi dengan MEDV (misal: RM, LSTAT)

5


Rank Widget Rank untuk mengurutkan fitur berdasarkan relevansi terhadap target — bantu memilih fitur terbaik (feature selection)

6

Linear Regression Hubungkan data ke widget Linear Regression — Orange otomatis menghitung koefisien, intercept, dan model regresi

7

Test and Score Evaluasi model: pilih Cross Validation (5-fold atau 10-fold) → perhatikan R^2 , MAE, RMSE untuk menilai kualitas prediksi





Interpretasi Output: Regresi Linier

- R^2 (R-squared): Angka antara 0–1 yang menunjukkan seberapa besar variasi harga rumah (MEDV) dapat dijelaskan oleh model. Contoh: $R^2 = 0.72$ artinya 72% variasi harga dapat diprediksi oleh model.
- MAE (Mean Absolute Error): Rata-rata selisih absolut antara harga prediksi dan harga aktual. Contoh: MAE = 3.4 artinya rata-rata prediksi meleset sekitar \$3.400 dari harga sebenarnya.
- RMSE (Root Mean Squared Error): Mirip MAE tetapi lebih sensitif terhadap error besar. RMSE yang jauh lebih tinggi dari MAE mengindikasikan adanya outlier dalam prediksi.
- Koefisien variabel: Menunjukkan arah dan kekuatan pengaruh setiap variabel. Contoh: koefisien RM (jumlah kamar) = +3.8 artinya setiap penambahan 1 kamar, harga rumah naik ~\$3.800.
- Koefisien negatif pada LSTAT (-0.95) berarti semakin tinggi persentase populasi berstatus ekonomi rendah, semakin rendah harga rumah di area tersebut.
- Pada Correlations: cari korelasi kuat (>0.5 atau <-0.5) antara fitur dan target. RM biasanya berkorelasi positif kuat, LSTAT berkorelasi negatif kuat dengan MEDV.


TOPIK 2

Clustering Pelanggan Toko

Segmentasi Pelanggan Menggunakan K-Means

Apa itu K-Means Clustering?

- K-Means adalah algoritma unsupervised learning (tanpa label) yang membagi data menjadi K kelompok (cluster) berdasarkan kemiripan data dalam satu cluster lebih mirip satu sama lain dibanding dengan cluster lain.
- Cara kerja K-Means: (1) Tentukan jumlah cluster K, (2) Tempatkan K centroid secara acak, (3) Setiap data diassign ke centroid terdekat, (4) Hitung ulang posisi centroid dari rata-rata anggota cluster, (5) Ulangi langkah 3-4 hingga posisi centroid stabil (konvergen).
- Jarak antar data dihitung menggunakan Euclidean Distance, maka normalisasi data sangat penting agar variabel berskala besar tidak mendominasi.
- Penentuan nilai K optimal bisa menggunakan Elbow Method (cari "siku" pada plot distorsi) atau Silhouette Score (skor validasi cluster).
- Silhouette Score mengukur seberapa mirip data dengan cluster-nya sendiri dibanding cluster tetangga. Nilai berkisar -1 hingga 1, semakin mendekati 1 semakin baik.
- K-Means cocok untuk segmentasi pelanggan, market basket grouping, anomaly detection, dan pengelompokan dokumen.



K-Means sensitif terhadap inisialisasi centroid awal. Orange menggunakan K-Means++ secara default untuk inisialisasi yang lebih cerdas.

Sumber Data: Mall Customer

Dataset Mall Customer

Dataset berisi 200 observasi data pelanggan sebuah mall/toko. Tujuannya adalah mengelompokkan pelanggan berdasarkan perilaku belanja untuk strategi pemasaran yang lebih tepat sasaran.

Cara Mendapatkan Data

1. Download dari Kaggle: cari "Mall Customer Segmentation Data"
2. File berbentuk .csv
3. Buka Orange → gunakan widget File
4. Browse dan pilih file Mall_Customers.csv
5. Pastikan semua kolom numerik terdeteksi sebagai continuous

Variabel/Field Utama

Variabel	Keterangan
CustomerID	ID unik pelanggan (identifier, bukan fitur analisis)
Gender	Jenis kelamin pelanggan (Male/Female)
Age	Usia pelanggan
Annual Income (k\$)	Pendapatan tahunan pelanggan dalam ribuan dolar
Spending Score	Skor belanja (1–100) yang diberikan oleh toko berdasarkan perilaku



Proses di Orange: K-Means Clustering

Tahapan Step-by-Step di Orange Data Mining

1

File Muat dataset Mall_Customers.csv → pastikan semua kolom numerik terdeteksi benar (Age, Annual Income, Spending Score)

2

Select Columns Pindahkan CustomerID ke Meta (bukan fitur), pilih Annual Income dan Spending Score sebagai Features utama

3

Preprocess Terapkan Normalize (standarisasi) agar skala antar variabel seragam — penting karena K-Means berbasis jarak

4


k-Means Hubungkan ke widget k-Means → atur jumlah cluster (mulai K=3 sampai K=6) → lihat Silhouette Score di setiap K

5

Scatter Plot Visualisasikan hasil cluster: X-axis = Annual Income, Y-axis = Spending Score, Color = Cluster — lihat apakah segmentasi terlihat jelas

6


Silhouette Plot Hubungkan output k-Means ke widget Silhouette Plot → evaluasi kualitas setiap cluster dan identifikasi data yang tidak pas (skor negatif)





Interpretasi Output: K-Means Clustering

- Silhouette Score rata-rata: Skor keseluruhan >0.5 menunjukkan struktur cluster yang reasonably good. Skor >0.7 menunjukkan pengelompokan yang kuat dan jelas.
- Pada Scatter Plot, cluster yang baik terlihat sebagai kelompok-kelompok yang terpisah jelas tanpa banyak tumpang tindih (overlap). Jika cluster saling tumpang tindih, pertimbangkan untuk mengubah nilai K.
- Contoh segmentasi 5 cluster: C1 (High Income, High Spending) = pelanggan premium, C2 (High Income, Low Spending) = pelanggan hemat/potensial, C3 (Low Income, High Spending) = pelanggan impulsif, C4 (Low Income, Low Spending) = pelanggan pasif, C5 (Average) = pelanggan mainstream.
- Silhouette Plot per cluster: Cluster dengan bar panjang dan seragam menunjukkan cluster yang kompak dan homogen. Bar yang pendek atau negatif menandakan data yang "salah" cluster.
- Implikasi bisnis: Setiap cluster memerlukan strategi pemasaran berbeda pelanggan premium dapat ditarget dengan program loyalitas, sementara pelanggan potensial perlu promosi yang lebih agresif.
- Jumlah anggota per cluster memberikan gambaran proporsi segmen cluster terbesar menunjukkan segmen pelanggan mayoritas yang perlu diijaga.



TOPIK 3

Asosiasi Barang Belanja

Market Basket Analysis Menggunakan Apriori

Apa itu Association Rule & Apriori?

- Association Rule Mining adalah teknik unsupervised learning untuk menemukan hubungan (asosiasi) antar item dalam kumpulan transaksi, sering disebut Market Basket Analysis.
- Contoh sederhana: "Jika pelanggan membeli Roti, maka kemungkinan besar juga membeli Mentega" aturan ini dinyatakan sebagai $\{\text{Roti}\} \rightarrow \{\text{Mentega}\}$.
- Apriori adalah algoritma paling populer untuk menemukan association rules. Cara kerjanya: (1) Temukan itemset yang sering muncul (frequent itemset), (2) Generate aturan asosiasi dari itemset tersebut.
- Tiga metrik utama: Support = seberapa sering itemset muncul dalam total transaksi (frekuensi), Confidence = probabilitas item B dibeli jika item A sudah dibeli (kekuatan aturan), Lift = seberapa kuat hubungan dibanding kebetulan (jika $\text{lift} > 1$ = hubungan positif).
- Contoh: $\text{Support}(\{\text{Roti}, \text{Mentega}\}) = 30\%$, artinya 30% dari seluruh transaksi mengandung Roti dan Mentega bersamaan.
- $\text{Confidence}(\{\text{Roti}\} \rightarrow \{\text{Mentega}\}) = 75\%$ artinya dari semua transaksi yang mengandung Roti, 75% juga mengandung Mentega. $\text{Lift} = 1.5$ artinya hubungan ini 1.5x lebih kuat dibanding



Lift > 1 menunjukkan asosiasi positif (item saling mendorong). Lift = 1 artinya independen (tidak ada hubungan). Lift < 1 artinya asosiasi negatif.

Sumber Data: Groceries

Dataset Groceries

Dataset berisi catatan transaksi pembelian barang belanjaan di sebuah supermarket. Setiap baris merepresentasikan satu transaksi yang berisi daftar item yang dibeli bersamaan oleh satu pelanggan.

Cara Mendapatkan Data

1. Buka Orange Data Mining
2. Gunakan widget Datasets
3. Cari "groceries" di daftar dataset bawaan
4. Klik untuk memuat dataset

Alternatif: Download dari Kaggle (Groceries Dataset), format .csv dengan item per transaksi.

Variabel/Field Utama

Variabel	Keterangan
Transaction ID	ID unik setiap transaksi pembelian
Items	Daftar barang yang dibeli dalam satu transaksi
Contoh item	whole milk, bread, vegetables, yogurt, soda, dll.
Format data	Basket format: setiap baris = satu transaksi, kolom = item (0/1 atau True/False)



Proses di Orange: Apriori Association

Tahapan Step-by-Step di Orange Data Mining

1

File / Datasets Muat dataset Groceries dari widget Datasets — Orange akan menampilkan data dalam format transaksional (biner)

2

Data Table Periksa data: setiap kolom mewakili satu jenis barang, nilai True/False menunjukkan apakah barang tersebut dibeli dalam transaksi itu

3


Association Rules Hubungkan ke widget Association Rules → atur parameter: Min Support (misal 1-5%), Min Confidence (misal 30-50%)

4

Baca Output Rules Output menampilkan aturan asosiasi lengkap: Antecedent → Consequent beserta nilai Support, Confidence, dan Lift

5

Filter & Sortir Urutkan rules berdasarkan Lift tertinggi atau Confidence tertinggi untuk menemukan asosiasi yang paling kuat dan bermakna





Interpretasi Output: Association Rules

- Setiap baris output menunjukkan satu aturan asosiasi: kolom kiri (Antecedent) = item pemicu, kolom kanan (Consequent) = item yang diprediksi, beserta ketiga metriknya.
- Contoh aturan: {yogurt, bread} → {whole milk} dengan Support=5%, Confidence=60%, Lift=2.3. Artinya: 5% total transaksi mengandung ketiga item ini, dan dari yang beli yogurt+bread, 60% juga beli whole milk.
- Lift = 2.3 artinya kombinasi ini 2.3 kali lebih sering muncul dibanding jika tidak ada hubungan — asosiasi cukup kuat dan bukan kebetulan.
- Aturan dengan Support rendah tapi Confidence dan Lift tinggi menunjukkan pola niche yang jarang terjadi tapi sangat konsisten — berguna untuk promosi targeted.
- Implikasi bisnis: Aturan asosiasi digunakan untuk product placement (taruh item terkait berdekatan di rak), bundle promotion (diskon paket), dan recommendation engine ("pelanggan juga membeli...").
- Semakin rendah threshold Min Support yang diatur, semakin banyak aturan ditemukan — tapi terlalu rendah akan menghasilkan aturan yang kurang bermakna (noise).

Rangkuman TM 6

Regresi Linier

- Supervised learning prediksi nilai numerik
- Dataset: Boston Housing (506 obs, 13 variabel)
- Workflow: Load → Correlations → Rank → Linear Regression → Test & Score
- Evaluasi: R^2 , MAE, RMSE

K-Means Clustering

- Unsupervised learning segmentasi kelompok
- Dataset: Mall Customer (200 obs, 5 variabel)
- Workflow: Load → Select Columns → Normalize → k-Means → Scatter Plot → Silhouette
- Evaluasi: Silhouette Score (>0.5 = baik)

Apriori Association

- Unsupervised learning menemukan pola asosiasi
- Dataset: Groceries (data transaksional)
- Workflow: Load → Association Rules
- Evaluasi: Support, Confidence, Lift (Lift >1 = asosiasi positif)



TUGAS MANDIRI

Dikerjakan di Luar Kelas

Association Rules

Gunakan dataset "Groceries" atau Market Basket dari Kaggle. Temukan minimal 10 aturan asosiasi bermakna. Laporkan: screenshot workflow, tabel 10 rules terbaik (Support, Confidence, Lift), dan interpretasi 3 aturan paling menarik secara bisnis.

THANK YOU

Dr. Donny Maha Putra

TM 6 — Big Data Analytics
Regresi Linier • K-Means Clustering • Association Rule Apriori