

ANALISIS INDIKATOR PERSETUJUAN PINJAMAN BANK BERDASARKAN KARAKTERISTIK PEMOHON



Kelompok 2 - Kelas A

- Nurlita Syaharani Jianiar (2310112233)
- Faiq Favian Kurniawantoro (2310112013)
- Arinii Nisa Qurrotaa'yun (2310112137)

Orange Data Mining



Pendahuluan



Perkembangan sektor keuangan yang semakin pesat ini membuat pengelolaan risiko kredit menjadi salah satu tantangan utama bagi pihak perbankan dan keuangan. Risiko kredit adalah kemungkinan kerugian yang muncul karena kegagalan debitur dalam membayar pinjaman yang telah diberikan (tidak mampu membayar pinjaman). Ketika tingkat gagal bayar (*loan default*) meningkat, dampaknya tidak hanya pada kerugian finansial saja, tetapi juga dapat mengganggu stabilitas operasional dan kinerja lembaga keuangan secara keseluruhan.

Rumusan Masalah

Apa model klasifikasi yang paling akurat di antara *K-Nearest Neighbour* (KNN), *Decision Tree*, *Random Forest*, *Naive Bayes*, dan *AdaBoost* dalam memprediksi status persetujuan pinjaman debitur (*LoanApproved*) berdasarkan data diri dan profil finansial mereka?

Bagaimana perbandingan tingkat akurasi antara model *Linear Regression*, *Random Forest Regression*, *Regression Tree*, dan *Gradient Boosting* dalam mengestimasi jumlah pinjaman (*LoanAmount*)? Serta, faktor manakah (seperti pendapatan, skor kredit, usia, atau pengalaman kerja) yang paling memberikan pengaruh signifikan terhadap besaran pinjaman tersebut?

Bagaimana hasil pemetaan kelompok debitur jika diklasterkan menggunakan metode *K-Means*, *Hierarchical Clustering*, dan *DBSCAN* berdasarkan atribut usia, pendapatan, jumlah pinjaman, skor kredit, dan pengalaman kerja? Serta, bagaimana perbedaan karakteristik risiko kredit yang terbentuk pada masing-masing kelompok tersebut?

Deskripsi Dataset



Dataset yang digunakan dalam proyek ini adalah *Loan Risk Prediction Dataset* yang bisa diakses secara publik di platform Kaggle. Dataset ini berisi 5.000 debitur dengan 10 karakteristik, dalam format CSV yang langsung diaplikasikan di Orange Data Mining. Dataset ini sudah terstruktur dengan rapi sehingga mudah digunakan dalam proses analisis, baik untuk melihat gambaran data secara umum maupun membuat model prediksi. Dataset ini menggambarkan profil peminjam dari empat kota besar di Amerika Serikat, yaitu Houston, San Francisco, New York, dan Chicago, dengan usia antara 18 hingga 69 tahun.

- Age => Usia Peminjaman (Numerical)
- Income => Pendapatan tahunan (Numerical)
- LoanAmount => Jumlah pinjaman (Numerical)
- CreditScore => Skor kredit peminjam (Numerical)
- YearsExperience => Lama pekerjaan (Numerical)
- Gender => Jenis Kelamin= Categorical
- Education => Tingkat pendidikan (Categorical)
- City= Kota domisili => (Categorical)
- EmploymentType => Jenis Pekerjaan => (Categorical)
- LoanApproved => Status persetujuan pinjaman (Categorical)



Tinjauan Pustaka

Data mining dapat disebut sebagai proses untuk menemukan korelasi atau pola dari ratusan bahkan ribuan field pada sebuah relasional database yang besar (Berry, M.J.A 2004). Dalam penerapannya, data mining memiliki beberapa metode yaitu:

Classification

Klasifikasi dalam data mining merupakan proses untuk mencari model atau fungsi yang menggambarkan dan membedakan kelas-kelas konsep data. Klasifikasi adalah sebuah proses training suatu fungsi yang memiliki target untuk digunakan memetakan tiap himpunan objek ke suatu kelas yang sudah didefinisikan.

Regression

Regresi dalam data mining digunakan untuk mencari prediksi dari suatu pola yang ada, dimana digunakan untuk menganalisis hubungan antara variabel-variabel dalam data, serta memprediksi tentang nilai-nilai variabel tertentu. Selain untuk menilai hubungan, regresi juga digunakan untuk mendeteksi anomali dalam data dengan memeriksa nilai residualnya.

clustering

Klastering digunakan untuk mencari pengelompokan atribut kedalam segmentasi-segmentasi berdasarkan similaritas pada karakteristik tertentu. Teknik klastering digunakan untuk mencari struktur dalam data tanpa memerlukan label kelas yang telah ditentukan sebelumnya.



Interpretasi Hasil Klasifikasi

Show performance scores							Target class:	(Average over classes)
Model	AUC	CA	F1	Prec	Recall	MCC		
kNN	0.943	0.904	0.899	0.904	0.904	0.725		

Model KNN menunjukkan performa yang baik dengan nilai AUC 0.943, yang berarti mampu membedakan nasabah layak dan tidak layak dengan sangat baik. Akurasi sebesar 0.904 menunjukkan sebagian besar prediksi sudah benar. Nilai precision dan recall yang seimbang (0.904) menandakan model cukup tepat dan tidak banyak melewatkan nasabah yang layak. F1 score 0.899 menunjukkan keseimbangan performa, sedangkan MCC 0.725 menunjukkan model cukup stabil dan dapat dipercaya.

Evaluation results for target (None, show average over classes)						
Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.944	0.969	0.969	0.969	0.969	0.912
Random Forest	0.944	0.968	0.967	0.967	0.968	0.907
Naive Bayes	0.937	0.944	0.944	0.945	0.944	0.844
AdaBoost	0.905	0.928	0.929	0.929	0.928	0.800
Gradient Boosting	0.947	0.969	0.969	0.969	0.969	0.912

Semua model klasifikasi menunjukkan performa yang baik pada dataset loan risk prediction, namun terdapat perbedaan kinerja di tiap model. Decision Tree dan Random Forest memiliki performa tinggi dengan akurasi di atas 0.96 dan AUC 0.944. Naive Bayes masih cukup baik, meskipun sedikit lebih rendah karena keterbatasan dalam menangkap pola kompleks. AdaBoost menjadi model dengan performa paling rendah dibandingkan yang lain. Sementara itu, Gradient Boosting memberikan hasil terbaik dengan AUC tertinggi (0.947) dan akurasi 0.969, sehingga paling optimal digunakan untuk prediksi loan approval.

Confusion Matrix - Orange				
Learners		Show: Number of instances		
kNN				
		Predicted		
		0	1	Σ
Actual	0	1111	27	1138
	1	117	245	362
Σ		1228	272	1500


Model KNN mengenali sebagian besar nasabah yang tidak layak dengan baik, terlihat dari jumlah prediksi benar yang cukup tinggi. Kesalahan dalam memberikan persetujuan kepada nasabah yang tidak layak relatif kecil. Namun, model masih cukup sering melewatkan nasabah yang sebenarnya layak, sehingga cenderung lebih ketat dalam memberikan persetujuan pinjaman.

Confusion Matrix (1) - Orange				
Learners		Show: Number of instances		
Tree Random Forest Naive Bayes AdaBoost Gradient Boosting				
		Predicted		
		0	1	Σ
Actual	0	3808	41	3849
	1	121	1030	1151
Σ		3929	1071	5000


Model Random Forest kelihatan cukup kuat dalam mengenali nasabah yang tidak layak, karena kesalahan dalam memberikan persetujuan sangat sedikit. Dari sisi risiko, ini termasuk aman. Walaupun masih ada beberapa nasabah yang sebenarnya layak tapi tidak terdeteksi, secara keseluruhan model ini cukup stabil dan bisa diandalkan.




Interpretasi Hasil Klasifikasi




Model Decision Tree menunjukkan performa yang sangat baik. Sebagian besar nasabah yang tidak layak berhasil dikenali dengan benar, dan kesalahan dalam memberikan persetujuan juga sangat kecil. Selain itu, jumlah nasabah layak yang berhasil diprediksi juga tinggi. Secara keseluruhan, model ini cukup akurat dan seimbang dalam mengambil keputusan




Berdasarkan decision tree, faktor utama yang menentukan loan approved adalah credit score. Jika nilainya rendah, nasabah langsung dianggap tidak layak. Jika cukup tinggi, model lanjut melihat employment type, di mana nasabah tanpa pekerjaan tetap cenderung ditolak. Untuk nasabah yang memiliki pekerjaan, keputusan ditentukan oleh income. Pendapatan rendah cenderung ditolak, sedangkan pendapatan tinggi umumnya disetujui.



Model ini masih cukup oke, tapi mulai terlihat lebih banyak kesalahan dibanding Decision Tree. Kesalahan dalam memberikan persetujuan ke nasabah yang tidak layak cukup sering terjadi. Walaupun begitu, kemampuan dalam mengenali nasabah yang layak masih cukup baik, hanya saja belum sebersih model yang lebih kompleks



Performa AdaBoost terlihat paling menurun dibanding model lainnya. Kesalahan terjadi di dua sisi sekaligus, baik dalam menyetujui nasabah yang tidak layak maupun menolak yang sebenarnya layak. Ini membuat model jadi kurang stabil untuk digunakan dalam kasus loan approval.



Model Gradient Boosting terlihat paling rapi dan seimbang. Kesalahan yang terjadi relatif kecil, baik dalam salah approve maupun salah tolak. Selain itu, model ini juga sedikit lebih baik dalam menangkap nasabah yang layak dibanding model lain, sehingga lebih seimbang antara hati-hati dan tidak kehilangan peluang.




Interpretasi Hasil Regresi

Model	MSE	RMSE	MAE	MAPE	sMAPE	R ²
Linear Regression	64837336.438	8052.163	6421.549	213.198	35.089	-0.002
Gradient Boosting	66318053.348	8143.590	6490.223	209.845	35.419	-0.024
Tree	67216461.960	8198.565	6518.100	214.801	35.564	-0.038
Random Forest	70115774.386	8373.516	6677.630	217.907	36.337	-0.083


Algoritma yang terbaik adalah linear regresi dengan R² (-0.002), MAE (6.421), RMSE (8.052), MAPE (213.198)

R² negatif mengartikan algoritma belum mampu memprediksi Loan Amount dengan baik. MAE linear menunjukan nilai terkecil yang mengartikan tingkat kesalahan rata-ratanya yang paling kecil. RMSE menunjukan nilai rata-rata kesalahan prediksi. MAPE rata-rata persentase kesalahan prediksi.

Hasil ini menunjukan bahwa semua model belum mampu memprediksi LoanAmount dengan baik, meski Linear Regression menjadi model dengan performa terbaik berdasarkan sebagian besar metrik evaluasi yang dianalisis karena seluruh nilai R² yang dihasilkan negatif.



Scatter Plot di atas menunjukan hubungan antara YearsExperience dan LoanAmount. Hasilnya menunjukan tren positif yang memprediksi bahwa semakin lama pengalaman bekerja, semakin tinggi pula tingkat jumlah pinjaman yang diajukan. Distribusi titik menyebar yang menunjukan bahwa jumlah pinjaman aktual yang diajukan bervariasi pada lamanya pengalaman kerja pemohon.



Scatter Plot di atas menunjukan hubungan antara Age dan LoanAmount. Hasilnya menunjukan tren negatif yang memprediksi bahwa semakin tinggi usia pemohon maka semakin rendah jumlah pinjaman yang diajukan. Distribusi titik menyebar yang menunjukan bahwa pemohon dengan usia muda atau tua tetap mengajukan pinjaman dengan jumlah yang bervariasi.




Scatter Plot di atas menunjukan hubungan antara CreditScore dan LoanAmount. Hasilnya menunjukan tren positif meskipun tidak signifikan dimana memprediksi pemohon dengan rekam jejak kredit yang baik akan mengajukan jumlah pinjaman yang tinggi. Distribusi titik menyebar yang artinya secara aktual rekam jejak pemohon yang mengajukan pinjaman yang tinggi maupun rendah bervariasi.




Interpretasi Hasil Clustering




Dengan variabel X nya Pendapatan dan variabel Y nya Jumlah Pinjaman, Pada setiap titik di grafik itu menggambarkan 1 data dari nasabah sehingga dapat di katakan posisi ini menunjukkan kombinasi antara pendapatan dengan jumlah pinjaman yang dimiliki.




Warna biru adalah cluster dengan jumlah sampel terbanyak dapat dilihat dari vertikal nya yang lebar, dengan nilai positif (0,013) menunjukkan bahwa ini memiliki karakteristik beban cenderung diatas rata rata atau mengalami kenaikan.




Pada warna merah memiliki jumlah sampel yang lebih moderat (lebih sedikit dari pada biru namun lebih banyak dari pada hijau) dengan bentuk yang konsisten. Warna merah memiliki nilai cluster -0.058, nilai ini adalah nilai yang paling negatif.




Warna hijau ini adalah cluster yang paling kecil, meskipun kecil sebagian besar barisnya masih berada di sisi positif, dan jika ada garis yang mendekati 0 berarti ada kemungkinan mirip dengan cluster lain. Nilai pada cluster hijau adalah -0,016 nilai ini berada di tengah tengah (negatif kecil mendekati 0) ini menunjukkan titik yang paling ideal.



Pada visualisasi ini menampilkan struktur pengelompokan data dalam bentuk dendrogram. Semakin kiri jarak antar dua cluster semakin besar maka artinya tidak semakin mirip. Sementara pada bagian kanan terlihat nilai nilai dari *Loan Amount* yang menjadi dasar pembukaan cluster.



Pada “Elbow Method” ini diharuskan untuk menambah widget baru yaitu “Python Script” dan langsung menghubungkannya ke “Data tabel” yang berhubungan dengan Preprocess. Sumbu X menunjukkan jumlah cluster (k) yang diuji, berkisar dari k = 2 sampai k = 10, sedangkan sumbu Y memperlihatkan nilai inertia WCSS (Within Cluster Sum of Squares), yang merupakan total variasi jarak data terhadap centroid di masing-masing cluster. Semakin rendah nilai WCSS, semakin padat cluster yang dihasilkan.



Sama seperti sebelumnya hubungkan widget “DBSCAN” ke “Data Table” yang terhubung dengan Preprocess. Grafik diatas merupakan k-distance graph. Pada grafik itu tampak ada titik denga nilai 3.24, yang digambarkan dengan garis vertikal dan horizontal.

Kesamaan Temuan Ketiga Analisis

Ketiga analisis ini sama-sama digunakan untuk memahami pola data nasabah agar bisa membantu dalam pengambilan keputusan. Classification digunakan untuk menentukan apakah pinjaman disetujui atau tidak, regression untuk memperkirakan jumlah pinjaman, dan clustering untuk mengelompokkan nasabah berdasarkan kemiripan karakteristiknya.

Dari hasil yang diperoleh, metode classification menunjukkan hasil yang cukup baik dalam memprediksi persetujuan pinjaman. Untuk di regression masih belum optimal karena belum mampu menangkap hubungan antara variabel dengan jumlah pinjaman secara maksimal. Untuk clustering, hasilnya sudah cukup membantu dalam membagi nasabah ke dalam beberapa kelompok dengan karakteristik yang berbeda.

Ketiga metode ini bisa digunakan secara bersama untuk memberikan gambaran yang lebih lengkap tentang kondisi nasabah, sehingga keputusan yang diambil bisa lebih tepat.

Peran Fitur yang Penting Untuk Dianalisis

Fitur yang penting di satu analisis biasanya penting juga di analisis lainnya, walaupun pengaruhnya bisa beda-beda. Pengaruh tersebut berbeda karena semua analisis pakai data yang sama, jadi faktor-faktor utamanya pasti sering muncul. Dari hasil yang didapat, fitur seperti pendapatan, skor kredit, usia, dan pengalaman kerja jadi yang paling berpengaruh. Fitur-fitur ini dipakai untuk menentukan apakah pinjaman disetujui, memperkirakan jumlah pinjaman, sampai mengelompokkan nasabah. Walaupun perannya bisa beda di tiap metode, fitur-fitur ini tetap penting karena membantu kita memahami pola dan kondisi nasabah secara keseluruhan.

Kecenderungan pada Cluster terhadap Kelas atau Target

Hasil clustering tidak langsung menunjukkan target LoanApproved karena bersifat unsupervised, tetapi tetap dapat dikaitkan dengan classification dan regression. Dengan metode K-Means, pemohon terbagi menjadi tiga cluster berdasarkan hubungan Income dan LoanAmount: cluster pertama berisi pemohon dengan pendapatan dan pinjaman tinggi, cluster kedua berisi pemohon dengan kondisi pendapatan dan pinjaman yang bervariasi sehingga risikonya perlu dianalisis lebih lanjut, sedangkan cluster ketiga berisi pemohon dengan pendapatan dan pinjaman rendah hingga menengah yang relatif lebih stabil. Secara keseluruhan, clustering lebih mendukung classification karena membantu melihat perbedaan karakteristik pemohon, sedangkan pada regression hanya menjadi pendukung bahwa LoanAmount tidak mudah diprediksi dari variabel numerik yang tersedia.

Rekomendasi Bisnis

- Gunakan model klasifikasi untuk membantu memprediksi apakah pinjaman layak disetujui atau ditolak.
- Perhatikan indikator utama seperti pendapatan, skor kredit, jumlah pinjaman, pengalaman kerja, usia, dan jenis pekerjaan.
- Tambahkan faktor pendukung seperti tujuan pinjaman, jaminan, aset, dan riwayat pembayaran agar evaluasi lebih akurat.
- Manfaatkan clustering untuk mengelompokkan nasabah menjadi risiko rendah, sedang, dan tinggi.
- Terapkan strategi berbeda untuk tiap kelompok nasabah agar risiko kredit dapat diminimalkan.
- Integrasikan ketiga analisis agar pengambilan keputusan lebih objektif, efisien, dan berbasis data.

KESIMPULAN DAN SARAN

Secara keseluruhan, ketiga metode ini saling melengkapi dalam memberikan gambaran yang komprehensif, sehingga institusi keuangan disarankan untuk mengadopsi model Gradient Boosting sebagai alat bantu keputusan kredit, memanfaatkan segmentasi nasabah untuk merancang strategi pengelolaan risiko yang tepat bagi setiap kelompok, serta melakukan perbaikan kualitas data secara menyeluruh agar hasil analisis ke depan dapat lebih akurat dan dapat diandalkan sebagai dasar pengambilan keputusan berbasis data.

Dataset harus menjalani prosedur pembersihan data (data cleaning) yang komprehensif. Adanya nilai yang tidak masuk akal seperti LoanAmount negatif menandakan kesalahan dalam input atau ketidaksesuaian data. Nilai-nilai semacam ini sebaiknya diperbaiki atau dihapus karena dapat mempengaruhi hasil analisis, terutama pada metode yang berbasis jarak seperti pengelompokan.

Thank
You

Establish a Clear Structure





Organize your content with a logical hierarchy to guide both visitors and search engines effectively.



Use internal links to demonstrate relationships between pages and create a seamless navigation experience.





Use Descriptive Anchor Text



Anchor text should be descriptive and related to the content being linked. Avoid generic terms like "click here" to improve keyword relevance and guide users to the right content.



Distribute Link Equity



Internal links help distribute link equity throughout your site, enhancing overall SEO effectiveness.



By linking to high-priority pages, you can pass on ranking power, boosting the visibility of those important pages.




Increase Crawlability



Link to important pages from other areas of your site to ensure efficient crawling by search engines.



This strategy helps guarantee that all key content is indexed and accessible by search engines.





Avoid Overlinking

- Don't overwhelm your content with too many internal links. Keep them natural and relevant to avoid confusing users and potentially lowering the quality of your content.



Update Old Content



Revise older content by adding links to new pages to improve SEO and keep your content fresh.




Guide users to the most up-to-date information by incorporating links to recent pages.





thank you so much



+123 456 7890



www.reallygreatsite.com















123 Anywhere St., Any City



www.reallygreatsite.com

Resource page



Resource page

