

EMPLOYEE HR ANALYTICS

Analisis Prediktif & Segmentasi Karyawan Menggunakan
Classification, Regression dan Clustering

Dipresentasikan oleh **Kelompok 3**

Raditya Budi Prabowo	2310112053
Meivita Dwi Ningsih	2310112079
Nisrina Audy Fakhira	2310112165

01 | EDA & Data Preparation

EDA

Berdasarkan hasil eksplorasi data, hubungan antar variabel tidak sepenuhnya linear dan cenderung kompleks. Jam kerja yang tinggi tidak selalu meningkatkan kepuasan, begitu juga dengan evaluasi kinerja yang tinggi yang tidak selalu mencerminkan tingkat kepuasan karyawan. Selain itu, faktor seperti gaji dan promosi menunjukkan pengaruh yang lebih jelas terhadap kepuasan. Hal ini menunjukkan bahwa kondisi karyawan dipengaruhi oleh berbagai faktor yang saling berinteraksi.

01 | EDA & Data Preparation

Data Preparation

14.999

Total Karyawan

11

Variabel

Tahap persiapan data dilakukan dengan memilih variabel yang relevan, dimana `satisfaction_level` digunakan sebagai target regresi dan variabel lainnya sebagai fitur. Proses evaluasi model menggunakan metode cross validation untuk menghasilkan hasil yang lebih stabil, serta dilakukan normalisasi data agar seluruh variabel berada pada skala yang sama sehingga tidak menimbulkan bias dalam proses analisis.

02 | Analisis Classification

Algoritma yang Digunakan

Decision Tree

Model dasar, mudah diinterpretasi

Gradient Boosting

Ensemble, performa terbaik

Naive Bayes

Berbasis Probabilitas

Random Forest

Ensemble, performa terbaik

KNN

Berbasis Jarak

Analisis klasifikasi dilakukan untuk memprediksi kemungkinan karyawan keluar menggunakan beberapa model machine learning. Hasil menunjukkan bahwa model berbasis ensemble seperti Random Forest dan Gradient Boosting memiliki performa terbaik dengan nilai akurasi dan AUC yang tinggi. Confusion matrix juga menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar, meskipun masih terdapat kesalahan prediksi akibat pola data yang kompleks. Secara keseluruhan, model ensemble lebih efektif dibandingkan model tunggal dalam menangani data yang tidak linear.

03 | Analisis Regression

Performa Model

Linear Regression

Tidak optimal, hubungan antar variabel tidak linear

Decision Tree

Cukup baik menangkap pola, namun masih di bawah ensemble

Random Forest

Performa terbaik, nilai error lebih rendah, stabil

Gradient Boosting

Performa terbaik, nilai error lebih rendah, stabil

Pada analisis regresi, model Random Forest dan Gradient Boosting menunjukkan performa terbaik dengan nilai error yang lebih rendah dibandingkan model lainnya. Hal ini menunjukkan bahwa hubungan antar variabel tidak sepenuhnya linear, sehingga model non-linear lebih mampu menangkap pola dalam data. Selain itu, hasil visualisasi menunjukkan adanya hubungan positif antara nilai aktual dan prediksi, meskipun masih terdapat penyebaran data yang menunjukkan bahwa model belum sepenuhnya sempurna.

04 | Analisis Clustering

Segmentasi karyawan tanpa label target menggunakan 3 algoritma

K-Means

K = 4

Silhouette = 0,201

Cluster optimal ditentukan dari Silhouette Score tertinggi.

Menghasilkan 4 segmen karyawan yang distingtif.

Hierarchical Clustering

Top N = 3

Silhouette = 0,174

Dendrogram menunjukkan pemisahan hierarkis yang jelas.

Menghasilkan 3 cluster yang konsisten dengan K-Means.

DBSCAN

eps = 1,28

MinPts = 4

Menghasilkan 2 cluster utama + noise. Berguna untuk deteksi karyawan dengan profil atipikal (outlier).

K - Means Clustering

C1 - Senior Berprestasi

(n=571)

Risiko: RENDAH

- Masa kerja paling lama
- Kepuasan & evaluasi tinggi
- Beban kerja sedang

C2 - Overworked & Frustrated

(n=490)

Risiko: SANGAT TINGGI

- Kepuasan sangat rendah (-1,823)
- Beban kerja & proyek tinggi
- Evaluasi tinggi (burnout)

C3 - Karyawan Normal

(n=2.425)

Risiko: RENDAH

- Semua fitur mendekati rata - rata
- Kelompok terbesar & paling stabil
- Masa kerja relatif muda

C4 - Underperformer Pasif

(n=1.014)

Risiko: SEDANG

- Evaluasi sangat rendah (-1,042)
- Beban kerja ringan, kepuasan rendah
- Disengaged (perlu coaching)

05 | Sintesis Terintegrasi

Dimensi	Classification (Bab 4)	Regression (Bab 5)	Clustering (Bab 6)
Target Analisis	Variabel left (keluar/tidak)	Variabel satisfaction_level (tingkat kepuasan)	Tanpa label target (segmentasi profil)
Model Terbaik	Random Forest & Gradient Boosting	Random Forest & Gradient Boosting	K-Means (K=4) Silhouette = 0,201
Variabel Kunci	number_project, average_monthly_hours, last_evaluation, time_spend_company	number_project, average_monthly_hours, time_spend_company	satisfaction_level, number_project, time_spend_company
Temuan Utama	Karyawan overworked dengan evaluasi tinggi paling rentan keluar	Kepuasan tidak linear terhadap beban kerja, $R^2 = 0,45$, korelasi prediksi ~0,6	C2 (Overworked & Frustrated) = kelompok paling kritis
Pola Hubungan	Non-linear; ensemble lebih unggul dari model tunggal	Non-linear, ensemble lebih unggul dari regresi linear	Tumpang tindih moderat, pola berbasis kepadatan data

Variabel Konsisten Lintas Analisis: number_project · average_monthly_hours · last_evaluation · time_spend_company
Konsistensi ini bukan kebetulan, keempat variabel ini adalah prediktor utama kondisi SDM perusahaan.

06 | Keterkaitan antar Analisis & Rekomendasi Bisnis

Keterkaitan antar Analisis - Kepuasan (Terkonfirmasi di 3 Analisis)

Karyawan dengan evaluasi tertinggi dan beban kerja terberat justru memiliki kepuasan terendah dan risiko keluar tertinggi. Ketiga analisis secara konsisten mengkonfirmasi hal ini.

01

Intervensi Prioritas (C2)

Redistribusi beban kerja, program apresiasi berbasis kinerja, dan dialog terbuka dengan karyawan overworked sebelum mereka memutuskan keluar.

02

Menahan Karyawan Senior (C1)

Sediakan tantangan baru, program mentorship, atau rotasi peran untuk mencegah kebosanan pada karyawan senior yang saat ini masih loyal.

03

Sistem Pemantauan Dini

Mengembangkan early warning system berbasis profil cluster, tandai karyawan yang bergeser menuju profil C2 untuk intervensi lebih awal.

04

Tinjau Sistem Evaluasi Kinerja

Evaluasi kinerja tinggi $\neq$ kepuasan tinggi. Pastikan kompensasi dan pengakuan sepadan dengan kontribusi karyawan berprestasi.

07 | Kesimpulan dan Saran

Analisis terhadap 14.999 data karyawan menunjukkan bahwa model terbaik untuk memprediksi karyawan keluar adalah Random Forest dan Gradient Boosting, dengan faktor utama seperti jumlah proyek, jam kerja, evaluasi, dan lama bekerja. Hubungan antara beban kerja dan kepuasan karyawan bersifat kompleks dan tidak linear, sementara clustering mengungkap adanya kelompok karyawan overworked namun tidak puas. Secara keseluruhan, kepuasan karyawan menjadi faktor kunci yang menghubungkan seluruh analisis.

Saran

- Menjadikan Cluster 2 (Overworked & Frustrated) sebagai prioritas intervensi pertama.
- Mengembangkan program retensi khusus untuk Cluster 1 (Senior Berprestasi).
- Menerapkan program coaching dan peningkatan keterlibatan untuk Cluster 4 (Underperformer Pasif).
- Membangun sistem pemantauan dini (early warning system) berbasis profil karyawan.
- Meninjau dan menyelaraskan sistem evaluasi kinerja dengan sistem penghargaan.

BIG DATA ANALYTICS

TERIMA KASIH

Kelompok 3 - Employee HR Analytics