

UTS ANALISIS BIG DATA

LAPORAN PROJECT BIG DATA ANALYTIC
CUSTOMER SEGMENTATION
& PURCHASE BEHAVIOR

DISUSUN OLEH:

Muhamad Furqon Al Farisy

Samuel Bonardo Simangunsong

Nurjanatul Fitriah

2310112021

2310112069

2310112229

DOSEN PENGAMPU:

Dr. Donny Maha Putra

PENDAHULUAN

LATAR BELAKANG

Perkembangan perekonomian dan kemajuan teknologi digital yang semakin pesat mendorong perusahaan untuk dapat beradaptasi secara cepat dalam menghadapi lingkungan bisnis yang dinamis. Di tengah kondisi tersebut, **pelanggan tidak lagi dipandang sebagai kelompok yang sama, terlihat dari setiap individu memiliki karakteristik, preferensi, dan pola perilaku yang berbeda-beda.** Selain itu, **perkembangan teknologi juga menyebabkan meningkatnya volume data yang dihasilkan dari aktivitas pelanggan.** Data seperti riwayat pembelian, jumlah transaksi, dan preferensi produk sebenarnya menyimpan informasi yang sangat berharga apabila dapat diolah dengan baik. Salah satu **pendekatan yang dapat digunakan adalah analisis berbasis data mining** yang memungkinkan data untuk dianalisis dari berbagai sudut pandang. Dengan cara ini, perusahaan dapat memahami pola-pola tertentu yang sebelumnya tidak terlihat dan dapat mengetahui perilaku pelanggan secara lebih jelas.

PENDAHULUAN

LATAR BELAKANG

Perkembangan perekonomian dan kemajuan teknologi digital yang semakin pesat mendorong perusahaan untuk dapat beradaptasi secara cepat dalam menghadapi lingkungan bisnis yang dinamis. Di tengah kondisi tersebut, **pelanggan tidak lagi dipandang sebagai kelompok yang sama, terlihat dari setiap individu memiliki karakteristik, preferensi, dan pola perilaku yang berbeda-beda.** Selain itu, **perkembangan teknologi juga menyebabkan meningkatnya volume data yang dihasilkan dari aktivitas pelanggan.** Data seperti riwayat pembelian, jumlah transaksi, dan preferensi produk sebenarnya menyimpan informasi yang sangat berharga apabila dapat diolah dengan baik. Salah satu **pendekatan yang dapat digunakan adalah analisis berbasis data mining** yang memungkinkan data untuk dianalisis dari berbagai sudut pandang. Dengan cara ini, perusahaan dapat memahami pola-pola tertentu yang sebelumnya tidak terlihat dan dapat mengetahui perilaku pelanggan secara lebih jelas.

Identifikasi Masalah

1. Data pelanggan yang tersedia belum dimanfaatkan secara optimal untuk menghasilkan insight yang mendukung pengambilan keputusan.
2. Perusahaan kesulitan dalam mengelompokkan pelanggan berdasarkan karakteristik dan perilaku yang berbeda.
3. Belum diketahui secara pasti faktor-faktor yang mempengaruhi tingkat pengeluaran pelanggan.
4. Kurangnya pemahaman mengenai segmentasi pelanggan yang dapat digunakan sebagai dasar strategi pemasaran yang lebih efektif.

Rumusan Masalah

1. Bagaimana mengklasifikasikan pelanggan berdasarkan karakteristik dan perilaku yang dimiliki menggunakan metode classification?
2. Bagaimana pengaruh variabel demografis dan perilaku pelanggan terhadap nilai pengeluaran pelanggan menggunakan metode regression?
3. Bagaimana segmentasi pelanggan dapat terbentuk berdasarkan karakteristik yang dimiliki menggunakan metode clustering?

TINJAUAN TEORI

Big Data Analytics

Big data analytics adalah proses pengumpulan, pengelolaan, pemrosesan dan analisis data dalam jumlah besar, termasuk data terstruktur dan tidak terstruktur, untuk mengidentifikasi pola, tren, dan informasi yang relevan.

Di dunia bisnis big data analytics berfungsi menjadi kunci penggerak yaitu mencakup berbagai aspek yang dapat membantu organisasi mencapai keberhasilan dan keunggulan kompetitif.

Dengan analisis data yang cermat, organisasi dapat membuat keputusan strategi yang lebih akurat

Machine Learning

Machine Learning adalah suatu mesin yang dikembangkan untuk bisa belajar dengan tanpa arahan dari penggunanya. pembelajaran mesin dikembangkan berdasarkan disiplin ilmu seperti statistika, matematika, dan data mining.

Istilah Machine learning diperkenalkan pertama kali oleh beberapa ilmuwan matematika seperti Adrien Marie Legendre, Thomas Bayes dan Andrey Markov pada sekitar tahun 1920-an.

Penerapan machine learning membawa perubahan yang signifikan dalam berbagai industri, membantu meningkatkan efisiensi, kecepatan, dan akurasi dalam pengambilan keputusan.

Classification

Classification adalah proses data yang sudah memiliki label atau kategori tertentu, dan kita ingin memprediksi kategori dari data baru berdasarkan pola yang sudah ada.

Jenis jenis algoritma classification yang populer antara lain ada Naive Bayes, KNN, TREE, RANDOM FOREST, ADABOOST.

Classification termasuk dalam kategori supervised learning. karena sudah ada label atau kategori yang digunakan untuk melatih model, data baru bisa diklasifikasikan sesuai pola yang ditemukan dari data lama

TINJAUAN TEORI

Regression

Regression adalah metode analisis yang digunakan untuk memahami hubungan antara dua variabel atau lebih. Tujuannya adalah untuk memprediksi nilai dari variabel dependen berdasarkan nilai dari variabel independen.

Dalam konteks data science, analisis regression adalah metode yang digunakan untuk menganalisa dan memprediksi tren atau pola dalam data. misalnya dilihat dari e-commerce analisis dapat membantu memprediksi penjualan berdasarkan faktor tertentu, bisa berupa harga atau preferensi konsumen.

Clustering

Clustering adalah proses mengelompokkan data tanpa adanya label tertentu. Dalam konteks bisnis, clustering dapat diterapkan untuk mengelompokkan pelanggan berdasarkan perilaku pembelian mereka tanpa label yang telah ditentukan sebelumnya.

Misal seorang manajer pemasaran yang ingin mengelompokkan pelanggan berdasarkan faktor usia, pendapatan, rata rata pengeluaran, dan frekuensi pembelian. Jenis jenis algoritma clustering yang populer yaitu K-Means, dan Hierarchical C

METODE

Penelitian ini menggunakan pendekatan kuantitatif dengan metode data mining untuk menganalisis data pelanggan.


Proses pencarian data dilakukan dengan mencari data di kaggle dengan kata kunci sesuai dengan tema dataset.

Data yang digunakan bersumber dari kaggle dengan tema dataset yaitu customer segmentation and purchase behavior yang memuat informasi demografis dan perilaku pembelian pelanggan.

Dilakukan pemilihan dari total 6 dataset dan dipilih dataset yang sesuai dengan syarat kelayakan 3 analisis classification, regression, dan clustering

EDA & Data Preparation

- Id: Identifikasi unik untuk setiap pelanggan.
- Age: Usia pelanggan.
- Gender: Jenis kelamin pelanggan (Laki-laki, Perempuan, Lainnya).
- Income: Pendapatan tahunan pelanggan (dalam USD).
- Spending_score: Skor pengeluaran (1-100), menunjukkan perilaku pengeluaran dan loyalitas pelanggan.
- Membership_years: Jumlah tahun pelanggan telah menjadi anggota. purchase_frequency: Jumlah pembelian yang dilakukan pelanggan dalam setahun terakhir.
- Preferred_category: Kategori belanja yang disukai (Elektronik, Pakaian, Bahan Makanan, Rumah & Taman, Olahraga).
- Last_purchase_amount: Jumlah yang dibelanjakan pelanggan pada pembelian terakhir mereka (dalam USD).



Lisensi data: CC0: Public Domain

ANALISIS CLASIFFICATION

Langkah 1: Mempersiapkan Dataset

Langkah 2: Load Dataset

Langkah 3: Masukkan Data CSV yang Sudah Didownload

Langkah 4: Membuat Target Klasifikasi

Langkah 5: Pemilihan Fitur Target

langkah 6: Transformasi Data Categorical

Langkah 7: Preprocessing

Langkah 8: Penerapan Algoritma Klasifikasi

Langkah 9: Mengevaluasi performa model

Langkah 10: Analisis Confusion Matrix

Langkah 11: Visualisasi Model

Langkah 12: Melihat Hasil Prediksi


HASIL ANALISIS

TEST & SCORE

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
kNN (3)	0.520	0.360	0.357	0.356	0.360	0.025
Naive Bayes (3)	0.469	0.331	0.300	0.310	0.331	-0.054
Tree (3)	0.488	0.323	0.321	0.320	0.323	-0.030
Random Forest (3)	0.485	0.344	0.329	0.326	0.344	-0.013
AdaBoost (3)	0.490	0.325	0.325	0.326	0.325	-0.020

TREE VIEWER



HASIL ANALISIS

NAIVE BAYES

Actual	Predicted			Σ
	< 40	40 - 70	≥ 70	
	< 40	227	46	119
	40 - 70	172	29	79
	≥ 70	222	31	75
Σ	621	106	273	1000

RANDOM FOREST

Actual	Predicted			Σ
	< 40	40 - 70	≥ 70	
	< 40	204	74	114
	40 - 70	155	42	83
	≥ 70	157	73	98
Σ	516	189	295	1000

KNN

Actual	Predicted			Σ
	< 40	40 - 70	≥ 70	
	< 40	170	94	128
	40 - 70	117	71	92
	≥ 70	133	76	119
Σ	420	241	339	1000

TREE

Actual	Predicted			Σ
	< 40	40 - 70	≥ 70	
	< 40	157	109	126
	40 - 70	129	66	85
	≥ 70	140	88	100
Σ	426	263	311	1000

ADABOOST

Actual	Predicted			Σ
	< 40	40 - 70	≥ 70	
	< 40	138	121	133
	40 - 70	105	74	101
	≥ 70	126	89	113
Σ	369	284	347	1000

Analisis Regresi

Tahapan Analisis

Input Dataset

**Menentukan Variable
Feature dan Target**

Preprocessing Data


Penerapan Widget Algoritma

Hasil Pengujian Test And Score

Hasil Visual Model


Hasil Analisis Regresi

Scatter Plot



3 Variabel Berpengaruh

1	N	spending_score		NA	0.194
2	N	membership_years		NA	0.193
3	N	last_purchase_amount		NA	0.200
4	N	age		NA	0.197
5	C	preferred_category	5	NA	0.162
6	N	income		NA	0.184
7	C	gender	3	NA	0.070



Bagan Tree Viewer

K-Means Clustering

1. **Penentuan jumlah cluster (k) optimal** Hubungkan widget preprocess dengan widget K-Means (Preprocess data → Data). Penentuan jumlah cluster optimal dilakukan menggunakan Elbow Method. Pada nilai Silhouette Score struktur data paling stabil berada pada $k = 7$ dengan skor tertinggi sebesar 0.136.
2. **Validasi *Silhouette Plot*** validasi menggunakan Silhouette Plot (Hubungkan widget K-Means dengan widget silhouette plot). Jarak yang digunakan secara standar dalam perhitungan ini adalah Euclidean distance.

Cluster 7 (C7) = Skor Silhouette: 0.164 menunjukkan kualitas pengelompokan terbaik dibanding cluster lainnya.

3. **Visualisasi Clustering** Scatter Plot (Hubungkan widget silhouette plot dengan widget scatter plot) dan Bar Plot Hubungkan widget silhouette plot dengan widget bar plot

Interpretasi persona tiap cluster:

- **C1 Pelanggan Lama dengan Belanja Rendah**
- **C2 Pelanggan Tidak Aktif**
- **C3 Pelanggan Muda dengan Daya Beli Rendah**
- **C4 Pelanggan Baru dengan Pengeluaran Tinggi**
- **C5 Pelanggan Rata-rata**
- **C6 Pelanggan Stabil dan Aktif**
- **C7 Pelanggan Loyal Utama**

Hierarchical Clustering

1. **Perhitungan jarak matriks (Distances)** Hubungkan widget preprocess dengan widget Distances (Preprocess data → Data). Distance metric yang digunakan adalah Euclidean Distance
2. **Pembentukan Struktur Pohon (Hierarchical Clustering)** Data yang sudah dihitung jaraknya kemudian diteruskan ke widget Hierarchical Clustering dan dapat terlihat visualisasi pohon yang disebut Dendrogram. Pada Linkage dipilih Ward's Method dan pada Top N dipilih 7 cluster dengan menyesuaikan K = 7 di K-Means.

3. **Validasi Karakteristik** Scatter Plot Hubungkan widget Hierarchical Clustering dengan widget scatter plot dan Bar Plot Hubungkan widget Hierarchical Clustering dengan widget bar plot.

Interpretasi persona tiap cluster:

- **C1 Pelanggan Lama dengan Pola Belanja Tidak Konsisten**
- **C2 Pelanggan Pasif dengan Nilai Transaksi Rendah**
- **C3 Pelanggan dengan Daya Beli Rendah dan Aktivitas Terbatas**
- **C4 Pelanggan Potensial Berkembang**
- **C5 Pelanggan Cukup Aktif dengan Pola Belanja Menengah**
- **C6 Pelanggan Aktif dengan Intensitas Belanja Tinggi**
- **C7 Pelanggan Bernilai Tinggi dan Loyal**

Kesamaan temuan antara Classification, Regression, dan Clustering

Ketiga metode analisis menunjukkan hasil yang konsisten, ditemukan adanya kesamaan temuan yang menunjukkan bahwa struktur hubungan antar variabel dalam dataset relatif lemah.

Apakah fitur penting di satu analisis juga penting di analisis lain?

Terdapat beberapa variabel yang umumnya lebih sering muncul sebagai variabel penting jika dibandingkan dengan yang lain, yaitu membership_years, last_purchase_amount, dan income.

Apakah cluster yang terbentuk memiliki kecenderungan kelas atau target tertentu?

Hasil analisis clustering menunjukkan bahwa setiap cluster memiliki karakteristik yang berbeda, sehingga memungkinkan untuk diidentifikasi terhadap kelas tertentu dalam analisis classification atau terhadap nilai target dalam regression.

Rekomendasi bisnis yang muncul dari sintesis ketiga analisis

Pendekatan yang paling direkomendasikan untuk diterapkan dalam strategi bisnis adalah berbasis kepada segmentasi pelanggan. Hal ini dikarenakan metode clustering, meskipun tidak signifikan tetapi masih mampu memberikan gambaran mengenai pengelompokan pelanggan berdasarkan karakteristik yang dimiliki.