

Laporan Analisis Medical Insurance Cost Menggunakan Orange Data Mining

KLP05 - Kelas A

- Retha Varelie (2310112073)
- Fauziah Rabi'ah Jamin (2310112089)
- W Salsa Fitriana Ichwan (2310112143)
- Kayla Zahratun Nisa (2310112163)

UTS Big Data Analytics

Latar Belakang dan Tujuan

Latar Belakang

Industri asuransi kesehatan merupakan salah satu sektor yang bergantung pada akurasi analisis data agar bisa digunakan dalam menentukan kebijakan penetapan harga premi yang tepat. Perusahaan asuransi harus mampu memetakan profil risiko nasabah agar bisa menjaga stabilitas arus kas dan memenuhi liabilitas klaim di masa mendatang.

Tujuan Analisis

Berdasarkan latar belakang tersebut, disusun tujuan analisis sebagai berikut:

- **Classification:** Untuk mengetahui manakah di antara algoritma kNN (k-Nearest Neighbor), Random Forest, AdaBoost, Decision Tree, dan Naive Bayes yang dapat memberikan analisis prediksi paling akurat mengenai status merokok nasabah berdasarkan metrik evaluasi yang ditentukan.
- **Regression:** Untuk mengetahui bagaimana pengaruh variabel independen (usia, BMI, jumlah anak, wilayah tinggal, dan gaya hidup) terhadap estimasi biaya asuransi nasabah dan algoritma mana yang bisa meminimalkan tingkat kesalahan prediksi.
- **Clustering:** Untuk mengetahui bagaimana karakteristik pengelompokkan nasabah dengan fitur-fitur numerik dan bagaimana interpretasi persona dari tiap cluster tersebut dalam membantu perumusan strategi bisnis perusahaan.

Landasan Teori

Asuransi kesehatan dan peran krusial prediksi biaya dalam industri tersebut. Asuransi kesehatan berfungsi sebagai pelindung finansial dari risiko medis yang tak terduga, di mana akurasi prediksi biaya klaim menjadi kunci bagi perusahaan asuransi untuk menentukan tarif premi yang kompetitif dan mengelola risiko portofolio peserta secara efektif. Penggunaan teknologi Machine Learning (ML) hadir sebagai solusi modern yang memungkinkan sistem belajar secara otomatis dari data historis untuk memprediksi nilai di masa depan dengan tingkat akurasi yang tinggi, melampaui metode statistik konvensional.

Dalam implementasinya, penelitian ini menggunakan tiga pendekatan utama Machine Learning.

1. Analisis klasifikasi digunakan untuk memprediksi label kategori, seperti menentukan status perokok atau non-perokok, menggunakan algoritma seperti KNN, Decision Tree, dan Random Forest.
2. Analisis regresi diterapkan untuk memprediksi variabel numerik kontinu, khususnya besar biaya medis (charges), dengan membandingkan model Linear Regression dan Random Forest Regression.
3. Analisis klasterisasi (clustering) melalui metode K-Means dan Hierarchical Clustering dilakukan untuk mengelompokkan nasabah berdasarkan kemiripan karakteristik tanpa adanya label target.

Metode Penelitian

Metode yang digunakan dalam laporan “Medical Insurance Cost” menggunakan pendekatan Data Mining dengan bantuan Orange Data Mining. Penelitian ini menerapkan tiga pendekatan analisis, yaitu klasifikasi (Classification), regresi (Regression), dan pengelompokkan (Clustering).

Deskripsi Dataset

Dataset ini berisi informasi nasabah asuransi kesehatan di AS. Jumlah datanya berisi 1.338 baris dan 7 kolom. Serta tidak ada missing value. Variabel-variabel yang ada pada dataset:

- Age: usia nasabah
- Sex: jenis kelamin
- Bmi: indeks massa tubuh
- Children: jumlah anak yang ditanggung asuransi
- Smoker: status perokok
- Region: wilayah tinggal di AS
- Charges: biaya asuransi

Hasil EDA

- Rata rata: usia 39,2 tahun | BMI 30,66 | Anak 1,09 | Charges 13.270
- Smoker: 79,5% tidak merokok | 20,5% merokok
- Charges: sebaran miring ke kanan

Penyesuaian data

- Missing value: tidak ada, data bersih
- One-hot encoding: sex & region diubah jadi 0/1 (karena tidak berurutan)
- Min-Max scaling: semua kolom numerik jadi rentang 0-1 (mencegah charges dominasi)

Classification


Analisis ini dilakukan dengan menetapkan variabel **smoker** sebagai target karena dalam industri asuransi hal ini menjadi variabel yang harus diperhatikan. Kemudian dataset dihubungkan ke lima algoritma yang berbeda, yaitu K-Nearest Neighbor (kNN), Decision Tree, AdaBoost, Random Forest, dan Naive Bayes agar bisa membandingkan performa masing-masing model

Hasil Test and Score dengan metode 10-folds-Cross validation menunjukkan:

- **Random Forest** memiliki kemampuan diskriminasi yang paling unggul di antara algoritma lain, dengan skor AUC **0.979**, yang berarti algoritma Random Forest ini bisa membedakan nasabah perokok dan non perokok dengan sangat baik.
- Apabila fokus penilaian pada ketepatan prediksi secara keseluruhan (Classification Accuracy) dan keseimbangan antara presisi (Precision) serta daya tangkap model (F1-Score), algoritma **AdaBoost** menjadi yang terunggul dengan skor konsisten di angka **0,960**.

Keunggulan **Random Forest** dalam membedakan antara nasabah perokok dan non perokok juga dapat dilihat dalam grafik ROC di situ terlihat bahwa kurva Random Forest, yang digambarkan dengan garis pink, merupakan kurva yang paling dekat dengan sudut kiri atas grafik.

Evaluation results for target (None, show average over classes) ▾						
Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.935	0.918	0.913	0.917	0.918	0.732
AdaBoost	0.930	0.960	0.960	0.960	0.960	0.876
Tree	0.891	0.948	0.947	0.947	0.948	0.836
Random Forest	0.979	0.948	0.948	0.948	0.948	0.840
Naive Bayes	0.959	0.938	0.940	0.945	0.938	0.825



Classification

Berdasarkan hasil Confusion Matrix dapat disimpulkan bahwa:

- **Naive Bayes** ternyata memiliki daya tangkap yang tinggi terhadap nasabah perokok, dengan tingkat keberhasilan **93,9%**.
- Sedangkan **kNN** dan **AdaBoost** dapat meminimalkan salah tuduh terhadap nasabah karena model ini mampu mengidentifikasi nasabah non-perokok dengan ketepatan sebesar **98,1%**.
- Algoritma **kNN** menunjukkan performa yang paling buruk karena kegagalan dalam mendeteksi nasabah perokok mencapai sebesar **32,9%**. Sebaliknya, algoritma seperti Naive Bayes berhasil menekan tingkat kesalahan tersebut dengan hanya **6,1%** nasabah perokok yang gagal dideteksi.
- **AdaBoost** menawarkan solusi yang lebih seimbang karena meskipun kegagalan dalam mengidentifikasi perokok lebih tinggi dibanding Naive Bayes, tapi kemampuan AdaBoost dalam menekan kesalahan identifikasi hanya **1,9%** sehingga sangat krusial untuk menjaga loyalitas nasabah dan daya saing perusahaan di tengah pasar.

Hasil Confusion Matrix

		Predicted		Σ
		no	yes	
Actual	no	93.8 %	6.2 %	320
	yes	6.1 %	93.9 %	82
Σ		305	97	402

		Predicted		Σ
		no	yes	
Actual	no	96.6 %	3.4 %	320
	yes	12.2 %	87.8 %	82
Σ		319	83	402


		Predicted		Σ
		no	yes	
Actual	no	97.5 %	2.5 %	320
	yes	15.9 %	84.1 %	82
Σ		325	77	402

		Predicted		Σ
		no	yes	
Actual	no	98.1 %	1.9 %	320
	yes	12.2 %	87.8 %	82
Σ		324	78	402

		Predicted		Σ
		no	yes	
Actual	no	98.1 %	1.9 %	320
	yes	32.9 %	67.1 %	82
Σ		341	61	402

Regression

Analisis Regresi dilakukan untuk memprediksi nilai numerik estimasi biaya asuransi (charges) nasabah menggunakan pendekatan yang terstruktur di platform Orange Data Mining. Berdasarkan hasil evaluasi melalui metode 10-folds Cross Validation, algoritma Gradient Boosting terbukti sebagai model paling optimal karena memiliki nilai R-Square tertinggi dan RMSE terendah dibandingkan model lainnya.



Test and Score - Orange

Cross validation

Number of folds: 10

☒ Stratified

Cross validation by feature

Random sampling

Repeat train/test: 10

Training set size: 5 %

☒ Stratified

Leave one out

Test on train data

Test on test data

Model	RMSE	MAE	MAPE	R2
Tree	5650...	284...	30.111	0.782
Gradient Boosting	4551...	249...	28.257	0.859
Random Forest	4684...	259...	29.533	0.850
Linear Regression	6084...	420...	42.383	0.747

Compare models by: Coefficient of determination

Negligible diff.: 0.1

	Tree	Gradient Boosting	Random Forest	Linear Regression
Tree		0.000	0.001	0.932
Gradient Boosting	1.000		0.927	1.000
Random Forest	0.999	0.073		1.000
Linear Regression	0.068	0.000	0.000	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Stratification is ignored for regression

Melalui visualisasi Scatter Plot, ditemukan bahwa sebaran data cenderung membentuk tiga jalur kelompok linear yang berbeda, yang mengindikasikan adanya pengaruh kuat dari variabel kategorikal tertentu. Hasil secara konsisten mengidentifikasi tiga variabel utama yang paling signifikan mempengaruhi besaran biaya, yaitu status merokok sebagai faktor pembeda paling dominan, diikuti oleh BMI yang berdampak besar saat berinteraksi dengan status merokok, serta faktor usia yang memberikan pengaruh linear stabil terhadap peningkatan risiko kesehatan.

Clustering


Tujuan: Mengelompokkan nasabah berdasarkan kemiripan karakteristik.

Penentuan Jumlah Cluster Optimal

- Metode Silhoutte Plot → Nilai tertinggi pada $K = 3$ (skor 0,55).
- $K = 2$ (0,51) | $K = 4$ dan seterusnya lebih rendah

Hasil K-Means (3 cluster)

Cluster	Jumlah Nasabah	Persentase
Cluster 1	468	35%
Cluster 2	336	25,1 %
Cluster 3	534	39,9%



- **Hierarchical Clustering** → Dendrogram (metode Ward) mengkonfirmasi 3 cluster stabil.
- **DBSCAN** → 47,6% data terdeteksi noise, kurang cocok untuk segmentasi semua nasabah.

3 cluster optimal untuk segmentasi nasabah asuransi kesehatan

Sintesis Terintegrasi

Kesamaan temuan penting

- Dari ketiga analisis, biaya asuransi (charges) muncul sebagai indikator yang paling menonjol dalam membaca risiko nasabah.
- Selain itu, status merokok juga terlihat penting karena berkaitan dengan kemungkinan biaya yang lebih tinggi.
- Sementara itu, variabel demografis seperti usia, BMI, dan jumlah anak belum cukup kuat untuk menjelaskan perbedaan biaya secara penuh.

Hubungan Cluster dengan Hasil Classification dan Regression

- Di classification, pola yang berkaitan dengan smoker dan charges membantu membedakan nasabah berisiko lebih tinggi.
- Di regression, target utamanya memang charges, tetapi hasil R^2 yang hanya 0,115 menunjukkan bahwa variabel yang dipakai belum cukup kuat menjelaskan biaya asuransi secara baik.
- Cluster 1 punya rata-rata charges paling tinggi ($\pm$ Rp32.050), sehingga cenderung merepresentasikan kelompok nasabah dengan risiko lebih tinggi dan kemungkinan lebih dekat dengan kelas smoker pada classification.
- Cluster 2 dan Cluster 3 punya rata-rata charges lebih rendah ($\pm$ Rp8.762 dan $\pm$ Rp8.087), sehingga lebih dekat ke kelompok risiko biaya rendah.

Sintesis Terintegrasi

Alur keputusan bisnis (Classification → Regression → Clustering)

- Classification: memverifikasi risiko perilaku nasabah, terutama status merokok.
- Regression: memperkirakan biaya asuransi, meskipun hasilnya masih terbatas karena R^2 rendah.
- Clustering: membagi nasabah ke kelompok risiko, sehingga strategi bisa lebih tepat sasaran

Implikasi utama

- Praktis: membantu mengecek apakah data nasabah, terutama status merokok, sudah sesuai.
- Bisnis: Cluster 1 perlu perhatian lebih karena biaya rata-ratanya tertinggi; Cluster 2 dan 3 bisa diarahkan ke program loyalitas.
- Akuntansi: membantu memperkirakan cadangan klaim dan mengelola risiko keuangan dengan lebih hati-hati.

Kesimpulan & Saran

Kesimpulan Hasil Analisis

- Classification: Random Forest unggul dengan AUC 0,979, sedangkan AdaBoost stabil di 0,960.
- Regression: Linear Regression memiliki error terendah, tetapi R^2 0,115, jadi prediksi biaya masih terbatas.
- Clustering: terbentuk 3 cluster; Cluster 1 punya biaya tertinggi Rp32.050, sedangkan Cluster 2 dan 3 lebih rendah.

Ketiga analisis saling melengkapi untuk membaca risiko nasabah, menentukan premi, dan menyusun strategi bisnis.

Saran

- Menggunakan data mining secara terintegrasi untuk menilai risiko nasabah.
- Tambahkan variabel lain seperti riwayat penyakit, riwayat klaim, pekerjaan, pendapatan, dan gaya hidup.
- Cluster 1 perlu pengawasan lebih, sedangkan Cluster 2 dan 3 bisa diarahkan ke program loyalitas atau kampanye hidup sehat.
- Hasil analisis sebaiknya jadi dasar awal keputusan, tetap dikombinasikan dengan pertimbangan bisnis dan kebijakan perusahaan.



TERIMAKASIH!