

REAL ESSTATE & PROPERTY VALUATION

Anggota Kelompok 6

Derul Mauludin

2310112029

Nabil Maulana

2310112023

Bagas Rae Supriya Hardianto

2310112041

Latar Belakang

Transformasi praktik akuntansi manajemen dan penilaian properti saat ini menuntut pergeseran dari metode konvensional yang rentan bias menuju pendekatan analitik berbasis Big Data. Tuntutan transparansi Good Corporate Governance (GCG) mewajibkan entitas bisnis untuk mengintegrasikan berbagai variabel kompleks ke dalam model valuasi demi meminimalisir asimetri informasi. Mengingat pemrosesan manual atas ribuan data observasi pasar sangat berisiko memunculkan human error, pemanfaatan Big Data yang dipadukan dengan algoritma Machine Learning menjadi fondasi yang esensial. Melalui komputasi himpunan data berskala masif ini, pola tersembunyi antara karakteristik aset, variabel tata kelola, dan rekam jejak harga dapat dideteksi secara objektif dan real-time, memastikan representasi nilai wajar di dalam laporan keuangan menjadi jauh lebih akurat dan komprehensif.



Deskripsi dataset

Dataset yang digunakan dalam penelitian ini adalah Real Estate Property Transactions Dataset yang dipublikasikan di platform Kaggle oleh Subhi Arjaria (2024). Dataset mencatat 10.000 transaksi properti residensial di negara bagian Connecticut, Amerika Serikat, mencakup periode Januari 2009 hingga Desember 2022. Dataset terdiri dari 12 variabel yang merepresentasikan dimensi waktu, lokasi, nilai ekonomi, dan karakteristik fisik properti.

No	Variabel	Tipe	Role	Keterangan
1	Date	String	Meta	Tanggal transaksi (format YYYY-MM-DD); digantikan Year
2	Year	Numerik	Fitur	Tahun transaksi (2009–2022); 14 tahun data
3	Locality	Kategorik	Fitur	Kota/wilayah; 7 kota utama, 12,6% missing
4	Estimated Value	Numerik	Fitur	Estimasi nilai pasar properti (USD); 12,3% missing
5	Sale Price	Numerik	Target	Harga jual aktual (USD); variabel target utama
6	Property	Kategorik	Fitur/Target	Tipe properti; ada 1.788 nilai tidak valid '?'
7	Residential	Kategorik	Fitur	Jenis hunian (Detached, Duplex, Triplex, Fourplex)
8	num_rooms	Numerik	Fitur	Jumlah kamar (3, 4, 6, atau 8 kamar)
9	num_bathrooms	Numerik	Fitur	Jumlah kamar mandi (1–8)
10	carpet_area	Numerik	Fitur	Luas karpet/area (sq ft); 12,8% missing
11	property_tax_rate	Numerik	Fitur	Tingkat pajak properti (%)
12	Face	Kategorik	Fitur	Arah hadap bangunan (North/South/East/West)

Rumusan masalah

1

Bagaimana kinerja dan tingkat akurasi dari berbagai algoritma machine learning seperti Linear Regression, Random Forest, atau algoritma lainnya dalam memprediksi sales price suatu properti menggunakan 12 atribut yang tersedia?

2

Di antara 12 variabel yang ada, atribut manakah yang memiliki pengaruh paling signifikan terhadap penentuan sales price?

3

Model algoritma manakah yang memberikan performa prediksi paling stabil dan menghasilkan tingkat eror seperti Mean Absolute Error atau Root Mean Squared Error paling rendah untuk diandalkan dalam valuasi real estate?

Tujuan Analisis

1



Membangun dan melatih beberapa model machine learning untuk melakukan estimasi dan prediksi sales price secara objektif berdasarkan 10.000 observasi data properti.

2

Mengevaluasi serta membandingkan secara sistematis kinerja dari setiap model menggunakan metrik evaluasi standar guna mengidentifikasi algoritma yang paling akurat untuk diterapkan pada data valuasi properti.

3

Menganalisis bobot pentingnya fitur feature importance untuk mengidentifikasi variabel-variabel kunci yang paling krusial dalam membentuk harga jual, guna memberikan wawasan berbasis data untuk pengambilan keputusan investasi.



Metodologi



Seluruh rangkaian eksperimen data ini dieksekusi menggunakan perangkat lunak Orange Data Mining. Alur kerja metodologi dimulai dengan Exploratory Data Analysis (EDA) untuk memahami distribusi awal dari 12 variabel yang ada. Sebelum masuk ke pemodelan, kami melakukan pra-pemrosesan data, khususnya menangani potensi missing values dan menstandarisasi skala pada fitur-fitur numerik agar algoritma yang sensitif terhadap jarak tidak menghasilkan keluaran yang bias. Evaluasi model dilakukan secara komprehensif menggunakan modul Test and Score dengan menerapkan skema Cross-Validation (k-fold). Skema ini memutar peran data latih dan data uji secara bergantian, sehingga metrik performa yang dihasilkan seperti Akurasi dan AUC untuk klasifikasi, dan Root Mean Squared Error (RMSE) untuk regresi benar-benar merepresentasikan kemampuan model di dunia nyata, bukan sekadar menghafal data (Kuhn & Johnson, 2013).

EDA & Data Preparation

Analisis Distribusi Sale Price

Sale Price merupakan variabel target utama penelitian ini. Analisis distribusi menggunakan widget Distributions dan Box Plot di Orange mengungkapkan karakteristik sebagai berikut:

Statistik	Nilai	Statistik	Nilai
Jumlah Observasi	10.000	Median	\$340.000
Rata-rata (Mean)	\$622.475	Q1 (25th percentile)	\$160.000
Standar Deviasi	\$1.029.709	Q3 (75th percentile)	\$630.000
Nilai Minimum	\$2.000	Skewness	6,454 (right-skewed)
Nilai Maksimum	\$25.750.000	Missing Values	0 (0%)

Karakteristik Data:

- Dataset berisi 10.000 transaksi properti (2009–2022)
- Target: Sale Price (harga jual aktual)
- Distribusi harga tidak normal (right-skewed)
- Rentang sangat lebar: \$2.000 – \$25,75 juta
- Terdapat outlier ±10% (segmen properti premium)

Pola Penting (EDA):

- Single Family dominan (68%) → pasar tidak seimbang
- Estimated Value sangat berpengaruh (korelasi tinggi)
- Beberapa variabel (rooms, area) → korelasi lemah/negatif
- → indikasi pola data kompleks (tidak linear)

Data Preparation:

- Missing value → mean (numerik) & modus (kategorik)
- Normalisasi → Z-score (standarisasi skala)
- Outlier tidak dihapus (tetap representatif pasar real estate)

Hasil Classification

FileEditViewWindowHelp

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.987	0.971	0.972	0.975	0.971	0.898
kNN	0.987	0.970	0.971	0.975	0.970	0.897
Random Forest	0.988	0.970	0.971	0.975	0.970	0.897
Naive Bayes	0.988	0.971	0.972	0.976	0.971	0.900

Compare models by: Area under ROC curve

☐ Negligible diff.: 0.1

	Tree	kNN	Random Forest	Naive Bayes
Tree		0.679	0.225	0.338
kNN	0.321		0.017	0.123
Random Forest	0.775	0.983		0.695
Naive Bayes	0.662	0.877	0.305	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

10k

10k

4×10000

- Semua model menunjukkan performa sangat tinggi (Accuracy ±97%, AUC ±0,98)
- Naive Bayes → model terbaik (MCC tertinggi & performa paling konsisten)
- Perbedaan antar model relatif kecil → semua algoritma bekerja baik

Hasil Regression

The screenshot displays a machine learning interface with the following components:

- Left Panel (Cross validation settings):**
 - ☒ Cross validation
 - Number of folds: 10
 - ☐ Stratified
 - ☐ Cross validation by feature
 - ☐ Random sampling
 - Repeat train/test: 2
 - Training set size: 90 %
 - ☒ Stratified
 - ☐ Leave one out
 - ☐ Test on train data
 - ☐ Test on test data
- Top Table (Model Performance Metrics):**

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	252199074345.551	502194.260	207851.802	100.550	45.526	0.762
Random Forest (1)	238200140663.580	488057.518	177865.567	66.010	31.053	0.775
Gradient Boosting	225064199433.744	474409.316	174506.971	74.246	33.324	0.788

Compare models by: Mean square error


	Linear Regression	Random Forest (1)	Gradient Boosting
Linear Regression		0.726	0.846
Random Forest (1)	0.274		0.859
Gradient Boosting	0.154	0.141	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Model Gradient Boosting merupakan yang terbaik karena memiliki R^2 tertinggi (0,788) serta MAE dan RMSE terendah.

- MAE & RMSE: Terbaik pada Gradient Boosting → error paling kecil.
- MAPE: Terbaik pada Random Forest (66,01%) → paling baik dalam persentase error
- Linear Regression memiliki error paling besar → performa paling lemah
- Gradient Boosting → prediksi paling mendekati nilai aktual
- Random Forest → cukup baik
- Linear Regression → penyimpangan lebih besar
- Gradient Boosting → residual paling kecil dan acak (model paling fit)
- Linear Regression → masih ada indikasi error sistematis

Hasil Clustering




Pengujian dilakukan pada rentang $k = 2$ sampai 8

- Nilai tertinggi pada $k = 2 \rightarrow$ cluster paling jelas
- $k > 2 \rightarrow$ terjadi overlap antar cluster

Nilai 0,634 ($>0,5$) menunjukkan cluster terpisah dengan baik, Penurunan skor pada $k > 2 \rightarrow$ kualitas cluster memburuk

- Artinya, penambahan cluster justru membuat data semakin overlap
- Pada $k = 2 \rightarrow$ cluster terpisah jelas dan tidak banyak overlap
- Pada $k > 2 \rightarrow$ cluster menjadi kurang jelas dan saling tumpang tindih



Sintesis Terintegrasi

Pendekatan analitik tiga lensa (Classification, Regression, Clustering) yang diterapkan pada 10.000 data transaksi properti telah memberikan pemahaman mengenai dinamika valuasi real estate. Berikut adalah sintesis dari ketiga analisis tersebut:

- Analisis Klasifikasi : Algoritma Naive Bayes terbukti sangat efektif dengan tingkat akurasi 97,1% dan nilai AUC 0,988 dalam mengidentifikasi tipe properti. Hal ini mengonfirmasi bahwa terdapat hubungan yang sangat terstruktur antara atribut fisik (seperti luas area dan jumlah kamar) terhadap klasifikasi tipe bangunan.
 - Analisis Regresi : Prediksi harga jual atau Sales Price merupakan masalah yang kompleks dan non-linear, terbukti dari dominasi algoritma Gradient Boosting yang menghasilkan performa terbaik dan tingkat kesalahan terendah. Menunjukkan bahwa penentuan nilai wajar properti sangat dipengaruhi oleh interaksi variabel yang rumit, yang tidak dapat ditangkap sepenuhnya oleh metode linear tradisional.
 - Analisis Klasterisasi (Segmentasi Pasar): Melalui K-Means dengan *Silhouette Score* tertinggi sebesar 0,634 pada k=2, terungkap bahwa pasar properti secara alami terbelah menjadi dua segmen utama. Segmentasi organik ini memberikan konteks esensial bahwa pasar tidak homogen, melainkan memiliki dua kutub karakteristik yang berlawanan dan terpisah dengan sangat baik.
- 



Implikasi

Peningkatan Kualitas Penilaian Aset: Model regresi komputasional memberikan estimasi fair value yang jauh lebih akurat dan objektif untuk dilaporkan di dalam neraca keuangan. Hal ini menjawab keterbatasan metode penilaian konvensional yang kerap kali bias terhadap tren masa lalu.

Mitigasi Risiko dalam Akuntansi Manajemen: Dari kacamata akuntansi manajemen, pemahaman mengenai prediktor utama harga jual dan segmentasi pasar memungkinkan manajemen untuk mengambil keputusan investasi, alokasi biaya, dan strategi perpajakan (pengelolaan Property Tax) secara lebih terukur. Manajemen dapat menghindari akuisisi aset yang overvalued dan merencanakan portofolio dengan margin risiko yang lebih aman.

Efisiensi Audit Operasional: Bagi auditor internal maupun eksternal, eksistensi pipeline data ini menyediakan jejak audit yang sistematis. Auditor dapat dengan mudah menguji kewajaran nilai aset dengan mereplikasi model pada dataset historis, mempercepat proses audit, dan meningkatkan tingkat keyakinan atas laporan keuangan entitas.




Kesimpulan



Penelitian ini menggabungkan tiga pendekatan analitik, yaitu klasifikasi, regresi, dan klasterisasi untuk menganalisis pasar properti di Connecticut dengan 10.000 data. Hasil klasifikasi menunjukkan bahwa Naive Bayes menjadi model terbaik dengan akurasi 97,1% dan AUC 0,988. Pada analisis regresi, Gradient Boosting memberikan performa terbaik ($R = 0,788$) dengan error terendah, menunjukkan bahwa harga properti bersifat non-linear. Sementara itu, klasterisasi K-Means mengidentifikasi 2 kelompok utama dengan Silhouette Score 0,634, menandakan pemisahan yang jelas. Variabel Estimated Value menjadi faktor paling dominan dalam menentukan harga jual, dengan hubungan positif yang kuat.





Thank You!

