

MARKETING CAMPAIGN RESPONSES ON BANK

Orange Data Mining Project

Classification - Regression - Clustering

Oleh : Kelompok 7

- **Fira Khairunnisa Simamora** 2310112047
- **Muhammad Iqbal Maulana** 2310112059
- **Triasa Puspayunita Tapiheru** 2310112119

PENDAHULUAN

Latar belakang

Perkembangan teknologi digital membuat sektor perbankan menghasilkan data dalam jumlah besar, mulai dari profil nasabah, riwayat transaksi, hingga interaksi pemasaran.

Rumusan Masalah


1. Bagaimana memprediksi respon nasabah terhadap kampanye pemasaran bank menggunakan pendekatan classification berdasarkan karakteristik nasabah dan atribut kampanye yang tersedia dalam dataset?
2. Bagaimana menganalisis target numerik yang berkaitan dengan interaksi kampanye menggunakan pendekatan regression berdasarkan variabel-variabel yang terdapat dalam dataset?
3. Bagaimana mengelompokkan nasabah ke dalam beberapa segmen menggunakan pendekatan clustering berdasarkan kemiripan karakteristik nasabah untuk mendukung strategi pemasaran yang lebih tepat sasaran?

Rumusan Masalah

1. Memberikan identifikasi pola dan faktor yang berhubungan dengan respon nasabah terhadap kampanye pemasaran melalui pendekatan classification.
2. Menganalisis hubungan antar variabel dalam mempengaruhi target numerik yang tepat pada kampanye pemasaran melalui pendekatan regression.
3. Mengelompokkan nasabah ke dalam segmen-segmen tertentu berdasarkan karakteristik yang serupa melalui pendekatan clustering.
4. Mengintegrasikan hasil classification, regression, dan clustering untuk memperoleh pemahaman yang lebih lengkap mengenai perilaku nasabah, sehingga dapat dirumuskan menjadi rekomendasi yang tepat sasaran untuk menjadi strategi pemasaran bank.

DESKRIPSI DATASET

Dataset yang digunakan dalam penelitian ini adalah **Bank Marketing Dataset** yang berasal dari *UCI Machine Learning Repository* (Moro et al., 2014) dan diakses melalui platform **Kaggle** dalam format **bank.csv**. Dataset ini memuat data kampanye pemasaran berbasis telemarketing yang dilakukan oleh bank, dengan unit analisis berupa nasabah yang dihubungi dalam kegiatan tersebut. Fokus utama dari dataset ini adalah untuk melihat bagaimana karakteristik nasabah dan riwayat interaksi sebelumnya berkaitan dengan keputusan mereka dalam merespons penawaran produk keuangan, khususnya deposito berjangka.



The screenshot displays the Kaggle dataset page for 'Bank Marketing Dataset'. At the top, it shows the creator 'JANIO MARTINEZ BACHMANN' and the update status 'UPDATED 8 YEARS AGO'. The dataset title 'Bank Marketing Dataset' is prominently displayed, followed by the subtitle 'Predicting Term Deposit Subscriptions'. To the right, there is a colorful word cloud graphic with terms like 'marketing', 'strategy', 'social media', 'management', 'presentation', 'recommendation', 'innovation', and 'strategy'. Below the title, there are tabs for 'Data Card', 'Code (342)', 'Discussion (7)', and 'Suggestions (0)'. The 'About Dataset' section is visible, containing a 'Context' paragraph and a 'Usability' score of 8.24. The 'License' is listed as 'CC0: Public Domain', and the 'Expected update frequency' is also indicated.

Dataset terdiri dari 17 variabel yang merepresentasikan berbagai dimensi informasi nasabah dan interaksi pemasaran. Secara umum, variabel tersebut dapat dikelompokkan ke dalam beberapa kategori. Pertama, **aspek demografis** seperti *age*, *job*, *marital*, dan *education* yang menggambarkan karakteristik dasar nasabah. Kedua, **aspek kondisi finansial** yang tercermin dalam variabel seperti *balance*, *housing*, dan *loan*. Ketiga, **variabel terkait riwayat interaksi** pemasaran, seperti *contact*, *month*, *day*, serta variabel yang lebih spesifik seperti *duration* (durasi kontak), *campaign* (jumlah kontak dalam kampanye saat ini), *pdays* (jarak hari sejak kontak sebelumnya), *previous* (jumlah kontak sebelumnya), dan *poutcome* (hasil kampanye sebelumnya).

METODOLOGI

Pendekatan Penelitian

Pendekatan yang digunakan adalah kuantitatif berbasis data mining.

Sumber Data

Dataset berasal dari platform **Kaggle - Bank Marketing Dataset**
[kaggle.com/datasets/janiobachmann/bank-marketing-dataset](https://www.kaggle.com/janiobachmann/bank-marketing-dataset)

Memuat:

- Karakteristik demografis nasabah
- Kondisi finansial
- Riwayat interaksi pemasaran
- Respons terhadap campaign
- Dan lainnya

Software

Orange Data Mining

Metode Analisis

Classification

Tujuan :
Memprediksi respons nasabah terhadap campaign

Regression

Tujuan :
Memahami pola hubungan yang lebih kompleks dalam data

Clustering

Tujuan:
Mengidentifikasi kelompok nasabah berdasarkan kemiripan karakteristik

HASIL CLASSIFICATION

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.778	0.803	0.803	0.803	0.803	0.604
kNN (1)	0.873	0.807	0.807	0.808	0.807	0.613
Naive Bayes	0.855	0.769	0.768	0.769	0.769	0.536
Random Forest	0.909	0.840	0.840	0.841	0.840	0.681

Variabel Target yang Dipilih
Deposit


Alasan Pemilihan

Menunjukkan respon nasabah terhadap *campaign* bank, sehingga sesuai untuk klasifikasi *yes/no*

Model Terbaik
Random Forest

Kesimpulan

- Performa paling baik dibanding model lain
- AUC tertinggi 0.909 dan CA 0.840
- Paling optimal untuk memisahkan nasabah yang deposit dan tidak deposit



Kategorik Biner:
Deposit: yes/no

Variabel Prediktor:
Gabungan Data Numerik dan Data Kategorikal

Hasil klasifikasi menunjukkan bahwa Random Forest merupakan model terbaik untuk memprediksi respons nasabah terhadap campaign bank. Temuan ini menegaskan bahwa strategi pemasaran dapat dilakukan lebih terarah, dengan memfokuskan penawaran kepada nasabah yang memiliki peluang lebih besar untuk menerima deposit.

HASIL CLASSIFICATION

Actual

		Predicted		
		no	yes	Σ
no	4865	1008	5873	
yes	1192	4097	5289	
Σ	6057	5105	11162	

Bentuk Data:

Data ini berbentuk data terstruktur/tabular

Kualitas Prediksi


- Random Forest: AUC 0,909 dan CA 0,840
- kNN dan Decision Tree masih cukup kompetitif
- Naive Bayes memiliki performa paling rendah

Pola Error (*Residual*)

- 8.962 prediksi benar dari 11.162 data
- 4.865 data no diprediksi benar sebagai no
- 4.097 data yes diprediksi benar sebagai yes
- Model sedikit lebih baik mengenali kelas no dibanding yes

Interpretasi Tree Viewer

- Variabel duration menjadi faktor paling berpengaruh dalam klasifikasi
- Pemisahan awal terjadi pada $\text{duration} \leq 206$ dan $\text{duration} > 206$
- Durasi komunikasi yang rendah cenderung mengarah ke kelas no
- poutcome = success dominan mengarah ke kelas yes
- Variabel lain yang ikut berpengaruh adalah month, contact, day, job, dan poutcome



Kesimpulan Hasil Analisis Classification

Hasil klasifikasi menunjukkan bahwa Random Forest merupakan model terbaik untuk memprediksi respons nasabah terhadap campaign bank. Sementara itu, interpretasi Decision Tree menunjukkan bahwa **duration** atau lamanya komunikasi menjadi faktor utama dalam membedakan nasabah yang melakukan deposit dan tidak melakukan deposit.

HASIL REGRESSION

Test and Score						
Settings						
Sampling type: 10-fold Cross validation						
Scores						
Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	119632.888	345.880	251.991	190.772	70.069	0.007
Random Forest	126392.658	355.517	261.634	200.799	70.884	-0.049
Tree	206593.966	454.526	321.328	205.817	80.274	-0.715
Gradient Boosting	118908.800	344.832	250.737	187.953	69.629	0.013
SVM	296225.922	544.266	497.276	475.621	97.267	-1.459

Variabel Target yang Dipilih
Duration

Alasan Pemilihan

Merupakan indikator engagement nasabah yang mencerminkan kualitas interaksi, bukan sekadar waktu

Model Terbaik


Gradient Boosting

Kesimpulan


- Prediksi paling mendekati nilai aktual
- Error paling kecil dibanding model lain
- Paling stabil dalam menangani data kompleks

Meskipun performa regresi relatif rendah, *Duration* sebagai variabel target tetap dipilih. Ini menunjukkan bahwa durasi interaksi adalah besaran yang sangat bervariasi yang bergantung pada variabel situasional tertentu, beberapa di antaranya tidak diamati dalam dataset yang tersedia.

Dari segi *marketing*, *duration* dipengaruhi oleh dua hal, baik oleh karakteristik pelanggan maupun oleh aspek kualitatif tertentu dari dinamika komunikasi itu sendiri. Meskipun demikian, hasil analisis tetap mampu mengidentifikasi variabel yang berkontribusi terhadap *duration*, seperti *campaign*, sehingga memberikan *insight* yang bernilai meskipun kemampuan prediksinya terbatas.



HASIL REGRESSION



Kesimpulan Hasil Regresi

Data memiliki pola kompleks (non-linear)

Kualitas Prediksi

Prediksi belum sepenuhnya akurat karena terjadi penyebaran error cukup besar

Pola Error (*Residual*)

- Error tidak tersebar merata
- Variasi tinggi pada rentang prediksi tertentu (300–500)

Artinya

- Model belum stabil secara konsisten
- Masih ada dinamika data yang belum tertangkap

Faktor Paling Berpengaruh Campaign (Faktor Utama)

Semakin tinggi frekuensi kontak yang dilakukan (*campaign*), semakin besar kemungkinan durasi interaksi tidak stabil, karena nasabah yang sering dihubungi cenderung membutuhkan klarifikasi lebih lanjut atau menunjukkan respons yang beragam terhadap penawaran.

Marital

Status menikah mengindikasikan bahwa semakin tinggi tanggung jawab finansial, semakin besar kemungkinan nasabah membutuhkan waktu lebih lama untuk mempertimbangkan keputusan, sehingga durasi interaksi cenderung lebih variatif. berarti sosial ikut memengaruhi interaksi

Housing


Kondisi kepemilikan kredit rumah mencerminkan beban finansial nasabah, di mana semakin besar kewajiban finansial, semakin besar kemungkinan nasabah bersikap lebih berhati-hati, sehingga durasi interaksi menjadi lebih dinamis.

Ranks				
		#	Univar. reg.	RReliefF
1	 campaign		19.307	0.021
2	 marital=married		14.627	0.027
3	 housing=yes		13.728	0.023

Kesimpulan Hasil Analisis Regresi

Model terbaik yaitu **Gradient Boosting**, mampu memberikan prediksi paling stabil, namun secara umum performa regresi masih terbatas. Hal ini menunjukkan bahwa durasi interaksi dipengaruhi oleh faktor yang kompleks dan tidak sepenuhnya terukur. Namun, variabel seperti **campaign**, **marital**, dan **housing** tetap terbukti berkontribusi dalam membentuk pola durasi, sehingga memberikan insight penting terkait dinamika komunikasi antara bank dan nasabah.

HASIL CLUSTERING



Kesimpulan Hasil Analisis Scatter Plot

Dari hasil clustering pada Scatter Plot di atas, dapat disimpulkan bahwa pengelompokan sudah terlihat cukup jelas, terutama untuk pemisahan media kontak antara unknown, telephone, cellular. Namun jika dilihat berdasarkan persebaran titik duration, pada scatter plot tersebut terlihat bahwa masih banyak cluster yang saling berdekatan terlebih pada durasi rendah hingga menengah. Dengan demikian dapat disimpulkan bahwa hasil cluster cukup jelas untuk segmentasi jenis kontak yang dilakukan, namun tidak bisa sempurna karena masih terdapat kemiripan pola dalam duration antar cluster.

HASIL CLUSTERING

Cluster	Silhouette Score
K-Means	
C1	0,031
C2	0,073
C3	-0,031
Hierarchical Clustering	
C1	-0,017
C2	0,022
C3	-0,099

BDSCAN	
C1	-0,558
C2	0,647
C3	-0,515
C4	0,261
C5	0,320
C6	-0,424
C7	-0,369
C8	0,649
C9	0,567
C10	0,398
C11	0,588
C12	0,852

C13	0,442
C14	0,108
C15	0,694
C16	0,630
C17	0,878
C18	0,893
C19	0,931
C20	0,259
C21	0,806
C22	0,855
C23	0,930
C24	0,710

Kesimpulan Hasil Analisis Silhouette Plot

Berdasarkan nilai Silhouette Score tertinggi dari masing-masing metode, pada K-Means cluster terbaik adalah C2 dengan nilai 0,073. Namun, nilai ini masih mendekati 0, sehingga pemisahan cluster belum terlalu kuat. Pada Hierarchical Clustering, cluster terbaik juga terdapat pada C2 dengan nilai 0,022, tetapi nilainya masih sangat rendah sehingga kualitas cluster belum optimal. Sementara itu, pada DBSCAN, cluster terbaik adalah C19 dengan nilai 0,931, yang menunjukkan bahwa cluster tersebut sangat kompak dan terpisah jelas dari cluster lain. Jadi, secara keseluruhan metode DBSCAN menghasilkan cluster terbaik dibandingkan K-Means dan Hierarchical Clustering.

SINTESIS & IMPLIKASI TERINTEGRASI

KONSISTENSI TEMUAN ANTAR ANALISIS

Inti:

Respons nasabah dipengaruhi oleh interaksi yang kompleks.

Poin utama:

- Duration menjadi variabel penting di berbagai analisis.
- Classification: duration memengaruhi peluang deposit.
- Regression: duration dipengaruhi variabel lain.
- Clustering: duration menunjukkan pola interaksi nasabah.

Kesimpulan:

Duration menjadi penghubung utama antar analisis.

KETERKAITAN CLUSTERING DENGAN CLASSIFICATION & REGRESSION

Inti:

Clustering berkaitan dengan analisis lain melalui variabel duration.

Poin utama:

- Cluster dibentuk berdasarkan contact dan duration.
- Durasi tinggi cenderung berkaitan dengan peluang deposit lebih besar.
- Regression menjelaskan bahwa duration dipengaruhi oleh campaign, marital, housing, job, pdays, dan previous.

Kesimpulan:

Clustering membantu melihat segmentasi pola komunikasi nasabah.

SINTESIS & IMPLIKASI TERINTEGRASI

INTEGRASI TEMUAN DALAM PERSPEKTIF BISNIS

Inti:

Campaign tidak cukup hanya mengandalkan jumlah kontak.

Poin utama:

- Komunikasi yang sering belum tentu efektif.
- Kualitas interaksi lebih penting daripada sekadar frekuensi kontak.
- Respons nasabah berbeda-beda tergantung kondisi dan relevansi penawaran.

Kesimpulan:

Strategi pemasaran harus berfokus pada kualitas komunikasi.

IMPLIKASI DAN REKOMENDASI MANAJERIAL

Inti:

Bank perlu membuat campaign yang lebih terarah.

Poin utama:

- Target nasabah perlu dipilih berdasarkan peluang respons.
- Komunikasi harus lebih personal dan relevan.
- Data mining membantu membaca pola perilaku nasabah.
- Strategi campaign sebaiknya berbasis data riil.

Kesimpulan:

Bank perlu menyusun strategi pemasaran yang lebih tepat sasaran, efektif, dan efisien.

KESIMPULAN & SARAN

KESIMPULAN

Secara keseluruhan, analisis classification, regression, dan clustering pada Bank Marketing Dataset saling melengkapi dalam menjelaskan perilaku nasabah terhadap marketing campaign bank. Pada classification, Random Forest menjadi model terbaik karena mampu menangkap pola data yang kompleks, dengan duration sebagai prediktor paling kuat dalam menentukan peluang nasabah menerima penawaran. Pada regression, Gradient Boosting menjadi model paling stabil dalam memprediksi duration, meskipun nilai R^2 yang rendah menunjukkan bahwa durasi interaksi belum sepenuhnya dapat dijelaskan oleh variabel yang tersedia. Sementara itu, clustering dengan variabel contact dan duration menunjukkan adanya perbedaan pola interaksi antar segmen nasabah, meskipun hasilnya masih bersifat eksploratif karena variabel yang digunakan terbatas. Dengan demikian, duration menjadi variabel utama yang menghubungkan ketiga analisis karena menggambarkan tingkat keterlibatan nasabah dalam proses campaign.

SARAN

Berdasarkan hasil analisis classification, regression, dan clustering, pihak bank disarankan untuk memanfaatkan hasil classification dalam menentukan target kampanye agar pemasaran lebih terarah kepada nasabah yang berpotensi melakukan deposit. Selain itu, bank perlu memperhatikan duration karena durasi komunikasi menjadi variabel penting dalam keputusan nasabah. Pihak bank juga perlu mengevaluasi media komunikasi yang digunakan, karena pemilihan media yang tepat dapat meningkatkan peluang respons positif dari nasabah.

THANK YOU

