



ANALISIS SALES & REVENUE

SUPERMART DATASET

DOSEN PENGAMPU : DR. DONNY MAHA PUTRA, S.KOM.,M.AK

ANGGOTA KELOMPOK 08 :

- | | |
|------------------------------------|------------|
| 1.RADEN AHMAD ARIJUDDIN BRILLYANTO | 2310112017 |
| 2.ZASKIA HANIFAH | 2310112071 |
| 3.ANGELICA FAJARINA NUGROHO | 2310112191 |
| 4.ANISA AMELIA GHANDI | 2310112219 |



UTS Big Data Analytics- Kelas A

PENDAHULUAN

pentingnya analisis data dalam menghadapi persaingan bisnis ritel yang semakin kompleks, dengan menekankan pemanfaatan Supermart Dataset untuk memahami pola penjualan dan pendapatan melalui pendekatan data-driven. Penelitian ini mengintegrasikan tiga metode utama, yaitu klasifikasi (KNN, Decision Tree, Random Forest) untuk memprediksi kategori data, regresi (Linear Regression dan Random Forest Regression) untuk memperkirakan nilai revenue atau profit, serta clustering (K-Means dan Hierarchical Clustering) untuk mengidentifikasi segmentasi tersembunyi dalam data. Melalui kombinasi metode tersebut, analisis diharapkan mampu menghasilkan insight yang komprehensif terkait faktor-faktor yang memengaruhi kinerja penjualan, perilaku konsumen, serta peluang optimasi strategi bisnis, sehingga dapat mendukung pengambilan keputusan yang lebih efektif, efisien, dan adaptif bagi Supermart.



TINJAUAN TEORI

Penelitian ini menggunakan tiga pendekatan analisis yang saling melengkapi satu sama lain. Pendekatan ini terdiri dari klasifikasi yang bertujuan untuk mengelompokkan data kedalam kategori tertentu dengan informasi data yang ada, algoritma yang diuji pada pendekatan ini yaitu KNN, Decision Tree serta Random Forest dan Adaboost. Pendekatan yang kedua yaitu regresi yang bertujuan untuk memprediksi nilai numeric seperti profit dan revenue berdasarkan Discoun, sales, dan Quantity, dengan menggunakan algoritma linear regression dan Random Forest Regression. Pendekatan yang terakhir adalah clustering yang bertujuan untuk mengelompokkan data tanpa label untuk menemukan pola yang tersembunyi seperti segmentasi pelanggan dan tren wilayah. Pendekatan ini menggunakan dua algoritma yaitu K-Means dan Hierarchical clustering. Ketiga pendekatan ini berjalan di atas dasar yang sama, yaitu data mining sebagai proses untuk menggali pola yang bermakna dari tumpukan data transaksi yang besar.



METODE

Analisis menggunakan pendekatan data analytics berbasis machine learning dengan aplikasi Orange untuk mengolah dataset Supermart. Metode yang digunakan meliputi klasifikasi, regresi, dan klastering untuk mendapatkan insight dari sisi prediksi dan pola data.

Proses analisis dilakukan bertahap, dimulai dari pemahaman data dan EDA untuk melihat karakteristik serta hubungan antar variabel. Selanjutnya dilakukan data preparation seperti pemilihan variabel dan penentuan target.

Pada tahap analisis, digunakan beberapa metode yaitu:

- Klasifikasi untuk memprediksi kategori (KNN, Decision Tree, Random Forest)
- Regresi untuk memprediksi nilai numerik seperti profit (Linear Regression, Random Forest)
- Klastering untuk mengelompokkan data berdasarkan kemiripan (K-Means, Hierarchical)

Hasil dari seluruh metode kemudian dievaluasi dan diinterpretasikan untuk mendapatkan insight yang dapat digunakan dalam mendukung pengambilan keputusan bisnis.

EXPLORATORY DATA ANALYSIS

Nama Dataset: Superstore Dataset
Sumber : Kaggle
Link [Superstore Dataset](#)
Lisensi : Public/Open
Format Data : CSV
Jumlah Data : 9.994 baris & 21 kolom.

Hasil Analisis menunjukkan bahwa:

➡ Data Table : 9994 instance tanpa missing data

➡ 4 Model Pivot Table :

- Category (R), Region (C), Profit (V)
- Category (R), SubCategory (C), Profit (V)
- Category (R), Segment (C), Profit (V)
- Segment (R), Category (C), Discount (V)

INSIGHTS

- Profitable: Technology (Copiers & Phones)
- Loss: Furniture (Bookcases & Tables)
- West: Best Selling Region
- Central: Lowest Selling Region
- Home Officer: Profitable Consumer

➡ Rank Analysis: Segment (T)

Scoring Method: Info. Gain, Gain Ratio, Gini, ANOVA, Chi Square, ReliefF, FCBF

INSIGHT: State, Discount, Sub-Category paling berpengaruh dalam membedakan segmen pembeli

➡ Correlations Analysis:

- Category (T)
- Pearson ✓
- Spearman ✓ More accurate

➡ Distributions Analysis:

- Sales as Variable
- Splitted by Category

➡ Scatter Plot ⇔ *Diskon (X) Profit (Y)*

INSIGHTS

- Diskon naik, Profit Turun
- Most profitable transactions @ level discount 30%
- Kerugian dikuasai Furniture & Office Supplies

➡ Box Plot

- Box Plot 1: Profit & Segment Consumer
- Box Plot 2: Sales & Category Product

INSIGHTS


- Home Office ➡ Mean & Median Paling Tinggi
- Technology ➡ Mean Paling Tinggi

INSIGHTS

- Sales ➡ Profit, Berpengaruh, +
- Diskon ➡ Profit, Berpengaruh, -
- Quantity ➡ Profit, Pengaruh non significantly

INSIGHTS

- Technology ➡ Most profitable
- Furniture ➡ Biggest Loss
- Office Supply ➡ Biggest Volume



➡ Column Statistics
Category as Target & Numeric

INSIGHTS

- Office Supplies dominance vol.
- Technology paling sedikit jumlahnya

DATA PREPARATION

Preparation Focus

- Data disesuaikan dengan kebutuhan
- Target dan feature dipilih sesuai keinginan interpretasi
- Feature yang tidak relevan diberi role skip/ignored
- Sampling dilakukan untuk mengurangi beban komputasi

Data Preparation: Classification Analysis

- Target → Category (Multiclass)
- Class → Furniture, Office Supplies, Technology
- Feature non relevan → Skip/Ignored
- Sampling → 50% / 4.997 data

Data Preparation: Regression Analysis

- Target → Profit
- Linear Regression → Discount to Profit
- Random Forest → Sales, Quantity, Discount to Profit
- Fokus → Prediksi profit transaksi

Data Preparation: Clustering Analysis

- Features → Sales, Quantity, Discount, Profit
- Feature → Numeric
- Sampling untuk K-Means → 50%
- Fokus → Segmentasi Transaksi

KNN

KNN menunjukkan performa yang cukup baik dengan akurasi 97,7% saat menggunakan metric Manhattan, yang terbukti lebih optimal dibandingkan Euclidean. Model mampu mengklasifikasikan data dengan baik, terutama pada kategori Office Supplies dan Furniture, meskipun masih terdapat kesalahan pada kategori yang memiliki pola mirip seperti Technology.

Predictions - Orange

Show probabilities for: **Classes in data** ☒ Show classification errors **Restore Original Order**

	kNN	error	Category	Order ID	Order Date
1	1.00 : 0.00 : 0.00 → Furniture	0.000	Furniture	CA-2016-117590	12/8/2016
2	0.00 : 1.00 : 0.00 → Office Supplies	0.000	Office Supplies	CA-2016-157364	11/19/2016
3	0.60 : 0.40 : 0.00 → Furniture	0.400	Furniture	CA-2017-131492	10/19/2017
4	0.00 : 1.00 : 0.00 → Office Supplies	0.000	Office Supplies	US-2016-143819	3/1/2016
5	0.00 : 1.00 : 0.00 → Office Supplies	0.000	Office Supplies	CA-2017-139402	12/9/2017
6	0.80 : 0.00 : 0.20 → Furniture	0.200	Furniture	CA-2014-136567	12/20/2014

☒ Show performance scores Target class: (Average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.998	0.977	0.977	0.977	0.977	0.958

4997 | 4997 | 1×4997

NAÏVE BAYES

Naïve Bayes menghasilkan performa sangat tinggi dengan akurasi 100% serta proses yang cepat dan sederhana. Model ini mampu mengenali pola data dengan sangat baik, namun hasil yang terlalu sempurna perlu diperhatikan karena berpotensi kurang stabil jika diterapkan pada data baru.

Confusion Matrix (1) - Orange

Learners: Naive Bayes

Show: Number of instances

		Predicted			Σ
		Furniture	Office Supplies	Technology	
Actual	Furniture	2121	0	0	2121
	Office Supplies	0	6026	0	6026
	Technology	0	0	1847	1847
Σ		2121	6026	1847	9994

Output: ☒ Predictions ☐ Probabilities


☒ Apply Automatically

Select Correct Select Misclassified Clear Selection

1×9994 - | 9994


DECISION TREE

Decision Tree mampu memberikan interpretasi yang jelas terhadap pola data, di mana faktor seperti sales, profit, dan quantity menjadi penentu utama dalam klasifikasi. Model ini membantu memahami hubungan antar variabel, namun memiliki kompleksitas yang cukup tinggi.



RANDOM FOREST DAN ADABOOST


Random Forest dan AdaBoost menunjukkan performa terbaik dengan akurasi yang sangat tinggi dan hasil yang lebih stabil. Kedua model ini mampu menangkap pola data yang lebih kompleks serta mengurangi kesalahan klasifikasi dibandingkan model tunggal.



BAB 6

LINEAR REGRESSION


Di slide ini kita bisa lihat hasil dari model linear regression, dari tabel korelasinya, terlihat ada ada angka -0,219 antara diskon dan profit. Ini berarti makin besar diskon yang kita kasih, profit kita justru makin turun, masalahnya model ini ternyata terlalu simpel dan kaku buat data kita. Angka R2 nya cuma di kisaran 0,19, yang kalau diibaratkan, model ini cuma bisa nangkep sekitar 19% dari kejadian nyata di lapangan, sisanya meleset semua. lihat di grafik residual plot-nya, ada pola garis vertikal yang aneh di sana. Itu tandanya model ini punya 'error' bawaan yang bikin model ini sanggup memprediksi angka-angka profit yang ekstrem atau melonjak. Jadi kesimpulannya, buat urusan data Superstore yang sekompleks ini, kita nggak bisa cuma mengandalkan cara linear kayak gini (tidak dapat diandalkan).



Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	41123.397	202.789	53.003	inf	149.255	0.197

RANDOM FOREST REGRESSION


Jika pada linear regression kurang akurat, kita bisa mencoba dengan random forest regression. Hasil analisis yang didapat bisa kita lihat skor R2 mencapai 0,862 yang berarti model ini mampu menangkap hampir 70% pola pada data superstore ini. Ini bukan angka yang sempurna tapi bisa lebih diandalkan. Bisa kita lihat ada yang menarik dari grafiknya, titik kuning dan hijau bagian atas menunjukkan kalau diskon melewati angka 50% akan berujung rugi. tapi titik biru tua di sisi lain menunjukkan kalau diskon kecil atau tanpa diskon sama sekali profit akan naik secara signifikan. Pola diagonal juga terlihat lebih jelas dan rapi, tingkat eror nya juga lebih sedikit. Ini bikin visual yang lebih realistis dan relevan untuk dijadikan dasar dalam menentukan strategi diskon kedepannya.



Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Random Forest	16268.334	127.547	27.059	inf	49.094	0.682


K-CLUSTERING

Hasil analisis menunjukkan bahwa jumlah cluster optimal adalah 3 (silhouette score 0,87 dan didukung juga oleh Elbow Method), yang mengelompokkan data menjadi: transaksi kecil dengan profit rendah (C1), transaksi menengah dengan profit tidak stabil (C2), dan transaksi besar dengan profit tinggi (C3). Insight utama yang diperoleh adalah adanya korelasi positif antara sales dan profit namun tidak selalu konsisten, quantity tidak berpengaruh signifikan terhadap profit, serta diskon memiliki korelasi negatif kuat terhadap profit di mana diskon tinggi cenderung menyebabkan kerugian. Temuan ini memberikan dasar penting bagi perusahaan dalam mengoptimalkan strategi penjualan, khususnya dalam pengelolaan diskon dan fokus pada transaksi bernilai tinggi yang lebih menguntungkan.



HIERARCHIAL CLUSTERING

Menghasilkan 4 cluster utama berdasarkan tingkat kemiripan data. Hasil visualisasi melalui scatter plot menunjukkan bahwa terdapat variasi pola yang signifikan, seperti adanya cluster 1 dengan penjualan tinggi namun profit negatif (berisiko tinggi), cluster 2 dengan transaksi kecil dan profit mendekati nol (volume besar tapi kontribusi rendah), serta cluster 3 dengan performa stabil dan cluster 4 dengan penjualan yang tinggi dan juga profit yang positif. Secara umum, temuan ini menegaskan bahwa nilai penjualan tidak selalu berbanding lurus dengan profit, sehingga perusahaan perlu lebih selektif dalam strategi penjualan, terutama dalam mengelola transaksi bernilai besar agar tetap menguntungkan.



Sintesis Integrasi EDA

EDA menunjukkan bahwa performa penjualan Supermart berbeda di tiap region dan kategori produk. West menjadi region dengan profit tertinggi, sedangkan Central paling rendah karena Furniture banyak merugi. Dari sisi kategori, Technology menjadi produk paling menguntungkan, terutama Copiers dan Phones. Sebaliknya, Furniture perlu dievaluasi karena Bookcases dan Tables konsisten memberikan kerugian

Sintesis Integrasi Klasifikasi

Analisis klasifikasi menunjukkan bahwa kategori produk dapat diprediksi dengan sangat baik berdasarkan pola sales, profit, discount, dan quantity. Hampir semua model memiliki hasil evaluasi sangat tinggi, sehingga dapat disimpulkan bahwa setiap kategori produk memiliki karakteristik transaksi yang berbeda. Technology menjadi kategori yang paling kuat pada sales dan profit tinggi.

Sintesis Integrasi Regresi

Regresi menunjukkan bahwa profit paling banyak dipengaruhi oleh sales dan discount. Sales berperan menaikkan profit, sedangkan discount yang terlalu besar justru menurunkan profit. Random Forest Regression memberikan hasil yang lebih baik dibanding Linear Regression karena mampu menangkap pola profit yang lebih kompleks.

Sintesis Integrasi Clustering

Clustering menunjukkan bahwa transaksi Supermart terbagi ke dalam beberapa kelompok dengan karakter berbeda. Transaksi dengan discount rendah cenderung menghasilkan profit tinggi, sedangkan discount di atas 30% mulai masuk zona berisiko. Quantity besar juga tidak selalu menghasilkan profit besar, karena profit tinggi justru banyak muncul pada quantity sedang.

KESIMPULAN

Data menunjukkan bahwa sales dan discount paling berpengaruh terhadap profit.

Sales meningkatkan profit, tapi diskon tinggi bisa menyebabkan kerugian.

Model klasifikasi menghasilkan performa tinggi, dengan Random Forest & AdaBoost paling stabil, sementara KNN cukup baik untuk awal.

Intinya, pengelolaan sales dan discount jadi kunci utama.

SARAN

1. Kontrol diskon, terutama di atas 30%
2. Fokus pada kategori Technology, dan evaluasi Furniture
3. Gunakan Random Forest/AdaBoost untuk analisis lebih lanjut
4. Perlu keseimbangan antara penjualan dan profit



**TERIMA
KASIH**

