

FRAUD AND ANOMALY DETECTION

LAPORAN PROJECT BIG DATA ANALYTICS

Presented by:

Raihan Febrian Asyifa (2310112011)

Kayla Najla Ramadhina (2310112235)

Ravy Handaru Pratomo (2310112175)

Dosen Pengampu:

Dr. Donny Maha Putra





LATAR BELAKANG



Fraud pada transaksi keuangan menjadi isu serius seiring meningkatnya penggunaan layanan digital seperti mobile banking, e-wallet, dan kartu pembayaran. Kemudahan ini diikuti dengan meningkatnya risiko kejahatan seperti pencurian identitas dan manipulasi transaksi. Data dari European Banking Authority dan European Central Bank menunjukkan kerugian fraud pembayaran mencapai EUR 4,3 miliar pada 2022, sementara di Amerika Serikat kerugian bahkan mencapai lebih dari USD 12,5 miliar pada 2024. Hal ini menunjukkan bahwa fraud tidak hanya berdampak pada sistem, tetapi juga mempengaruhi kepercayaan publik dan stabilitas ekonomi lembaga keuangan.

Deteksi fraud menjadi semakin kompleks karena pola transaksi tidak selalu terlihat mencurigakan secara langsung, melainkan harus dianalisis dari berbagai variabel seperti jumlah transaksi, lokasi, perangkat, hingga riwayat aktivitas pengguna. Oleh karena itu, pendekatan machine learning digunakan untuk menangkap pola yang kompleks dan nonlinier. Dalam penelitian ini digunakan synthetic fraud dataset yang memiliki 21 variabel dan target Fraud Label. Dataset ini tetap relevan karena mampu merepresentasikan karakteristik transaksi nyata tanpa risiko kebocoran data, serta dapat digunakan untuk analisis klasifikasi, regresi, dan clustering dalam satu kerangka yang terintegrasi.



RUMUSAN MASALAH >>>>



Bagaimana algoritma klasifikasi seperti kNN, Naïve Bayes, Decision Tree, Random Forest, dan ensemble stacking digunakan untuk membedakan transaksi fraud dan non-fraud secara akurat.



Bagaimana variabel `transaction_amount` dimodelkan untuk memahami dan memprediksi pola aktivitas keuangan serta mendeteksi transaksi yang menyimpang.



Bagaimana data transaksi dikelompokkan berdasarkan kemiripan karakteristik untuk membentuk segmentasi pengguna yang lebih jelas.



DESKRIPSI DATASET >>>>

- Transaction_ID
- User_ID
- Transaction_Amount
- Transaction_Type
- Timestamp
- Device_Type
- Location
- Merchant_Category
- IP_Address_Flag
- Previous_Fraudulent_Activity
- Daily_Transaction_Count
- Avg_Transaction_Amount_7d
- Failed_Transaction_Count_7d
- Card_Type
- Card_Age
- Transaction_Distance
- Authentication_Method
- Risk_Score
- Is_Weekend
- Fraud_Label

TINJAUAN TEORI & METODE

ANALISIS BIG DATA



Big Data Analytics merupakan teknologi yang digunakan untuk memproses data dalam jumlah besar dan beragam, sehingga mampu menghasilkan informasi yang lebih akurat serta memberikan wawasan yang lebih mendalam (Gracia & Arhamarra, 2026). Data yang termasuk dalam kategori big data biasanya memiliki karakteristik yang dikenal dengan konsep 5V, yaitu volume (jumlah data yang besar), velocity (kecepatan data), variety (keberagaman bentuk data), veracity (keakuratan data), dan value (nilai yang dihasilkan dari data) (Hussain et al., 2023).



TINJAUAN TEORI & METODE

FRAUD DETECTION & ANOMALY



Fraud merupakan tindakan yang dilakukan dengan sengaja dalam suatu kondisi tertentu untuk memperoleh keuntungan yang tidak sah atau menimbulkan kerugian bagi pihak lain (Nurhalisa & Rely, 2024). Fraud seringkali melibatkan manipulasi transaksi, pencurian identitas, atau penyalahgunaan sistem pembayaran.




TINJAUAN TEORI & METODE

DATA MINING



Data Mining adalah proses penggalian atau penyaringan data dengan memanfaatkan kumpulan data berukuran besar melalui serangkaian tahapan, sehingga diperoleh informasi yang bernilai dari data tersebut (Asyuti & Setyawan, 2023). Machine learning telah mendorong inovasi signifikan dalam upaya mendeteksi kecurangan di berbagai sektor seperti keuangan, e-commerce, dan layanan keuangan digital, sekaligus mengubah cara perusahaan dalam menghadapi tantangan identifikasi kecurangan yang kompleks dan tersembunyi (Prasetyo & Dewayanto, 2024).





METODE



Fraud Risk




Anomaly Detection

Classification (theory)	Classification merupakan proses mengenali serta mengelompokkan suatu objek ke dalam kategori atau kelompok yang memiliki kesamaan (Adhitya dkk, 2023). Analisis klasifikasi dibagi menjadi 3,yaitu: - KNN - Decision Tree - Random Forest
Regression (theory)	Regression adalah metode dalam supervised learning yang digunakan untuk memprediksi nilai numerik berdasarkan hubungan antara variabel independen dan dependen. Tujuan analisis regresi adalah untuk mengestimasi nilai variabel dependen berdasarkan variabel independen sekaligus menganalisis hubungan antarvariabel tersebut (Bode, 2019).Analisis regression bisa menggunakan Analisis Regresi Linear
Clustering (theory)	Clustering adalah teknik untuk mengelompokkan data ke dalam beberapa klaster berdasarkan kesamaan karakteristik antar objek (Putra dkk, 2025). Metode ini memungkinkan data untuk membentuk kelompok secara alami, sehingga dapat digunakan untuk memahami pola perilaku pengguna. Ada 2 cara menganalisis klaster, pertama menggunakan hierarchy clustering dan KNN Mean


HASIL CLASSIFICATION



Analisis klasifikasi menggunakan dataset sekitar 50.000 transaksi dengan target Fraud_Label (0 = non-fraud, 1 = fraud) memperlihatkan bahwa model mampu membedakan kedua kelas dengan cukup baik, meskipun deteksi fraud belum sepenuhnya optimal. Model Naïve Bayes menghasilkan AUC 0,957, accuracy 0,837 (83,7%), F1-score 0,820, precision 0,859, recall 0,837, dan MCC 0,623. Pada confusion matrix tercatat 114.278 true negative dan 27.956 true positive, serta 1.092 false positive dan 26.674 false negative, yang menunjukkan masih adanya transaksi fraud yang tidak terdeteksi. Model ensemble stacking memberikan hasil yang lebih tinggi dengan AUC sekitar 0,905–0,967, accuracy hingga 0,906 (90,6%), F1-score 0,904, precision 0,907, recall 0,906, dan MCC 0,782, dengan keseimbangan prediksi yang lebih baik pada kedua kelas.




HASIL >>>> REGRESSION




Analisis regression menggunakan sekitar 50.000 data transaksi dengan target transaction_amount yang bersifat numerik kontinu dan memiliki distribusi tidak merata, di mana sebagian besar transaksi berada pada nilai kecil dan sebagian lainnya memiliki nilai sangat tinggi, sehingga membentuk pola right-skewed. Proses analisis dimulai dari pemuatan data, seleksi variabel seperti Risk_Score, Account_Balance, Transaction_Distance, Daily_Transaction_Count, Avg_Transaction_Amount_7d, dilanjutkan normalisasi, pembagian data training dan testing, hingga pembentukan model Linear Regression dan Random Forest Regression. Hasil evaluasi Linear Regression menunjukkan nilai MSE 0,12913, RMSE 0,35936, MAE 0,30124, R^2 0,40785, serta MAPE mencapai $7,75 \times 10^{16}$, yang menunjukkan error sangat besar akibat adanya nilai aktual mendekati nol. Visualisasi Predicted vs Actual memperlihatkan titik data belum mengikuti garis diagonal, dan residual belum tersebar acak. Model Random Forest memberikan hasil yang lebih tinggi dengan AUC 0,9987, accuracy 0,8843, F1-score 0,8761, precision 0,9011, recall 0,8843, dan MCC 0,7388, sehingga mampu menangkap pola yang lebih kompleks. Variabel yang paling berpengaruh terhadap nilai transaksi antara lain Risk_Score, Transaction_Distance, dan Failed_Transaction_Count_7d, yang berkaitan dengan tingkat risiko, lokasi transaksi, dan riwayat aktivitas pengguna.

HASIL CLUSTERING



Analisis clustering dilakukan untuk mengelompokkan sekitar 50.000 data transaksi berdasarkan kemiripan karakteristik numerik seperti `transaction_amount`, `account_balance`, `risk_score`, `transaction_distance`, dan `daily_transaction_count`. Proses dimulai dari seleksi variabel, normalisasi data, hingga penentuan jumlah cluster menggunakan metode Elbow yang menghasilkan $K = 3$ sebagai jumlah cluster terbaik. Model K-Means dan Hierarchical Clustering digunakan untuk membentuk kelompok data dan melihat hubungan antar data melalui dendrogram. Evaluasi menggunakan Silhouette Score menunjukkan sebagian besar data berada pada nilai positif, sehingga hasil pengelompokan cukup baik meskipun masih terdapat beberapa data di batas antar cluster. Hasil akhir membagi data menjadi tiga kelompok utama dengan karakteristik aktivitas dan risiko yang berbeda.



HASIL CLUSTERING

- **Dataset:** ±50.000 data transaksi
- **Variabel:** transaction_amount, account_balance, risk_score, transaction_distance, daily_transaction_count
- **Jumlah cluster optimal:** K = 3 (Elbow Method)
- **Metode:** K-Means & Hierarchical Clustering (dendrogram)
- **Evaluasi:** Silhouette Score (mayoritas bernilai positif)

Hasil cluster:

- **Cluster 1:** aktivitas rendah, risiko rendah
- **Cluster 2:** aktivitas sedang, risiko sedang
- **Cluster 3:** aktivitas tinggi, risiko tinggi

Visualisasi: Scatter Plot menunjukkan pemisahan cluster cukup jelas meskipun masih ada overlap





SINTESIS TERINTEGRASI



Ketiga pendekatan analisis menunjukkan pola yang sama pada data transaksi, di mana variabel seperti nilai transaksi, waktu, dan aktivitas pengguna menjadi faktor utama dalam membentuk pola tersebut. **Classification** digunakan untuk **membedakan transaksi fraud dan non-fraud**, **regression** menjelaskan **faktor yang mempengaruhi perubahan nilai transaksi**, sedangkan **clustering** membagi data ke dalam kelompok berdasarkan kemiripan karakteristik. Hasil clustering menunjukkan tiga kelompok utama, yaitu aktivitas rendah, sedang, dan tinggi, yang mencerminkan perbedaan perilaku pengguna dalam sistem. Kelompok dengan aktivitas rendah memiliki pola yang stabil, sedangkan kelompok dengan aktivitas tinggi menunjukkan potensi risiko yang lebih besar.

Penggabungan ketiga analisis **memberikan gambaran yang lebih lengkap mengenai pola transaksi dan perubahan perilaku pengguna**. Pola transaksi yang stabil dapat diproses secara normal, sedangkan transaksi dengan perubahan nilai atau aktivitas yang tidak biasa dapat menjadi fokus pengawasan. Informasi ini membantu meningkatkan efektivitas deteksi fraud, mendukung pengambilan keputusan, serta memperkuat proses pengendalian dan audit dalam pengelolaan transaksi keuangan.



KESIMPULAN & IMPLIKASI

Analisis terhadap 50.000 data transaksi menggunakan Orange Data Mining menghasilkan pemahaman yang terintegrasi melalui classification, regression, dan clustering. Model terbaik pada klasifikasi adalah Ensemble Stacking dengan AUC 0,967, akurasi 90,6%, dan F1-Score 0,904, dengan variabel penting Failed_Transaction_Count_7d dan Risk_Score. Analisis regresi menunjukkan R^2 sebesar 0,408 sehingga pola data tidak sepenuhnya linear, sedangkan clustering membentuk 3 kelompok pengguna, yaitu risiko rendah, sedang, dan tinggi, dengan kelompok risiko tinggi menjadi fokus utama pengawasan. Pengembangan selanjutnya dapat menggunakan algoritma seperti XGBoost atau LightGBM serta teknik SMOTE untuk meningkatkan deteksi fraud, ditambah pemanfaatan fitur waktu dan data yang lebih beragam. Dalam implementasi, aturan seperti Failed_Transaction_Count_7d > 3 dan Risk_Score > 0,85 dapat digunakan sebagai dasar kebijakan, serta hasil clustering dapat dimanfaatkan untuk segmentasi pengguna dan peningkatan efektivitas monitoring transaksi.



THANK YOU >>>>

