



ANALISIS BIG DATA UNTUK BISNIS - B

Presented By :
KELOMPOK 1

ANALISIS PREDIKSI CUSTOMER CHURN DAN RETENTION PADA E-COMMERCE

Anggota Kelompok:

- | | |
|----------------------------|------------|
| 1. Dinda Febia | 2310112015 |
| 2. Benedita Oktavia Agatha | 2310112057 |
| 3. Alodia Dahana | 2310112185 |

Dosen Pengampu:

Dr. Donny Maha Putra, S.Kom., M.Ak



PENJELASAN DATASET

Perkembangan industri semakin ketat semenjak munculnya e-commerce yang memberikan kemudahan bagi para penggunanya. Namun masalahnya, pelanggan mudah berpindah dari satu platform ke platform lainnya jika mereka merasa kurang puas baik dari segi pelayanan, harga, atau *experience* dalam menggunakan aplikasi. Dari sini lah masalah ecommerce, yaitu *customer churn*. Untuk mengurangi *customer churn*, perusahaan mencoba untuk memahami pola perilaku pelanggan.

Data set **e-commerce customer churn** menyediakan tanda-tanda awal pelanggan yang bisa berpotensi menjadi *churn* untuk diidentifikasi e-commerce untuk diolah sehingga e-commerce bisa menjaga loyalitas dan menjadi pilihan pelanggan.



TINJAUAN TEORI

Data Mining

Sering dikenal dengan *Knowledge Discovery Database* (KDD), Merupakan proses penyerapan pengetahuan dan cara menemukan pola tersembunyi dari sekumpulan data besar. Data mining mencakup pengumpulan serta pemanfaatan data historis untuk mengidentifikasi keteraturan dan hubungan antarvariabel dalam dataset.

Orange Data Mining

Perangkat lunak berbasis open source yang dibuat untuk mempermudah pengguna dalam menganalisis data yang besar.

Analisis *Classification*

Teknik pengelompokan data ke dalam kategori tertentu berdasarkan fitur yang dimiliki untuk memprediksi kelas dari data baru secara akurat sesuai karakteristik yang telah dipelajari.

1. *K-Nearest Neighbor* (k-NN)

Melakukan klasifikasi objek dalam data berdasarkan jarak kedekatannya.

2. *Decision Tree*

Menampilkan hasil perhitungan dalam bentuk pohon keputusan yang mudah dipahami.

3. *Random Forest*

Kumpulan dari decision tree yang digabungkan untuk mendapat model yang lebih akurat.

Analisis *Regression*

Metode statistik untuk memperkirakan nilai kontinu dengan mengidentifikasi hubungan linear maupun non-linear di antara berbagai variabel.

1. *Linear Regression*

Salah satu metode statistik yang memberikan hasil akhir berupa prediksi dari analisis nilai numerik dari data dengan melakukan pengembangan hubungan matematis antarvariabel.

2. *Random Forest*

Algoritma *ensemble learning* yang cara kerjanya dengan menggabungkan *decision tree* untuk mendapatkan hasil prediksi yang lebih akurat.

Analisis *Clustering*

Metode analisis data yang digunakan untuk mengelompokkan objek-objek atau data yang mempunyai karakteristik yang sama.

1. *K-Means Clustering*

Algoritma pengklasteran dengan membagikan kumpulan data berdasarkan atribut yang ada ke dalam jumlah kelompok yang ditentukan.

2. *Hierarchical Clustering*

Teknik pengelompokan data dalam *machine learning* yang membentuk hirarki berlapis dari *cluster* yang biasanya divisualisasikan dalam melalui pendekatan *agglomerative* dan pendekatan *divisive*.



EXPLORATORY DATA ANALYSIS DAN DATA PREPARATION

Penelitian ini menggunakan dataset customer churn e-commerce yang terdiri atas 5000 baris data dan 20 kolom variabel yang terbagi atas data numerik seperti tenure, city tier, warehouse to home, hour spend on app, number of device registered, satisfaction score, number of address, complain, order amount hike from last year, coupon used, order count, day since last order, cashback amount dan data kategorikal seperti gender, preferred payment mode, preferred order cat, marital status, preferred login device. Setiap variabel menggambarkan karakteristik yang berkaitan dengan kemungkinan pelanggan berhenti menggunakan layanan (Churn). Variabel-variabel ini lah yang akan digunakan ke dalam tiga model yaitu classification, regression, dan clustering.

Data Preparation:

- **Identifikasi dataset awal**

Ditemukan beberapa permasalahan yaitu *missing value*. Beberapa variabel seperti Variabel *gender*, *preferred login device*, *preferred payment mode*, dan *preferred order category* masih berbentuk kategorikal. Pada model seperti *KNN*, *Linear Regression*, dan *K-Means* data kategorikal ini memerlukan perubahan menjadi data numerik untuk bisa diproses oleh model.

- **Penanganan missing value**

Missing value ini perlu diperbaiki karena kekosongan data pada beberapa variabel menyebabkan model tidak dapat difungsikan. Dalam penelitian ini untuk mengisi data yang kosong digunakan *widget impute* pada *orange data mining*, dengan metode *average/Most Frequent*.


- **Preprocess data**

Preprocess dilakukan agar skala antar variabel numerik menjadi lebih seragam dan setiap variabel memberikan kontribusi yang sama dalam pemodelan. Pada *preprocess* ini dataset menggunakan metode *standardize* pada *normalize features*.




CLASSIFICATION

K-Nearest Neighbor



Decision Tree





CLASSIFICATION

Random Forest



Decision Tree





HASIL ANALISIS CLASSIFICATION

Show performance scores							Target class:	1
Model	AUC	CA	F1	Prec	Recall	MCC		
kNN	0.955	0.919	0.722	0.877	0.613	0.691		

Model kNN dengan target kelas *churn* (1) memperoleh hasil AUC 0,955 berarti kemampuan model dalam membedakan kelas sangat baik, CA atau nilai *accuracy* 0,919 berarti sebagian besar data berhasil diprediksi dengan benar, *precision* 0,877 menunjukkan kalau prediksi *churn* yang dihasilkan model cukup akurat. Namun di sini *recall* hanya 0.613 ini nunjukin kalo model belum mampu mendeteksi seluruh *customer churn* secara optimal.


Berdasarkan workflow secara keseluruhan, widget test and score menunjukkan bahwa dari ketiga model, adaboost merupakan model yang paling baik dibandingkan model tree dan random forest. Model adaboost memiliki accuracy 0,964, F1 0,964, Precision 0,965, recall 0,964 dan MCC 0.875 angka-angka ini lebih tinggi dibanding 2 model lain.

Evaluation results for target (None, show average over classes)						
Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.879	0.916	0.910	0.914	0.916	0.678
Random Forest	0.988	0.959	0.958	0.959	0.959	0.851
AdaBoost	0.943	0.964	0.964	0.965	0.964	0.875




REGRESSION

Linear Regression:



Random Forest Regression (menambahkan dari model *linear regression*):






HASIL ANALISIS


Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Random Forest	0.070	0.264	0.142	inf	83.043	0.514
Gradient Boosting	0.076	0.275	0.170	inf	177.600	0.472
Linear Regression	0.107	0.327	0.246	inf	181.712	0.257

Random Forest terbukti menjadi model prediksi terbaik dan paling akurat dibandingkan Gradient Boosting dan Linear Regression. Ditunjukkan dari nilai R2 tertinggi sebesar 0,514 (51,4%) yang berarti memiliki kemampuan memprediksi paling kuat, serta nilai error terkecil pada metrik MAE (0,142) dan RMSE (0,264) yang menunjukkan bahwa selisih antara prediksi dan data asli sangat minim. Metrik MAPE tidak dapat digunakan sebagai acuan karena ada data yang nilainya nol.




Visualisasi menggunakan Random Forest menunjukkan bahwa Tenure memiliki korelasi negatif terhadap potensi churn, di mana semakin lama masa langganan (terutama di atas 20 bulan), risiko churn

semakin menurun dan cenderung stabil di angka nol. Meskipun risiko tetap ada pada masa langganan menengah, model ini memberikan prediksi yang realistis dengan rentang probabilitas 0–1 yang terukur secara konsisten.



Hasil yang diberikan oleh random forest lebih bagus karena lebih sesuai perbandingannya. Maksudnya, jumlah pelanggan yang complain dan melakukan churn setelahnya sesuai dengan normalnya. Meskipun, tetap ada juga pelanggan yang tidak complain namun memutuskan churn.




Hasil visualisasi lebih realistis dibanding linear regression karena memberikan hasil prediksi di rentang 0–1. Plot yang tersebar menunjukkan kalau pelanggan yang baru menggunakan e-commerce justru banyak yang langsung melakukan churn. Mungkin saja pelanggan-pelanggan yang langsung melakukan churn

ketika selesai menggunakan e-commerce karena hanya mengincar diskon atau promo yang ada. Ini bisa jadi masukan untuk perusahaan agar memberikan diskon atau promo tambahan kepada pelanggan.




CLUSTERING

k-Means Clustering




Hierarchical Clustering






HASIL ANALISIS

Elbow Method dan Silhouette Score



Penggunaan elbow method dalam k-Means analisis dengan cara melihat kenaikan atau penurunan nilai ketika cluster ditambahkan. Penurunan terbanyak ada pada K2 ke K3 (0,0037). Untuk Silhouette Score, kita memilih score yang mendekati 1 yaitu K2. Sebenarnya, angka ini juga masih terbilang rendah karena nilai cluster yang bagus itu ada di angka 0,7 - 1. Hal ini bisa dikarenakan datanya itu mirip-mirip, selain itu datanya juga masih overlap

Scatter Plot




Di scatter plot ini sudah terlihat 2 cluster yaitu ada di C1 dan C2. Yang di mana di sini kita memakai X untuk order count dan Y untuk cashback amount. C1 menandakan customer yang aktif menggunakan e-commercenya hal ini bisa dilihat makin banyak ada di kanan (order count tinggi) dengan atas (cashback amount). Untuk C2, ketika cashback rendah (kiri-bawah), maka order countnya juga rendah.



HASIL ANALISIS

Silhouette Plot



Nilai dari silhouette plot masih >0 , walaupun sangat mendekati 0, ini artinya datanya udah bisa diidentifikasi sesuai clusternya (C1 dan C2) tapi memang belum benar-benar terpisah karena datanya mirip. Untuk C1, masih ada yang nilainya negatif karena datanya lebih masuk ke C2. Di sini clustering udah terlihat antara C1 dan C2 walaupun masih ada data yang salah masuk cluster (C1 <0)

Hierarchical Clustering



Dari analisa hierarki yang berasal dari dendrogram ini, jumlah cluster yang dipakai mencapai 14 kluster, dari C1-C14. Untuk kelompok C1, C2, C3, C4, C5, C6, C9, C10, C11, C14 menunjukkan 0 yang berarti pelanggan tidak churn, sementara C7, C8, C12 menunjukkan campuran, ada yang churn ada yang tidak. Untuk C7, C8, dan C12 masih memiliki pembagian cluster yang belum jelas. Nah jarak antara C1 dan C2 ke cluster lainnya juga lumayan jauh yang berarti mereka punya karakteristik yang berbeda, sementara C3-C14 memiliki karakteristik yang sama dikarenakan jaraknya berdekatan.



SINTESIS TERINTEGRASI

Analisis berdasarkan classification, regression, dan clustering menunjukkan ada konsistensi data yang kuat mengenai faktor-faktor pendorong customer churn. Dari ketiga metode mendapat hasil bahwa variabel complain, tenure, dan day since last order merupakan faktor yang paling memengaruhi pelanggan untuk churn. Random Forest menjadi fitur penting karena mampu memprediksi dengan lebih baik dan akurat dibandingkan teknik lainnya pada analisis classification dan regression. Sementara itu, visualisasi data melalui scatter plot memperjelas pola persebaran data secara terukur sehingga memudahkan proses identifikasi hubungan antar variabel secara lebih realistis pada analisis regression dan clustering.

Selanjutnya, analisis clustering berhasil mengelompokkan karakteristik pelanggan meskipun terdapat memiliki nilai silhouette score yang kecil. Ditemukan kecenderungan yang jelas di mana pelanggan pada cluster 1 memiliki loyalitas tinggi karena cenderung mengarah ke order count dan cashback amount yang tinggi. Sebaliknya, melalui analisis hierarki yang menggunakan target churn secara spesifik, perusahaan dapat mengidentifikasi kelompok pelanggan yang aman (C1–C6) serta mendeteksi kelompok "campuran" yang berisiko (C7, C8, C12), di mana masa langganan di atas 20 bulan ditemukan sebagai titik aman di mana risiko churn menurun secara drastis.

Kami merekomendasikan diadakannya perbaikan untuk variabel yang berpengaruh, seperti menyelesaikan complain dengan cepat, memberikan diskon, promo, atau layanan tambahan dengan capaian target tertentu, pemberian cashback untuk pelanggan yang pasif, dan memunculkan notifikasi diskon, promo, atau layanan tambahan.

KESIMPULAN

Berdasarkan analisis yang telah dilakukan dengan menggunakan analisis classification, regression, dan clustering terkait ecommerce customer churn bisa dilakukan melalui data mining. Dari analisis classification, AdaBoost menjadi hasil analisis terbaik dibanding decision tree dan random forest dengan nilai accuracy sebesar 0,964, F1 0,964, precision 0,965, recall 0,964, dan MCC 0,875. Pada analisis regression, yang paling bagus analisisnya ditunjukkan oleh random forest regression dengan nilai R^2 sebesar 0,514, MAE 0,142, dan RMSE 0,264. Lalu di analisis clustering, dengan k-Means jumlah cluster optimal yang diperoleh adalah $K = 2$ dengan silhouette score 0,124. Walaupun nilai silhouette score ini masih terbilang rendah karena tinggi nya berada di nilai 0,7-1. Tetapi masih bisa membandingkan menjadi 2 cluster. Secara keseluruhan, ketiga hasil analisis menunjukkan bahwa tenure, complain, dan day since last order merupakan fitur yang paling mempengaruhi perilaku churn pelanggan e-commerce. Fitur ini konsisten ditemukan selama hasil analisis yang akan menjadi dasar yang kuat bagi perusahaan untuk mengambil langkah strategis dalam menekan tingkat churn.

SARAN

DMasalah utama yang telah dilihat dalam ketiga analisis itu ada tenure, complaint, dan day since last order. Jadi saran yang bisa diberikan adalah dengan memprioritaskan komplain yang diberikan pelanggan secara cepat dan komunikatif dalam waktu tidak lebih dari satu hari. Lalu, ecommerce bisa membuat program member berdasarkan tenure akibat misalkan berlangganan selama satu sampai enam bulan agar mereka lebih tertarik untuk tetap belanja di ecommerce. Terakhir, ecommerce bisa mengadakan cashback dan penawaran yang personal seperti berdasarkan algoritma pelanggannya.



ANALISIS BIG DATA UNTUK BISNIS - B

Presented By :
Kelompok 1

THANK YOU

Anggota Kelompok:

- | | |
|----------------------------|------------|
| 1. Dinda Febia | 2310112015 |
| 2. Benedita Oktavia Agatha | 2310112057 |
| 3. Alodia Dahana | 2310112185 |

Dosen Pengampu:

Dr. Donny Maha Putra, S.Kom., M.Ak