

Laporan ini disusun guna memenuhi Ujian Tengah Semester (UTS)
mata kuliah Big Data
Lanjutan Semester Genap 2026/2027



Disusun Oleh:

Natasha Alexandra	2310112107
Salma Dwi Alzahra	2310112173
Muhammad Triandhika Bahytaqy	2310112117

Pendahuluan

Dalam proses pemberian kredit, lembaga keuangan sering menghadapi kesulitan dalam menilai apakah seorang nasabah layak menerima pinjaman atau beresiko gagal bayar. Kesalahan dalam pengambilan keputusan dapat menyebabkan kerugian finansial yang signifikan. Oleh karena itu dibutuhkan pendekatan berbasis data mining dan machine learning untuk meningkatkan akurasi dalam analisis risiko kredit

Rumusan Masalah

1. Bagaimana memprediksi apakah pengajuan peminjaman akan disetujui berdasarkan karakteristik peminjam?
2. Apa saja faktor yang mempengaruhi nilai numerik tertentu?
3. Bagaimana mengelompokkan peminjam ke dalam segmen tertentu berdasarkan karakteristik finansial dan demografis?

Tujuan Analisis

1. Menentukan apakah pengajuan pinjaman bisa disetujui dengan melihat karakteristik dari masing-masing peminjam.
2. Mengetahui faktor apa saja yang paling berpengaruh terhadap nilai tertentu, terutama dalam menentukan jumlah pinjaman.
3. Mengelompokkan peminjam ke dalam beberapa segmen berdasarkan kemiripan kondisi finansial dan demografis untuk melihat pola yang terbentuk

METODE EVALUASI



CLASSIFICATION

Algoritma Wajib

1. KNN
2. Decision Tree
3. Random Forest

Optional

1. Naive Bayes
2. AdaBoost

Metrik Evaluasi

1. Accuracy
2. Precision
3. Recall
4. F1-Score
5. ROC-AUC



REGRESSION

Algoritma Wajib

1. Linear Regression
2. Random Forest

Optional

1. Regression Tree
2. Gradient Boosting

Metrik Evaluasi

1. R^2
2. MAE
3. RMSE
4. MAPE



CLUSTERING

Algoritma Wajib

1. K - Means
2. Hierarchial

Optional

1. DBSCAN

Metrik Evaluasi

1. Elbow Method
2. D=Silhouette Score

Deskripsi Dataset

Dataset

- Dataset dalam penelitian ini adalah analisis risiko pinjaman yang merepresentasikan kondisi demografis dan finansial individu. Dataset ini terdiri dari 5,000 baris data yang merepresentasikan kondisi demografis dan finansial dari calon debitur.
- Variabel numerik : age, income, loan amount, credit score, years experience
- Variabel kategorikal: gender, education, dan loan approved.

Variabel Target

- Analisis Classification, variabel target yang digunakan yaitu loan approve menunjukkan status persetujuan pinjaman yaitu 0 = ditolak, 1 = diterima
- Analisis Regression, variabel target yang digunakan yaitu LoanAmount
- Analisis Clustering tidak digunakan variabel target karena metode ini bersifat mengelompokkan data berdasarkan kemiripan dari karakteristik antar data.

Kondisi Data


- Missing Value: Income, Credit Score, dan Education
- Data Tidak Valid: Nilai negatif pada Loan Amount

Data Preparation

Pada tahap ini perlu dilakukan beberapa proses sebelum data dianalisis dikarenakan terdapat missing value dan data yang tidak valid. Pertama, dataset diimpor ke dalam aplikasi Orange. Selanjutnya dilakukan imputasi karena terdapat beberapa data missing value. Setelah itu, dilakukan pembersihan data dengan menghapus nilai yang tidak valid, seperti nilai negatif pada LoanAmount. Kemudian, data dinormalisasi untuk menyamakan skala antar variabel sehingga model dapat bekerja lebih optimal. Terakhir, data dibagi menjadi data training dan testing dengan perbandingan tertentu untuk keperluan evaluasi model.



Workflow



Workflow analisis klasifikasi dimulai dari proses data cleaning dengan menghapus nilai hilang sehingga jumlah data berkurang dari 5000 menjadi 4583 data. Selanjutnya dilakukan pembagian data menggunakan data sampler dengan proporsi 70% training dan 30 % data testing, kemudian dilanjutkan ke tahap preprocessing. Model yang digunakan dalam analisis ini meliputi kNN, Naive Bayes, Decision Tree, AdaBoost, dan Random Forest, yang kemudian dievaluasi menggunakan test and score untuk melihat performa masing-masing model.

Evaluation Matrix

Model	AUC	Accuracy	F1-score	Precision	Recall	MCC
kNN	0.896	0.885	0.882	0.881	0.885	0.672
Naive Bayes	0.931	0.926	0.927	0.928	0.926	0.801
AdaBoost	0.905	0.929	0.929	0.929	0.929	0.806
Random Forest	<u>0.950</u> 👑	0.962	0.961	0.962	0.962	0.894
Decision Tree	0.944	<u>0.968</u> 👑	<u>0.968</u> 👑	<u>0.968</u> 👑	<u>0.968</u> 👑	<u>0.911</u> 👑

Hasil evaluasi menunjukkan bahwa Decision Tree memberikan performa terbaik dengan accuracy, precision, recall, dan F1-score masing-masing sebesar 0,968 dan MCC 0,911, yang artinya model sangat stabil dalam mengklasifikasikan kedua kelas. Sementara itu, model lainnya menunjukkan kualitas klasifikasi masih di bawah Decision Tree, yang mengindikasikan model kurang optimal dalam menangkap pola data. Secara keseluruhan, model berbasis tree lebih efektif dalam memahami pola persetujuan pinjaman dibandingkan model lainnya.



Decision Tree

Menjadi model paling optimal dalam memprediksi Credit Risk karena menunjukkan performa paling konsisten pada seluruh metrik evaluasi.





Evaluasi Model dengan Confusion Matrix

Model kNN

		Predicted		
		0	1	Σ
Actual	0	3286	201	3487
	1	328	768	1096
Σ		3614	969	4583

Model AdaBoost

		Predicted		
		0	1	Σ
Actual	0	3316	171	3487
	1	155	941	1096
Σ		3471	1112	4583

Model Naive Bayes

		Predicted		
		0	1	Σ
Actual	0	3296	191	3487
	1	146	950	1096
Σ		3442	1141	4583

Model Decision Tree


		Predicted		
		0	1	Σ
Actual	0	3448	39	3487
	1	108	988	1096
Σ		3556	1027	4583

Model Random Forest


		Predicted		
		0	1	Σ
Actual	0	3445	42	3487
	1	133	963	1096
Σ		3578	1005	4583


Hasil confusion matrix menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data dengan benar, terlihat dari jumlah prediksi yang tepat pada kelas 0 dan kelas 1 yang cukup tinggi. Namun, masih terdapat kesalahan prediksi berupa false positive, yaitu nasabah yang sebenarnya tidak layak tetapi diprediksi layak, serta *false negative*, yaitu nasabah yang layak namun tidak disetujui.

Evaluasi Model dengan ROC Curve




Hasil ROC Curve menunjukkan bahwa seluruh model memiliki kemampuan yang baik dalam membedakan antara nasabah yang layak dan tidak layak, terlihat dari kurva yang berada di atas garis diagonal. Model seperti Decision Tree dan Random Forest memiliki kurva yang lebih mendekati sudut kiri atas, yang menunjukkan tingkat *True Positive Rate* yang tinggi dengan *False Positive Rate* yang rendah.





Analisis Regression

Workflow



Analisis Evaluasi 5 model

Model	Model	Model	Model	Model
Linear Regression	7853.326	6299.977	170.575	-0.005
Random Forest	8420.307	6762.901	166.547	-0.155
Gradient Boosting	7983.09	6388.217	174.509	-0.038
Decision Tree	10759.725	8666.088	188.623	-0.886


Analisis regression digunakan untuk memprediksi nilai numerik yaitu Loan Amount berdasarkan variabel demografis dan finansial. Matriks yang digunakan:

- Linear Regression
- Random Forest Regression
- Regression Tree
- Gradient Boosting / SVR


Berdasarkan hasil evaluasi 5 model menggunakan metrik RMSE, MAE, MAPE, dan R^2 , model Linear Regression menunjukkan performa yang paling baik diantara model lain karena memiliki nilai MSE sebesar 7853.326 dan MAE sebesar 6299.977 yang lebih kecil dibandingkan model Random Forest, Gradient Boosting, dan Decision Tree. Selain itu, memiliki nilai error atau R^2 yang paling mendekati nol dibandingkan model yang lain yang berarti model linier regression bisa memberikan nilai yang akurat terhadap loan amount.

Analisis Regression


Analisis Predicted vs Actual




Gambar 5.2.1 : Scatter plot
linear regression



Gambar 5.2.2 : Scatter plot
random forest regression




Gambar 5.2.3 : Scatter plot
Tree




Gambar 5.2.4 : Scatter plot
Gradient boosting

Dalam analisis ini seluruh model masih belum mampu menganalisis hubungan antara nilai aktual dan prediksi. Titik-titik tidak mengikuti pola garis diagonal dan masih terkonsentrasi pada rentang tertentu, yang menunjukkan bahwa model belum mampu menangkap variasi data secara akurat.


Residual Plot




Gambar 5.3.1 : Scatter plot
linear regression



Gambar 5.3.2 : Scatter plot
random forest regression



Gambar 5.3.3 : Scatter plot
Tree



Gambar 5.3.4 : Scatter plot
Gradient boosting

Residual plot menunjukkan bahwa pola tidak tersebar secara acak tetapi membentuk pola diagonal yang menandakan adanya kesalahan sistematis pada model. Hal ini berarti model belum mampu menangkap hubungan data dengan baik dan error yang dihasilkan masih cukup besar.

Implementasi variabel paling berpengaruh

Interpretasi menggunakan model Linear Regression karena memiliki koefisien yang besarnya mempengaruhi setiap variabel terhadap Loan Amount. Berdasarkan hasil analisis 3 variabel yaitu:


1. Variabel Education dengan tingkat Master memiliki koefisien 454,554 dan High School dengan koefisien -526,064 yang menunjukkan semakin tinggi tingkat pendidikan akses pinjaman semakin besar.
2. Variabel City memiliki nilai koefisien 328,656 dan -288,257 yang menunjukkan bahwa lokasi mempengaruhi besaran pinjaman.
3. Variabel Age memiliki koefisien sebesar 53,857 yang menunjukkan bahwa semakin tinggi usia, semakin besar kemungkinan nilai pinjaman.

Analisis Clustering

Clustering digunakan untuk mengelompokkan nasabah tanpa menggunakan label. Algoritma yang digunakan meliputi:


1. K-Means
2. Hierarchical Clustering
3. DBSCAN

untuk melihat pola segmentasi dalam data.



K-Means	: Mengelompokkan data berdasarkan kedekatan terhadap titik pusat (centroid)
Hierarchical Clustering	: Membentuk kelompok data secara bertingkat berdasarkan tingkat kemiripan.
DBSCAN	: Mengidentifikasi kelompok berdasarkan kepadatan data serta mendeteksi outlier atau data yang menyimpang

K-Means



Nilai yang mendekati 1 menunjukkan bahwa data sudah terkelompok dengan baik, sedangkan nilai yang mendekati 0 menunjukkan adanya overlap antar cluster.

Pada C1, terdapat variasi nilai yang lebih besar dan beberapa nilai negatif, yang menunjukkan adanya kemungkinan overlap dengan cluster lain.

Sementara itu, cluster C2 dan C3 menunjukkan distribusi yang lebih stabil dan konsisten, sehingga dapat dikatakan memiliki kualitas pengelompokan yang lebih baik


Berdasarkan hasil analisis, jumlah cluster yang digunakan adalah tiga cluster ($k=3$). Pemilihan ini didukung oleh nilai silhouette yang menunjukkan kualitas pengelompokan yang cukup baik, di mana sebagian besar data berada pada nilai positif.

**C1 nilai rata-rata *credit score* 406,092
standar deviasi $\pm 71,73$**


**C2 nilai rata-rata *credit score* 669,471
standar deviasi $\pm 109,70$**

**C3 nilai rata-rata *credit score* 679,732
standar deviasi $\pm 102,40$.**

**ANOVA : 4057,409
signifikansi $p = 0,000$**




Hierarchical Clustering



Hasil hierarchical clustering menunjukkan bahwa Klaster C1 merupakan kelompok yang paling berbeda dan berdiri sendiri dibandingkan klaster lainnya. Sementara itu, Klaster C2 dan C3 memiliki kedekatan karakteristik, sehingga dapat dianggap sebagai dua variasi dari satu kelompok besar.

Pengelompokan ini tidak hanya dipengaruhi oleh satu variabel, tetapi merupakan hasil kombinasi berbagai faktor (multivariat), sehingga meskipun hubungan antara pendapatan dan skor kredit lemah, data tetap dapat tersegmentasi dengan jelas berdasarkan pola karakteristik lainnya.

DBSCAN




Berdasarkan grafik K-distance, ditemukan titik "siku" (elbow point) pada nilai 0.893. Pemilihan nilai epsilon ini dilakukan dengan mengurutkan jarak setiap titik ke tetangga terdekat ke-k ($k=5$). Secara deskriptif, nilai ini merupakan ambang batas optimal yang memisahkan area dengan kepadatan tinggi dari area yang lebih renggang.


Kelompok *noise*
nilai rata-rata *score credit* 557,9

Kelompok inti
nilai rata-rata *score credit* 575,9


signifikansi $p = 0,635$
 $p > 0,05$, maka H_0 gagal ditolak




Scatter Plot



C1 terpisah cukup jelas dari C2 dan C3, terutama pada rentang credit score yang lebih rendah. Namun, terdapat sedikit tumpang tindih antara C2 dan C3, yang menandakan bahwa kedua cluster tersebut memiliki karakteristik yang relatif mirip, khususnya dalam hubungan antara credit score dan income.




- Ketidakterkaitan Finansial: Pendapatan tidak menunjukkan hubungan kuat dengan skor kredit; baik pendapatan tinggi maupun rendah bisa memiliki skor kredit rendah atau tinggi.
- Kepadatan Populasi: Mayoritas data berada pada pendapatan menengah (40.000–70.000), yang menjadi pusat distribusi dengan variasi skor kredit paling besar.



Sebagian besar data berada dalam satu kelompok utama dengan pola yang relatif homogen dan tidak menunjukkan hubungan yang signifikan antara pendapatan dan skor kredit. Namun, terdapat beberapa yang teridentifikasi sebagai noise atau outlier dengan pola yang berbeda, pada kelompok ini terlihat kecenderungan hubungan negatif yang lebih kuat antara pendapatan dan skor kredit.

Interpretasi Persona



C1 nilai rata-rata *credit score* 406,092
standar deviasi $\pm 71,73$

C2 nilai rata-rata *credit score* 669,471
standar deviasi $\pm 109,70$

C3 nilai rata-rata *credit score* 679,732
standar deviasi $\pm 102,40$.

C1 : 38% pengajuan auto-reject

C2 : 32% review terbatas

C3 : 30% instant approval

Cluster 1 (Risiko Kredit Tinggi)

Cluster ini mencakup 38% dari total dataset (sekitar 1.900 nasabah dari 5.000 total data) dengan karakteristik credit score rata-rata 406 ± 72 , merupakan nilai terendah dibandingkan cluster lainnya. Persentase persetujuan pinjaman pada cluster ini hanya 28%, menunjukkan tingkat penolakan yang sangat tinggi (72%)

Cluster 2 (Risiko Kredit Sedang)

Cluster kedua terdiri dari 32% dataset (sekitar 1.600 nasabah) dengan credit score rata-rata 669, menunjukkan profil finansial yang lebih baik dibandingkan Cluster 1. Berdasarkan pola peningkatan credit score dan persentase persetujuan yang lebih tinggi (diperkirakan $\sim 67\%$), cluster ini merepresentasikan nasabah yang layak mendapat persetujuan dengan batasan tertentu dan premi risiko tambahan 1-2%.

Cluster 3 (Risiko Kredit Rendah)

Cluster terakhir mencakup 30% dataset (sekitar 1.500 nasabah) dengan credit score tertinggi 679, menunjukkan profil keuangan paling sehat. Dengan tingkat persetujuan pinjaman yang jauh lebih tinggi ($\sim 92\%$)

SINTESIS DAN IMPLIKASI

Analisis menunjukkan bahwa classification, regression, dan clustering saling melengkapi dalam memahami risiko kredit, dan tidak bisa berdiri sendiri.

Sintesis Terintegrasi

Classification (Decision Tree) paling efektif dalam memprediksi persetujuan pinjaman, dengan faktor utama:

- CreditScore
- EmploymentType
- Income

Regression masih terbatas (R^2 -0.005), sehingga:

- Prediksi nominal pinjaman belum optimal
- Perlu faktor tambahan di luar dataset


Clustering memperjelas segmentasi risiko:

- Low score → risiko tinggi (cenderung ditolak)
- High score → risiko rendah (cenderung disetujui)

Implikasi

- Keputusan kredit lebih akurat jika berbasis data
- Nasabah perlu diperlakukan berbeda sesuai risiko
- Mendukung pengelolaan risiko & pencadangan akuntansi

Hierarchical Clustering



Hasil hierarchical clustering menunjukkan bahwa Klaster C1 merupakan kelompok yang paling berbeda dan berdiri sendiri dibandingkan klaster lainnya. Sementara itu, Klaster C2 dan C3 memiliki kedekatan karakteristik, sehingga dapat dianggap sebagai dua variasi dari satu kelompok besar.

Pengelompokan ini tidak hanya dipengaruhi oleh satu variabel, tetapi merupakan hasil kombinasi berbagai faktor (multivariat), sehingga meskipun hubungan antara pendapatan dan skor kredit lemah, data tetap dapat tersegmentasi dengan jelas berdasarkan pola karakteristik lainnya.