



DIKTISAINTEK
BERDAMPAK



Kementerian Pendidikan Tinggi,
Sains, dan Teknologi

Project

Big Data Analysis

Presented by

Kelompok B

Dr. J

2310112227

2310112027

2310112093



Latar Belakang

Tingginya tingkat turnover karyawan, yang di Indonesia mencapai 12-18%, menimbulkan kerugian signifikan bagi perusahaan, baik dari sisi finansial maupun hilangnya pengetahuan spesifik. Biaya rekrutmen dan pelatihan yang dapat mencapai 200% dari gaji tahunan sering kali diremehkan karena perusahaan cenderung baru menyadari masalah setelah karyawan mengundurkan diri. Oleh karena itu, diperlukan analisis data yang sistematis untuk mengidentifikasi pola penyebab pengunduran diri, seperti masalah kompensasi, beban kerja, atau lingkungan kerja.

Proyek ini menggunakan dataset IBM HR Analytics melalui aplikasi Orange Data Mining dengan menerapkan teknik klasifikasi, regresi, dan klasterisasi untuk memprediksi risiko attrition serta memodelkan faktor penentu gaji. Pendekatan ini sangat relevan bagi praktik akuntansi di Indonesia, terutama dalam meningkatkan efisiensi biaya personalia dan pengungkapan risiko operasional sesuai dengan standar PSAK terbaru. Analisis ini memberikan rekomendasi berbasis bukti konkret untuk membantu perusahaan mengambil keputusan strategis yang lebih tepat.

Rumusan Masalah

Faktor apa saja yang paling berpengaruh dalam memprediksi attrition karyawan dan algoritma prediksi terbaik

Variable apa yang paling signifikan dalam mempengaruhi besaran monthly income dan keakuratan model regresi

Segmen karyawan apa yang terbentuk ketika diproses dengan K-Means dan Hierarchical Clustering



Tinjauan Pustaka

Metode Analisis

Pendekatan: Kuantitatif

Dataset: IBM HR Analytics Employee Attrition & Performance

Software Olah Data: Orange Data Mining



Employee HR Analytics

Cara perusahaan membaca data karyawan untuk membuat keputusan manajerial. Yanuarty menyebut bahwa JHR analytics memanfaatkan data SDM untuk membuat keputusan yang berbasis logic dan statistik



Analisis Prediktif

Analisis prediktif membantu HR untuk memperkirakan apa yang mungkin terjadi di masa depan



Employee Attrition

Kondisi dimana jumlah karyawan berkurang. Tingkat attrition yang tinggi dapat merugikan perusahaan dari aspek financial dan pengalaman & pengetahuan karyawan (Setiawan et al., 2020).



Teknik Analisis dalam HR Analytics

Teknik klasifikasi digunakan untuk memprediksi kemungkinan keluar masuknya karyawan. Regresi digunakan untuk melihat hubungan antar variabel. Clustering digunakan untuk mengelompokkan karyawan berdasarkan kemiripan data

Dataset

IBM HR Analytics Employee
Attrition & Performance

Target
Categoric

Employee Attrition

Target
Numeric

Monthly Income

Fitur
Numeric

Age, Daily Rate, Distance from Home, Education, Employee Number, Environment Satisfaction, Hourly Rate, Job Involvement, Job Level, Job Satisfaction, Monthly Rate, Number of Companies Worked for, Percent Salary Hike, Relationship Satisfaction, Standard Hours, Stock Option Level, Total Working Years, Training Times Last Year, Work Life Balance, Years at Company, Years in Current Role, Years Since Last Promotion, Years With urrent Manager

Total Instances:


1,470

Features:

35

Exploratory Data Analysis

Scatter Plot Age vs Monthly Income



Main Points EDA

Rank & Correlations

Faktor utama attrition berupa Overtime dengan X^2 63,845.
Job Role memiliki info gain pada 0,044

Feature Statistics

Data Standard Hours tidak ada variasi
Mean Monthly Income 6.502, Median 4.919


Distribution

Frekuensi attrition sering terjadi pada karyawan dengan monthly income rendah. Distribusi eksponensial Yes pada angka 0,802

Pivot Table

Selisih gaji terbesar berada di department Human Resources (0,771), diikuti oleh R&D (0,536) dan Sales (0,281)

Analisis Classification



Main Points Classifications

Variabel Target
Attrition

Metode Classification

- K-Nearest Neighbour
- Decision Tree
- Random Forest
- Naive Bayes

Tujuan Analisis

Tujuan utama dari analisis klasifikasi dalam teks tersebut adalah untuk memprediksi dan mengidentifikasi karyawan yang berisiko mengundurkan diri (attrition) secara proaktif sebelum hal itu terjadi. Dengan memanfaatkan variabel target biner (Yes/No), analisis ini bertujuan memberikan wawasan bagi manajemen SDM untuk mengantisipasi kehilangan talenta. Selain itu, proyek ini berfokus pada pembangunan model yang reliabel melalui penggunaan metrik evaluasi mendalam (seperti AUC, MCC, dan Recall) guna mengatasi tantangan ketimpangan data (class imbalance), sehingga model tetap akurat dalam mendeteksi kelompok minoritas yang justru menjadi fokus utama penelitian.

Decision Tree

Analisis Classification

Meskipun mencatatkan nilai AUC terendah (0,569) yang menunjukkan kemampuan prediksi hampir menyerupai tebakan acak, model Decision Tree tetap memberikan wawasan interpretatif yang signifikan melalui identifikasi segmen risiko melalui Tree Viewer. Model ini mendeteksi bahwa kombinasi usia muda (<34 tahun) dan beban kerja lembur merupakan profil paling rentan terhadap pengunduran diri dengan tingkat confidence 54%. Sebaliknya, karyawan senior di atas 34 tahun yang menjabat sebagai Manager atau Research Scientist menunjukkan stabilitas kerja maksimal dengan tingkat confidence 100%, membuktikan keunggulan algoritma ini dalam memetakan profil karyawan secara spesifik di tengah keterbatasan performa metriknya secara keseluruhan.

		Predicted		Σ
		No	Yes	
Actual	No	87.2 %	61.4 %	1233
	Yes	12.8 %	38.6 %	237
Σ		1281	189	1470

K-Nearest Neighbours

		Predicted		Σ
		No	Yes	
Actual	No	84.9 %	13.6 %	1233
	Yes	15.1 %	86.4 %	237
Σ		1448	22	1470

Model KNN menunjukkan karakteristik yang sangat konservatif dalam mendeteksi attrition, di mana algoritma ini jarang memberikan prediksi "Yes" namun memiliki tingkat kebenaran yang tinggi saat melakukannya. Meski mencatatkan akurasi (CA) yang tergolong tinggi sebesar 85,0%, performa pada metrik AUC (0,710) dan MCC (0,235) menunjukkan bahwa KNN kurang optimal dalam membedakan antara karyawan yang bertahan dan yang keluar secara seimbang. Hal ini menandakan bahwa model ini cenderung kesulitan menangkap pola pada kelompok minoritas dalam kondisi data yang tidak seimbang (class imbalance).

Naive Bayes

		Predicted		Σ
		No	Yes	
Actual	No	90.7 %	59.7 %	1233
	Yes	9.3 %	40.3 %	237
Σ		1145	325	1470

Model Naïve Bayes menunjukkan kemampuan deteksi attrition yang paling luas dengan menangkap 40,3% kasus pengunduran diri, meskipun konsekuensinya memiliki jumlah false positive yang cukup tinggi. Walaupun mencatatkan akurasi terendah (79,6%), model ini justru paling unggul dalam menangani ketimpangan data melalui nilai AUC (0,786) dan MCC (0,350) tertinggi dibandingkan algoritma lainnya. Hal ini membuktikan bahwa Naïve Bayes memiliki reliabilitas yang lebih baik dalam membedakan antara karyawan yang bertahan dan yang keluar secara adil, menjadikannya model yang paling efektif untuk mengidentifikasi kelompok minoritas dalam dataset ini.

Analisis Classification

Random Forest

		Predicted		
		No	Yes	Σ
Actual	No	86.9 %	29.5 %	1233
	Yes	13.1 %	70.5 %	237
Σ		1392	78	1470

Model Random Forest menunjukkan keseimbangan performa yang lebih baik dalam menangani kedua kelas dibandingkan KNN dan Decision Tree, tercermin dari nilai F1 tertinggi (0,813) dan MCC yang lebih unggul (0,272). Dengan tingkat deteksi kasus attrition sebesar 60,6% dan akurasi (CA) mencapai 84,9%, model ini terbukti lebih stabil dan moderat dalam mengklasifikasikan karyawan yang bertahan maupun yang keluar secara simultan. Nilai AUC sebesar 0,735 menegaskan kemampuan model dalam membedakan kedua kelompok tersebut dengan reliabilitas yang cukup kuat di tengah kondisi data yang tidak seimbang.

Evaluation results for target (None, show average over classes)						
Model	AUC	CA	F1	Prec	Recall	MCC
kNN (1)	0.710	0.850	0.793	0.852	0.850	0.235
Random Forest (1)	0.763	0.850	0.819	0.822	0.850	0.293
Naive Bayes (1)	0.786	0.796	0.808	0.826	0.796	0.350
Tree (1)	0.569	0.810	0.801	0.794	0.810	0.235


Compare models by: Area under ROC curve				
	kNN (1)	Random Forest (...)	Naive Bayes (1)	Tree (1)
kNN (1)		0.039	0.018	0.998
Random Forest (1)	0.961		0.095	0.997
Naive Bayes (1)	0.982	0.905		0.999
Tree (1)	0.002	0.003	0.001	

Evaluasi menggunakan stratified 5-fold cross-validation menunjukkan bahwa meskipun kNN dan Random Forest memiliki akurasi tertinggi (sekitar 85%), Naïve Bayes justru lebih unggul dalam membedakan kelas karyawan dengan nilai AUC (0,786) dan MCC (0,350) terbaik meskipun secara total akurasinya paling rendah. Random Forest menawarkan keseimbangan prediksi antar kelas yang lebih stabil melalui nilai F1 yang lebih tinggi, sementara Decision Tree menunjukkan performa paling lemah dengan kemampuan generalisasi yang sangat terbatas karena nilai AUC-nya mendekati tebakan acak.

KESIMPULAN

Naïve Bayes terpilih sebagai model terbaik karena keunggulannya dalam menangani ketimpangan data, sebagaimana dibuktikan oleh nilai AUC (0,786) dan MCC (0,350) tertinggi dibandingkan algoritma lainnya. Dari perspektif operasional HR, model ini berfungsi sebagai sistem peringatan dini (early warning system) yang jauh lebih efektif karena mampu mengidentifikasi cakupan potensi pengunduran diri yang lebih luas untuk ditindaklanjuti melalui program retensi. Keputusan ini didasari pada prinsip manajemen risiko di mana biaya penanganan false positive dinilai jauh lebih efisien dibandingkan potensi kerugian finansial akibat kehilangan talenta kunci yang gagal terdeteksi oleh sistem.

Analisis Regression



Main Points Regression

Variabel Target
Monthly Income

Variabel Analysis

- Age
- Job Level
- Total Working Years
- Years at Company
- Years in Current Role

Metode Regresi
Linear Regression


Random Forest Regression

Tujuan Regresi

Analisis ini bertujuan mengidentifikasi faktor dominan yang memengaruhi gaji dengan membandingkan efektivitas model Linear Regression dan Random Forest Regression melalui aplikasi Orange Data Mining. Dengan mengevaluasi metrik R^2 untuk mengukur kemampuan model dalam menjelaskan variasi data, serta MAE, RMSE, dan MAPE untuk meninjau besaran deviasi prediksi, penelitian ini tidak hanya menentukan algoritma dengan performa terbaik, tetapi juga memberikan validasi konkret mengenai tingkat presisi hasil estimasi terhadap realitas finansial yang sebenarnya.

Analisis Regression


Linear Regression



Analisis scatter plot menunjukkan korelasi positif yang sangat kuat ($r = 0,95$) antara Job Level dan Monthly Income, di mana kenaikan jabatan berbanding lurus dengan peningkatan pendapatan. Meskipun model Linear Regression menunjukkan akurasi yang tinggi ($R^2 = 0,898$), adanya variasi gaji pada level jabatan yang sama mengindikasikan bahwa jabatan bukanlah satu-satunya faktor penentu kompensasi. Hal ini tecermin pada nilai MAPE sebesar 22%, yang menandakan adanya variabel kompleks lain yang memengaruhi besaran gaji namun belum sepenuhnya tertangkap oleh model.

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	2198179	1482,626	1127,817	22,588	0,898

Random Forest Regression




Analisis scatter plot antara hasil prediksi Random Forest dan Total Working Years menunjukkan korelasi positif ($r = 0,79$), di mana peningkatan pengalaman kerja selaras dengan kenaikan estimasi gaji. Berbeda dengan variabel Job Level yang bersifat linear, pola persebaran data ini lebih beragam dan tidak sepenuhnya linear, yang mencerminkan kemampuan model dalam menangkap segmentasi data berdasarkan tingkat pengalaman. Meskipun masa kerja merupakan faktor signifikan, adanya variasi dalam kelompok-kelompok tersebut mempertegas bahwa penentuan gaji tetap dipengaruhi oleh kombinasi faktor-faktor lain di luar pengalaman kerja.

Model	MSE	RMSE	MAE	MAPE	R2
ABC	1888037,211	1374,059	1009,729	20,149	0,912

KESIMPULAN

Perbandingan performa antara Linear Regression ($R^2 = 0,898$) dan Random Forest Regression ($R^2 = 0,912$) menunjukkan bahwa Job Level merupakan prediktor utama pendapatan, disusul oleh Total Working Years. Meskipun model Random Forest terbukti lebih unggul dengan nilai MAPE terendah sebesar 20%, adanya variasi gaji pada kelompok jabatan yang sama mengindikasikan pengaruh faktor eksternal, seperti performa individu atau kebijakan perusahaan yang belum sepenuhnya tertangkap oleh model. Ketidakseragaman sistem kompensasi dalam kelompok homogen ini perlu menjadi perhatian strategis bagi manajemen, karena berpotensi menurunkan kepuasan karyawan dan memicu peningkatan risiko pengunduran diri.

Analisis Clustering



Main Points Clustering

Variabel Analysis

- Age
- Job Level
- Total Working Years
- Years at Company
- Years in Current Role
- Monthly Income

Metode Analisis

- K-Means Clustering
- Hierarchical Clustering
- DBSCAN


Jumlah Cluster

K-Means: 2 Cluster berdasarkan hasil Elbow Method dan Silhouette Score
 Hierarchical Clustering: 3 Cluster
 DBSCAN: 2 Cluster, Epsilon 1,076




Analisis Clustering

K-Means Clustering




Analisis scatter plot antara total masa kerja dan skor silhouette menunjukkan bahwa klaster C2 merepresentasikan kelompok senior sebagai tulang punggung organisasi dengan tren positif yang kuat ($r=0,71$). Sebaliknya, klaster C1 menunjukkan tren negatif ($r=-0,67$) yang didominasi oleh karyawan dengan masa kerja singkat, menandakan bahwa kelompok tersebut masih membutuhkan kepastian pengembangan karier karena mayoritas baru memulai perjalanannya di perusahaan.

Hierarchical Clustering



Visualisasi scatter plot hasil hierarchical clustering mengidentifikasi tiga kategori karyawan: C1 sebagai kelompok berpengalaman namun dinamis dengan korelasi rendah ($r = 0,25$); C2 sebagai kelompok menengah dengan jalur karier linear dan korelasi terkuat ($r = 0,51$); serta C3 sebagai kelompok karyawan baru dengan profil homogen dan korelasi paling rendah ($r = 0,17$).

DBSCAN Clustering



Visualisasi scatter plot melalui algoritma DBSCAN dengan parameter epsilon 1,076 berhasil mengidentifikasi dua kelompok stabil tanpa noise, yaitu klaster merah (junior) dan klaster biru (senior). Hasil analisis menunjukkan tren negatif signifikan pada klaster merah ($r = -0,55$) yang merepresentasikan karakteristik karyawan baru, sementara klaster biru menunjukkan korelasi positif ($r = 0,51$) yang menandakan bahwa semakin tinggi tingkat senioritas, semakin kuat pula kesesuaian posisi karyawan di dalam kelompoknya (silhouette score).

KESIMPULAN

Cluster 1: Karyawan Baru, Homogenitas tinggi, berisi demografi muda, masa kerja singkat, dan tingkat pendapatan dibawah rata-rata

Cluster 2: Tingkat pengalaman dan jabatan menengah, jalur karir linear dan stabil

Cluster 3: Kelompok elit dalam perusahaan dengan jabatan tertinggi, pendapatan jauh diatas rata-rata, dan masa kerja yang panjang



Sintesis Terintegrasi

Benang Merah

Integrasi hasil klasifikasi, regresi, dan klasterisasi membuktikan adanya pola yang konsisten: senioritas dan struktur jabatan adalah penentu utama nasib karyawan dalam organisasi. Sementara klasifikasi menyoroti profil risiko pengunduran diri (seperti usia muda dan beban lembur), regresi memvalidasi bahwa nilai ekonomi karyawan (gaji) sangat bergantung pada level jabatan dan masa kerja. Klasterisasi kemudian menyatukan temuan ini dengan memetakan segmentasi nyata antara kelompok junior yang dinamis dan kelompok senior yang menjadi tulang punggung perusahaan.

Perjalanan karier karyawan merupakan benang merah yang menghubungkan kompensasi dengan risiko attrition. Karyawan pada fase awal (junior) cenderung memiliki profil gaji yang lebih rendah dan risiko keluar yang lebih tinggi akibat beban kerja atau ketidakpastian jalur karier. Sebaliknya, senioritas memberikan stabilitas pendapatan namun menuntut pengakuan posisi yang selaras agar loyalitas tetap terjaga. Ketiga pendekatan ini secara kolektif menegaskan bahwa kebijakan manajemen SDM harus berfokus pada transisi karier yang transparan dan sistem kompensasi yang adil untuk meminimalisir risiko kehilangan talenta berharga.

Keterkaitan Cluster dengan Attrition



Integrasi hasil klasifikasi, regresi, dan klasterisasi secara konsisten menunjukkan bahwa perjalanan karier karyawan merupakan benang merah yang menghubungkan tingkat kompensasi dengan risiko attrition. Analisis regresi memvalidasi bahwa level jabatan dan senioritas adalah penentu utama besaran gaji, yang kemudian diperkuat oleh hasil klasterisasi yang memetakan stabilitas kelompok senior berbanding terbalik dengan kerentanan kelompok junior. Temuan klasifikasi melengkapi pola ini dengan mengidentifikasi profil karyawan muda dengan beban kerja lembur sebagai kelompok yang paling berisiko mengundurkan diri, sementara posisi manajerial senior cenderung memiliki loyalitas maksimal. Secara kolektif, temuan ini menegaskan bahwa kebijakan manajemen SDM yang berfokus pada kejelasan jalur karier dan keadilan sistem kompensasi di setiap segmen sangat penting untuk menjaga efisiensi biaya personalia serta stabilitas operasional perusahaan sesuai dengan standar pelaporan terkini.

Rekomendasi Bisnis

Implementasi strategi HR berbasis data mining mencakup pendekatan tersegmentasi: prioritas utama diarahkan pada karyawan junior melalui percepatan jalur karier dan peninjauan beban kerja guna menekan risiko attrition yang tinggi, sementara stabilitas manajemen menengah dijaga melalui rotasi tugas dan program kepemimpinan untuk mencegah stagnasi karier. Bagi kelompok senior, fokus bergeser pada optimalisasi peran strategis dan transfer pengetahuan sebagai bagian dari perencanaan suksesi yang berkelanjutan. Secara sistemis, penggunaan model Naïve Bayes sebagai early warning system memungkinkan divisi HR melakukan intervensi proaktif dan wawancara retensi lebih awal, sebuah langkah preventif yang jauh lebih efisien secara biaya dibandingkan menangani dampak operasional akibat kehilangan talenta kunci yang tidak terdeteksi sejak dini.



Kesimpulan dan Saran

Kesimpulan

Integrasi metode klasifikasi, regresi, dan klasterisasi secara komprehensif membuktikan bahwa fenomena employee attrition merupakan dampak langsung dari ketidakseimbangan antara beban kerja, kompensasi, dan fase karier karyawan. Melalui model Naïve Bayes, variabel kritis seperti lembur dan usia berhasil diidentifikasi sebagai sistem peringatan dini yang sensitif, sementara Random Forest Regression mengonfirmasi stabilitas struktur penggajian yang sangat bergantung pada level jabatan dengan tingkat akurasi R^2 mencapai 0,912. Temuan ini diperkuat oleh analisis klasterisasi yang memetakan dikotomi profil karyawan secara nyata, di mana kelompok junior yang memiliki pengalaman serta kompensasi lebih rendah menjadi titik risiko utama dibandingkan kelompok senior yang cenderung bertahan. Sinergi ketiga pendekatan ini tidak hanya memberikan validasi pola data yang konsisten, tetapi juga menawarkan landasan strategis bagi manajemen dalam merancang kebijakan retensi yang lebih akurat, tepat sasaran, dan berbasis bukti demi menjaga stabilitas operasional perusahaan.

Saran

Perusahaan sebaiknya memprioritaskan intervensi pada karyawan fase awal dengan menyeimbangkan beban lembur, menyesuaikan kompensasi, dan memperkuat jalur mentoring guna menekan angka attrition secara proaktif sebelum menjadi kerugian finansial yang signifikan. Ke depan, transparansi sistem penggajian perlu ditingkatkan untuk mencegah ketidakpuasan sistemik, sementara penelitian selanjutnya disarankan memperluas cakupan variabel pada aspek budaya dan psikologis serta mengeksplorasi algoritma tingkat lanjut seperti model ensemble yang lebih kompleks guna mempertajam akurasi prediksi. Dengan mengintegrasikan kebijakan SDM yang transparan dan analisis data yang presisi, perusahaan tidak hanya sekadar mempertahankan talenta, tetapi juga membangun fondasi organisasi yang lebih sehat dan berdaya saing tinggi.



[CONTACT US](#)

Thank You. Any Questions?

Date

25 April, 2026