



- BIG DATA ANALYTICS -

PROJECT ANALISIS *CUSTOMER PURCHASING BEHAVIOR* MENGGUNAKAN *CLASSIFICATION, REGRESSION, DAN CLUSTERING*

KELOMPOK 04

NAFISA NUR AMALINA-2310112067

MEY SELA SFAGI BR SAGALA-2310112135

MIFTAH AULIYA HAROKY-2310112201



PENDAHULUAN

Customer purchasing behavior mencakup pola pembelian konsumen yang dipengaruhi oleh faktor seperti usia, pendapatan, frekuensi pembelian, dan loyalitas pelanggan. Memahami perilaku ini penting untuk perusahaan dalam merancang strategi pemasaran yang tepat, meningkatkan loyalitas, dan mempertahankan pelanggan. Dengan perkembangan teknologi data mining dan machine learning, perusahaan dapat menggunakan alat seperti Orange Data Mining untuk menganalisis perilaku pelanggan secara interaktif. Melalui metode classification, regression, dan clustering, perusahaan dapat memprediksi pembelian, mengukur loyalitas, dan mengelompokkan pelanggan, yang pada akhirnya membantu meningkatkan strategi pemasaran dan profitabilitas.

Rumusan masalah

Berdasarkan latar belakang yang menjelaskan customer purchasing behavior, maka dibuat rumusan masalah sebagai berikut.

1. Bagaimana hasil analisis classification dalam memprediksi tingkat loyalitas pelanggan berdasarkan data Customer Purchasing Behavior?
2. Bagaimana hasil analisis regression dalam memprediksi jumlah pembelian pelanggan berdasarkan variabel yang memengaruhinya?
3. Bagaimana hasil analisis clustering dalam mengelompokkan pelanggan berdasarkan karakteristik perilaku pembelian mereka?
4. Bagaimana hubungan dan keterkaitan hasil analisis classification, regression, dan clustering dalam menghasilkan strategi bisnis yang lebih efektif?

Tujuan Laporan

Berdasarkan rumusan masalah diatas, maka penelitian ini dilakukan untuk tujuan sebagai berikut.

1. Untuk mengetahui hasil analisis *classification* dalam memprediksi tingkat loyalitas pelanggan berdasarkan data *Customer Purchasing Behavior*.
2. Untuk mengetahui hasil analisis *regression* dalam memprediksi jumlah pembelian pelanggan berdasarkan variabel yang memengaruhinya.
3. Untuk mengetahui hasil analisis *clustering* dalam mengelompokkan pelanggan berdasarkan karakteristik perilaku pembelian mereka.
4. Untuk mengetahui hubungan dan keterkaitan antara hasil analisis *classification*, *regression*, dan *clustering* dalam menghasilkan strategi bisnis yang lebih efektif.


CUSTOMER PURCHASING BEHAVIOR



DESKRIPSI DATASET - Purchasing Customer Behavior

- *Costumer_Id* : identitas unik pelanggan
- *Age* : usia pelanggan
- *Annual_Income* : pendapatan tahunan pelanggan dalam USD
- *Purchase_Amount* : total jumlah pembelian pelanggan dalam USD
- *Purchase_Frequency* : frekuensi pembelian pelanggan dalam satu tahun
- *Region* : wilayah tempat tinggal pelanggan (North, South, East, West)
- *Loyalty_Score* : skor loyalitas pelanggan dengan rentang nilai 0–100

METODE YANG DIGUNAKAN



CLASSIFICATION	REGRESSION	CLUSTERING
K-Nearest Neighbor (KNN)	Linear Regression	K-Means Clustering
Decision Tree	Random Forest Regression	Hierarchical Clustering
Random Forest	Regression Tree	DBSCAN
Naive Bayes	Gradient Boosting	




HASIL ANALISIS CALSSIFICATION



Algoritma K-Nearest Neighbor (KNN)

Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.836	0.654	0.643	0.655	0.654	0.497

AUC mencapai 0,836 (83,6%) menandakan model KNN memiliki kemampuan yang sangat baik dalam membedakan wilayah yang satu dengan lainnya, probabilitas kesalahannya cukup rendah sebesar 16,4%. Accuracy (CA) mencapai angka 0,654 yang artinya sebesar 65,4% data pada remaining data berhasil dapat dilakukan prediksi dengan tepat berdasarkan region asalnya.






Pada hasil analisis *Confusion Matrix*, dari total 214 data yang dilakukan untuk *testing*, total 140 data berhasil diprediksi benar dengan region *South* paling kuat.



HASIL ANALISIS CALSSIFICATION

Algoritma *Decision Tree* dan *Random Forest*



Nilai AUC sebesar 0,903 pada hasil algoritma *Decision Tree* dan 0.917 pada model *Random Forest* menunjukkan kemampuan pengukuran antar kelas model sudah sangat bagus dan dapat memisahkan kategori tanpa tertukar.

Algoritma *Decision Tree* mencapai nilai *Accuracy* (CA) sebesar 0,840 dan *Random Forest* mencapai nilai 0,845 yang menandakan *Random Forest* dapat memprediksi dengan benar sebesar 84,5%


Nilai ROC sebesar 0,898 pada *Random Forest* yang menunjukkan tingkat kepercayaan lebih baik dibandingkan *Decision Tree* sebesar 89,8%. Pada angka 0,102 menunjukkan peluang algoritma *Decision Tree* lebih baik daripada *Random Forest* hanya sebesar 10,2%.

Hasil analisis *Confusion Matrix* algoritma *Decision Tree* dari total 238 data yang dilakukan untuk *testing*, total 200 data berhasil diprediksi benar dengan region *South* paling kuat. Sedangkan pada *Random Forest* data yang berhasil diprediksi sebanyak 201 data dengan region *South* paling kuat juga.


Akurasi algoritma *Random Forest* sedikit lebih bagus dibandingkan *Decision Tree*

HASIL ANALISIS CALSSIFICATION

Algoritma *Naive Bayes*




Hasil dari *Test and Score* menunjukkan nilai AUC sebesar 0,706. Artinya algoritma *Naive Bayes* memiliki kemampuan yang tidak terlalu bagus ketika membedakan antar kelas. Nilai Accuracy (CA) hanya sebesar 0,542, algoritma hanya mampu memprediksi dengan benar hanya 54,2% dari data yang diberikan.



Dari hasil *Confusion Matrix* menunjukkan dari seluruh total 238 data yang digunakan, jumlah data yang berhasil diprediksi sebanyak 129 data. Prediksi *region berhasil* terbanyak adalah *North* dengan 49 data benar.

HASIL ANALISIS CALSSIFICATION

Komparasi Algoritma KNN, *Decision Tree*, *Random Forest* dan *Naive Bayes* Secara Bersamaan



Hasil dari *Test and Score* dalam melakukan analisis secara bersamaan menunjukkan nilai *Accuracy* (CA) terbaik adalah menggunakan algoritma *Random Forest* dengan hasil sebesar 0,849 (84,9%) dan AUC sebesar 0,917. Menunjukkan kemampuan pemisahan kelas yang sangat bagus.

Algoritma KNN dan *Decision Tree* memiliki nilai CA yang sama yaitu 0,840, tapi KNN memiliki AUC yang lebih baik dengan nilai 0,915 dengan diperkuat dari tabel ROC sebesar 0,987 KNN lebih baik daripada *Decision Tree* dalam membedakan suatu kelas.


Dari seluruh algoritma, performa yang paling bawah adalah *Naive Bayes* dengan CA hanya sebesar 0,542 yang mengasumsikan hubungan variabel dalam data memiliki asumsi tidak terdapat hubungan dan memiliki pola mandiri yang kuat.

HASIL ANALISIS REGRESSION


Workflow dan Test and Score

Workflow Model Regresi


Linear Regression




Random Forest Regression



Regression Tree



Gradient Boosting



Test and Score


Test and Score						
Model	MSE	RMSE	MAE	MAPE	sMAPE	R
Linear Regression	289.558	17.016	13.065	4.149	3.989	0.985
Tree	121.021	11.001	4.104	1.332	1.283	0.994
Gradient Boosting	33.975	5.829	0.993	0.314	0.307	0.998
Random Forest	16.179	4.022	1.330	0.436	0.430	0.999

Berdasarkan hasil evaluasi model pada tabel Test and Score, model Random Forest menunjukkan performa terbaik. Dengan nilai R^2 yang sangat tinggi, mencapai 0.999, model ini mampu menjelaskan hampir seluruh variasi pada data dengan sangat baik. Selain itu, nilai RMSE yang rendah (4.022) dan MAE yang juga kecil (1.330) menunjukkan bahwa model ini sangat akurat dalam memprediksi nilai yang mendekati nilai aktual. MAPE yang hanya 0.436 mengindikasikan bahwa kesalahan prediksi model ini sangat rendah, sehingga memberikan hasil yang dapat diandalkan. Secara keseluruhan, Random Forest terbukti memiliki kinerja terbaik di antara keempat model yang diuji, menjadikannya pilihan yang sangat efektif untuk analisis ini.


HASIL ANALISIS *REGRESSION*

Predicted vs Actual Plot dan Residual Plot

Linear Regression




Plot Predicted vs Actual menunjukkan bahwa model Linear Regression memiliki akurasi tinggi, dengan sebagian besar titik data dekat garis diagonal. Nilai korelasi $r = 0,99$ dan R^2 tinggi menunjukkan prediksi yang sangat mendekati nilai aktual, didukung oleh RMSE dan MAE yang rendah.




Residual Plot menunjukkan bahwa model Linear Regression memprediksi dengan baik, tanpa bias, dan error kecil. Korelasi $r = -0,27$ menunjukkan hubungan lemah antara prediksi dan residual, menandakan performa yang baik.

Regression Tree




Plot Predicted vs Actual menunjukkan bahwa model Regression Tree memiliki akurasi tinggi, dengan hampir seluruh titik data dekat garis diagonal. Korelasi $r = 1,00$ dan nilai R^2 , RMSE, serta MAE yang rendah menunjukkan prediksi yang sangat mendekati nilai aktual.




Residual Plot menunjukkan bahwa model Regression Tree akurat, tanpa bias, dengan error kecil dan korelasi $r = 0,00$, menandakan performa yang sangat baik.

Random Forest Regression




Plot Predicted vs Actual menunjukkan bahwa model Random Forest Regression memiliki akurasi sangat tinggi, dengan hampir seluruh titik data dekat garis diagonal. Korelasi $r = 1,0$ dan nilai R^2 , RMSE, serta MAE yang rendah menunjukkan prediksi yang sangat mendekati nilai aktual.




Residual Plot menunjukkan bahwa model Random Forest Regression memprediksi dengan akurat, tanpa bias, dan error kecil. Korelasi $r = -0,15$ menunjukkan hubungan lemah antara prediksi dan residual, menandakan performa yang sangat baik.

Gradient Boosting



Plot Predicted vs Actual menunjukkan bahwa model Gradient Boosting Regression sangat akurat, dengan hampir seluruh titik data dekat garis diagonal. Korelasi $r = 1,0$ dan nilai R^2 , RMSE, serta MAE yang rendah menunjukkan prediksi yang sangat mendekati nilai aktual.




Residual Plot menunjukkan bahwa model Gradient Boosting Regression memprediksi dengan akurat, tanpa bias, dan error yang sangat kecil. Korelasi $r = -0,03$ mengindikasikan hubungan yang lemah antara prediksi dan residual, menandakan performa model yang sangat baik.

HASIL ANALISIS REGRESSION


Feature Importance

Linear Regression




Model Linear Regression, peringkat variabel yang paling berpengaruh terhadap purchase_amount adalah Loyalty_score memiliki pengaruh Decrease in R^2 sebesar 2,0) diikuti oleh annual_income(Decrease in R^2 0,4), dan purchase_frequency (Decrease in R^2 0,2).

Random Forest Regression




Dalam Random Forest Regression, variabel age memiliki pengaruh terbesar terhadap purchase_amount (Decrease in R^2 265), diikuti oleh loyalty_score (Decrease in R^2 115) yang juga sangat berpengaruh, dan purchase_frequency(Decrease in R^2 92) yang berkontribusi besar dalam memprediksi jumlah pembelian.

Regression Tree



Dalam Regression Tree, variabel loyalty_score memiliki pengaruh terbesar terhadap purchase_amount (Decrease in R^2 630), diikuti oleh purchase_frequency (Decrease in R^2 560), dan age yang memiliki pengaruh sangat kecil (Decrease in R^2 5).

Gradient Boosting



Pada Gradient Boosting, purchase_frequency menempati urutan pertama dengan pengaruh terbesar (Decrease in R^2 530), disusul oleh loyalty_score (Decrease in R^2 520), dan age dengan pengaruh kecil (Decrease in R^2 10).


Secara keseluruhan dari keempat model regresi, loyalty_score dan purchase_frequency merupakan dua variabel yang paling konsisten berpengaruh pada semua model, dengan loyalty_score mendominasi di sebagian besar model dan purchase_frequency muncul sebagai yang paling berpengaruh dalam model Gradient Boosting. Age dan annual_income menunjukkan pengaruh yang lebih kecil, terutama dalam model-model seperti Regression Tree dan Gradient Boosting.

HASIL ANALISIS CLUSTERING



Algoritma K-Means Clustering



K-Means Scatter Plot



Dari analisa yang dilakukan, didapatkan korelasi positif yang cukup kuat, semakin tinggi pendapatan, maka semakin tinggi pula daya belinya. K-means membagi data menjadi 6 tingkatan yang berbeda, menggunakan Elbow Method.

1. C4 (orange) yang memiliki pendapatan paling tinggi (70.000+) dan belanja paling banyak (600+).
2. C2 (Merah), berada 1 tingkat di bawah C4.
3. C1 (Biru Muda), dengan pendapatan 55.000-65.000 dan belanja 380-450.
4. C6 (ungu), dengan pendapatan sekitar 50.000.
5. C3 (Hijau Muda), dengan pendapatan 40.000-50.000 dan belanja yang mulai menurun.
6. C5 (Kuning), dengan pendapatan <40.000 dan belanja <200.

K-Means Silhouette Plot



Hasil pengujian menggunakan silhouette plot menunjukkan skor rata-rata yang kuat, dengan cluster:


1. C3 dan C5 yang mendapat nilai tertinggi 0,746 dan 0,974. Yang artinya pelanggan di cluster ini memiliki kemiripan satu sama lain dan konsisten dengan cluster nya.
2. cluster C2, C4, dan C6 hasilnya stabil di angka 0,4-0,6, yang artinya pelanggan di cluster ini juga cukup solid dengan cluster nya masing-masing.
3. cluster C1, masih ada beberapa pelanggan yang memiliki karakteristik yang hampir mirip dengan cluster lainnya, sehingga nilai siluetnya negatif.

HASIL ANALISIS CLUSTERING



Algoritma Hierarchical Clustering

Hierarchical Clustering Scatter Plot




Selanjutnya, widget Scatter Plot. Data membentuk pola garis lurus naik ke kanan, yang artinya semakin tinggi pendapatan tahunan pelanggan, maka akan semakin tinggi pula jumlah belanjanya. Dengan tidak adanya outlier di gambar ini, membuktikan bahwa dataset pelanggan yang kami gunakan cukup konsisten. Dimulai dari,

1. C1 (Biru) yang berada paling bawah, dengan pendapatan dan belanja rendah.
2. C2, C4, C5, dan C6 yang bertahap semakin keatas, dengan pendapatan dan belanja juga semakin meningkat.
3. C2 (Hijau Muda), berada di kanan paling atas, yang menandakan bahwa cluster ini memiliki pendapatan dan juga belanja paling tinggi.

Tidak adanya penumpukan antar warna, menunjukkan algoritma dengan metode Ward Linkage berhasil mengidentifikasi batas-batas antar segmen dengan jelas.

Hierarchical Clustering Box Plot



Gambar disamping merupakan hasil dari Box Plot, grafiknya membentuk pola tangga, yang artinya semakin tinggi kelas ekonomi, maka akan semakin tinggi juga jumlah belanjanya.


1. C1, cluster yang paling hemat memiliki rata-rata belanja hanya sebanyak 168.
2. C2, rata-rata belanja sudah meningkat ke 242.
3. C4, cluster middle class, memiliki rata-rata belanja di angka 358.
4. C5 berada di angka 434.
5. C6, cluster ini cukup royal dengan rata-rata belanja 492.
6. C3 cluster Ultimate Sultan, rekor belanja tertinggi di angka 601.

HASIL ANALISIS CLUSTERING



Algoritma DBSCAN

DBSCAN Scatter Plot




Menurut hasil dari scatter plot disamping, terdapat beberapa cluster yang dihasilkan,

1. cluster C3 (Hijau Muda) memiliki anggota paling banyak, yang artinya mayoritas pelanggan berada di kelas menengah dengan pola belanja yang sama.
2. cluster C4 (Orange) di ujung kanan atas dengan pelanggan sultan
3. C5 (Kuning) di ujung bawah kiri dengan pelanggan hemat berpendapatan rendah.
4. cluster lainnya (C1, C2, dan C6) memiliki kepadatan sendiri yang membedakan dari kelompok besar di tengah.
5. Terakhir, ada 2 titik abu-abu di bagian bawah, titik ini dianggap sebagai noise atau anomali, karena pelanggannya memiliki karakteristik yang cukup berbeda dengan cluster yang lain.



DBSCAN Silhouette Plot



Di bagian paling bawah terdapat tulisan “11 Instances Omitted”, 11 orang ini dianggap sebagai Noise oleh DBSCAN, dan tidak masuk ke hitungan grafik karena tidak masuk ke ke cluster manapun.

1. C5 (0,979) dan C6 (0,882) merupakan cluster terbaik, karena pelanggannya sangat solid dan kompak, tidak ada keraguan sama sekali.
2. C1 (0,695), C2 (0,412) dan C4 (0,505) masih tergolong kuat, walaupun di C2 masih terdapat beberapa yang menjorok ke arah negatif.
3. C3 (0,094), cluster ini merupakan cluster yang “bingung”, karena masih terdapat beberapa garis yang menjorok ke arah negatif. Biasanya, pelanggan di area seperti ini, memiliki pendapatan dan belanja yang mirip dengan cluster di sebelahnya.

SINTESIS TERINTEGRASI

Analisis terintegrasi melalui Clustering, Regression, dan Classification membuktikan bahwa Annual Income dan Loyalty adalah penggerak utama perilaku belanja, di mana model Random Forest mencatatkan akurasi luar biasa sebesar 91,7% pada klasifikasi dan 0,999 pada regresi. Sinergi ini menghasilkan pemetaan strategis wilayah yang tajam: West Region sebagai basis pelanggan premium ("Sultan") yang memerlukan layanan eksklusif, North Region sebagai pusat kelas menengah yang responsif terhadap promo diskon, dan South Region sebagai wilayah heterogen yang membutuhkan variasi produk luas. Secara manajerial, perusahaan direkomendasikan untuk memprioritaskan alokasi sumber daya pada segmen loyalitas tinggi (Cluster C3/C4) dan memanfaatkan deteksi noise pada DBSCAN sebagai instrumen audit untuk memitigasi risiko transaksi. Untuk pengembangan laporan di masa depan, penggunaan teknik Data Balancing sangat disarankan agar prediksi AI tetap objektif dan tidak memihak pada kelompok data mayoritas.

KESIMPULAN



Berdasarkan hasil analisis yang kami lakukan pada dataset Customer Purchase Behavior dengan menggunakan metode classification, regression, dan clustering. Kami menyimpulkan bahwa hasil dari ketiga metode tersebut konsisten dan saling melengkapi satu sama lain. Fitur `annual_income` merupakan fitur penting yang membantu ketiga metode tersebut untuk memahami profil pelanggan secara menyeluruh. Clustering dapat mengidentifikasi segmen pelanggan secara alami, dengan membentuk 6 cluster melalui elbow method. Kemudian, pola ini akan divalidasi secara akurat oleh Regression. Dalam analisis Classification, algoritma Random Forest menjadi model yang paling unggul dalam memprediksi data pelanggan dengan nilai akurasi 91,7%. Sementara itu, pada analisis Regression, Random Forest juga mencapai nilai terbaik dengan nilai R^2 sebesar 0,999. Peta strategis wilayah juga telah dipetakan dengan baik sesuai dengan karakteristik tiap cluster, region West sebagai pelanggan premium, kemudian region North sebagai wilayah kelas menengah dan region South sebagai wilayah yang paling beragam.

SARAN



Berdasarkan keterbatasan dan temuan dalam laporan ini, berikut beberapa saran untuk pengembangan analisis selanjutnya. Untuk penelitian selanjutnya disarankan untuk menggunakan data dengan distribusi kelas yang lebih seimbang. Hal ini disebabkan pada algoritma seperti KNN dan random forest, terdapat kecenderungan untuk memihak ke arah yang distribusinya lebih besar, sehingga dapat mempengaruhi objektivitas prediksi. Penambahan variabel dalam dataset juga dapat dilakukan, untuk membantu algoritma classification dan clustering untuk membentuk profil pelanggan yang lebih spesifik.



TERIMA KASIH

