



Fakultas Ekonomi dan Bisnis
UPN “Veteran” Jakarta

Project Orange Data Mining Insurance & Healthcare Cost

UTS Semester Genap TA 2025/2026

Dosen Pengampu: Dr. Donny Maha Putra, M.Ak.

Kelompok 5

Kelas B - Analisis Big Data



Fadli Ahmad Ikhsanto

2310112095



Muhammad Zackri


2310112103



Zahwa Rakhshanda Afif

2310112075

Pendahuluan



Industri asuransi merupakan sektor yang sangat bergantung pada data untuk memahami karakteristik peserta, memperkirakan biaya yang harus ditanggung, serta menilai tingkat risiko. Data tidak lagi hanya berfungsi sebagai catatan administratif, tetapi juga menjadi dasar penting dalam analisis dan pengambilan keputusan.

Dalam praktiknya, analisis data pada bidang asuransi memiliki banyak kegunaan. Data dapat dimanfaatkan untuk membantu perusahaan dalam proses pricing, underwriting, penilaian risiko, hingga memahami pola perilaku pelanggan.

Oleh karena itu, penelitian ini dilakukan untuk melihat bagaimana data insurance dapat dianalisis melalui classification, regression, dan clustering agar menghasilkan insight yang berguna bagi pengambilan keputusan.




Rumusan Masalah:

Tinjauan Teori & Metode

Analisis Big Data

Kategori Algoritma

- Classification** ➤ Teknik memetakan data ke dalam label atau kategori yang telah ditentukan
- Regression** ➤ Teknik pemodelan hubungan fungsional variabel target dan variabel (prediktor)
- Clustering** ➤ Teknik pengorganisasian sekumpulan data ke dalam partisi-partisi berdasarkan tingkat kemiripannya



- 1 **K-Nearest Neighbor (KNN):** Tebak berdasarkan jarak/kemiripan dengan tetangga terdekat.
- 2 **Decision Tree:** Prediksi lewat struktur pohon hierarki.
- 3 **Random Forest:** Gabungan banyak pohon agar lebih akurat.
- 4 **AdaBoost (Adaptive Boosting):** Satukan model lemah secara bertahap jadi model kuat.
- 5 **Naive Bayes:** Klasifikasi berdasarkan hitungan probabilitas (peluang).
- 6 **Linear Regression:** Hubungkan variabel untuk ramal nilai kontinu (angka).
- 7 **K-Means Clustering:** Kelompokkan data serupa tanpa label target.
- 8 **Hierarchical Clustering:** Kelompokkan data dalam bentuk hierarki/tingkatan.

Tinjauan Teori & Metode

1

Analisis Big Data -

2

K-Nearest Neighbor (KNN) :

3

Decision Tree

4

Random Forest

5

AdaBoost (Adaptive Boosting)

Menyatukan beberapa klasifikator lemah, seperti pohon keputusan sederhana, secara bertahap untuk menciptakan satu model prediksi yang lebih kuat.

6

Naive Bayes

Algoritma penggolongan dalam pembelajaran mesin yang bersandar pada probabilitas, digunakan untuk meramalkan kategori dari suatu data.

7

Linear Regression


Menggambarkan hubungan antara variabel yang dependen dan satu atau lebih variabel yang independen untuk meramalkan nilai terus-menerus.

8

K-Means

Pengelompokkan data yang serupa ke dalam kelompok tertentu tanpa membutuhkan data target.


Model pada aplikasi Orange Data Mining:



kNN



Tree




Random Forest




AdaBoost



Naive Bayes



Linear Regression



k-Means


EDA & Data Preparation

INSURANCE.CSV		
CHARGES	Numerik	Biaya Asuransi
AGE	Numerik	Usia Individu
BMI	Numerik	Body Mass Index
CHILDREN	Numerik	Jumlah Anak
SEX	Kategorik	Jenis Kelamin
SMOKER	Kategorik	Status Merokok
REGION	Kategorik	Wilayah Tempat Tinggal

* Terdapat 1 data duplikat yang dihapus permanen, maka data observasi akhirnya adalah 1337 data.

* Tidak terdapat missing value

DATA PREPROCESSING



DATA PREPARATION

- Menghapus data duplikat yaitu pada baris 195 dan 581
- Menentukan variabel yang numerik dan kategorikal, serta menentukan *Charges* sebagai variabel target penelitian
- Melakukan Uji Normalisasi/Standardisasi melalui 2 pendekatan

→ Standardize to $\mu=0, \sigma^2=1$

→ Normalize to interval $[0, 1]$

- Hasil yang didapatkan adalah skala antarvariabel menjadi lebih seragam dan siap digunakan untuk analisis classification, regression, dan clustering

Analisis Classification

TEST AND SCORE

Berdasarkan hasil Test & Score, algoritma Decision Tree memperoleh nilai tertinggi pada CA = 0.961, F1-Score = 0.961, Precision = 0.961, dan Recall = 0.961. Sementara itu, Random Forest memperoleh nilai AUC tertinggi = 0.989, yang menunjukkan kemampuan terbaik dalam membedakan dua kelas secara keseluruhan. AdaBoost juga menunjukkan performa yang cukup stabil dengan nilai metrik yang mendekati Decision Tree. Di sisi lain, Naive Bayes memiliki nilai akurasi paling rendah dibanding model lainnya.

Model	AUC	CA	F1	Prec	Recall	MCC
Naive Bayes	0.954	0.925	0.927	0.935	0.925	0.793
kNN	0.977	0.942	0.943	0.943	0.942	0.824
AdaBoost	0.938	0.957	0.958	0.958	0.957	0.870
Tree	0.911	0.961	0.961	0.961	0.961	0.880
Random Forest	0.989	0.962	0.962	0.963	0.962	0.885

Confusion Matrix

Berdasarkan confusion matrix, Decision Tree menunjukkan performa terbaik dalam mengenali peserta yang benar-benar bukan perokok, karena memiliki True Negative (TN) tertinggi = 1042 dan False Positive (FP) terendah = 22. Sementara itu, Naive Bayes memiliki True Positive (TP) tertinggi = 254 dan False Negative (FN) terendah = 20, sehingga paling baik dalam mendeteksi peserta yang benar-benar perokok, tetapi model ini juga menghasilkan false positive tertinggi = 81. Hal ini menunjukkan bahwa setiap model memiliki kekuatan dan kelemahan yang berbeda.

Model	Ture Negative (TN)	False Negative (FP)	False Positive (FN)	True Positive (TP)
kNN	1024	37	40	237
Tree	1042	30	22	244
Random Forest	1029	25	35	249
AdaBoost	1033	26	31	248
Naive bayes	983	20	81	254

Analisis Classification

ROC ANALYSIS (ROC-AUC)

Pada analisis ROC-AUC, model terbaik adalah Random Forest dengan nilai AUC = 0.989, diikuti oleh kNN = 0.977, Naive Bayes = 0.954, AdaBoost = 0.938, dan Decision Tree = 0.911. Nilai AUC yang semakin mendekati 1 menunjukkan bahwa model semakin baik dalam membedakan kelas perokok dan bukan perokok. Dengan demikian, walaupun Decision Tree unggul pada sebagian besar metrik utama, Random Forest lebih unggul dalam kemampuan diskriminasi kelas secara keseluruhan.

Model	ROC Target = "Yes"	ROC Target = "No"	AUC
kNN	0.491	0.504	0.977
Decision Tree	0.500	0.500	0.911
Random Forest	0.500	0.500	0.989
AdaBoost	1.000	1.000	0.938
Naive Bayes	0.571	0.396	0.954

KESIMPULAN

Berdasarkan semua metrik yang telah dianalisa, Decision Tree terbukti menjadi Model yang paling optimal untuk Analisis Klasifikasi dengan dataset khusus ini. Sedangkan jika kita mempertimbangkan ROC-AUC untuk kelas yang seimbang, Random Forest menjadi model terbaik. Random Forest lebih buruk daripada Naive Bayes untuk deteksi kelas, yang membuat kesalahan paling sedikit dalam mendeteksi kelas positif di atas tingkat false positive. Dan secara alami, hasil klasifikasi menunjukkan bahwa atribut pengidentifikasi peserta dalam asuransi memiliki beberapa karakteristik yang informatif.

R² (Koefisien Determinasi)

Ketiga model belum optimal dalam memprediksi nilai charges atau biaya asuransi karena nilainya masih jauh dari pendekatan 1. Linear Regression = 0.115 (11.5%, Gradient Boosting = 0.008 (0.8%), Random Forest -0.105 (-10.5%)

MAE (Mean Absolute Error)

MAE merupakan rata-rata selisih absolut antara nilai prediksi dengan nilai aktual. Masing-masing model rata-rata prediksinya meleset dari nilai charges: Linear Regression = \$9042, Gradient Boosting = \$9229, Random Forest = \$9419.

RMSE (Root Mean Squared Error)

RMSE merupakan ukuran kesalahan atau selisih yang mirip dengan MAE, namun lebih sensitif terhadap kesalahan yang besar. Dari ketiga algoritma belum sepenuhnya akurat dalam memprediksi nilai charges. Linear Regression = 11387.737, Gradient Boosting = 12056.518, Random Forest = 12726.165.

MAPE (Mean Absolute Percentage Error)

MAPE menunjukkan rata-rata persentase kesalahan antara nilai prediksi dan nilai aktual. Dari ketiga algoritma MAPE > 100% yang berarti masih kurang akurat dalam memprediksi nilai charges. Linear Regression = 114.023 (114%), Gradient Boosting = 120.686 (120%), Random Forest = 122.096 (122%).

Analisis Regression

Suatu metode untuk memprediksi secara sistematis tentang apa yang paling mungkin terjadi di masa depan berdasarkan data yang ada saat ini untuk memperkecil kesalahan. Dalam arti lain, analisis regresi adalah metode statistik yang digunakan untuk menentukan kemungkinan hubungan antara variabel-variabel.

Step by Step


File (upload dataset Insurance) → skip sex, smoker, region → set charges sebagai target → Rank (cek relevansi fitur) → Correlations (cek Pearson ke charges) → Select Columns (charges = target; age, bmi, children = features) → Linear Regression (default) → Random Forest (default) → Gradient Boosting (default) → Test & Score (hubungkan ke semua model, 5 folds) → cek MSE, RMSE, MAE, MAPE, sMAPE, R² → Scatter Plot (hubungkan ke Test & Score, x = age, y = charges)

Hasil Test & Score

Model	MSE	RMSE	MAE	MAPE	sMAPE	R ²
Linear Regression	129680565.048	11387.737	9042.464	114.023	71.176	0.115
Gradient Boosting	145359637.726	12056.518	9229.319	120.686	70.425	0.008
Random Forest	161955273.334	12726.165	9419.067	122.096	67.672	-0.105


Scatter Plot Analisis Regression

X = age (usia) dan Y = charges (biaya asuransi)




Dari pola yang terlihat, disimpulkan bahwa semakin bertambah age , maka nilai charges cenderung meningkat. Hal ini membuktikan age memiliki pengaruh positif yang cukup kuat terhadap charges.

X = children (jumlah anak) dan Y = charges (biaya asuransi)



Dari pola tidak terlihat hubungan linear yang kuat antara kedua variabel. Maka dapat disimpulkan children tidak memiliki pengaruh yang signifikan terhadap charges.

X = bmi (body mass index) dan Y = charges (biaya asuransi)




Dari pola terlihat penyebarannya masih cukup lebar Hal ini membuktikan bmi memiliki pengaruh positif terhadap charges, namun pengaruhnya tidak terlalu kuat karena masih banyak variasi data.

Kesimpulan

Berdasarkan hasil analisis regresi menggunakan scatter plot, kami menggunakan 3 variabel yang berpengaruh terhadap nilai charges (biaya asuransi), yaitu age (usia), bmi (body mass index), dan children (jumlah anak). Dari ketiga variabel tersebut, dapat disimpulkan bahwa age (usia) merupakan variabel yang paling berpengaruh terhadap charges (biaya asuransi), selanjutnya diikuti oleh variabel bmi (body mass index), sedangkan children (jumlah anak) tidak berpengaruh signifikan terhadap charges (biaya asuransi).

Analisis Clustering



TUJUAN

Mengelompokkan pengguna asuransi berdasarkan kemiripan karakteristik numerik tanpa menggunakan label target, sehingga dapat terlihat segmentasi profil peserta berdasarkan pola biaya dan karakteristik dasar.

VARIABEL

Semua variabel yang dipakai untuk clustering adalah numerik, sedangkan variabel kategorikal tidak digunakan pada proses pembentukan cluster.

METODE


- K-Means Clustering
- Hierarchical Clustering
- DBSCAN

JUMLAH CLUSTER

- K-Means: 4 Cluster berdasarkan Elbow Method dan Silhouette Score
- Hierarchical Clustering: 4 Cluster dengan Distance Euclidean (Normalized)
- DBSCAN: $\text{eps} = 0,84$ dan $\text{minPts} = 3$


Analisis Clustering

K-MEANS CLUSTERING




Pada scatter plot K-Means data menjadi 4 cluster pada variabel Charges yang membentuk kelompok biaya rendah, menengah, dan tinggi. Hasil ini menunjukkan K-Means cukup efektif dalam membentuk segmentasi

DBSCAN



Pada scatter plot DBSCAN, terdapat pembagian dua jenis kelompok yaitu data yang termasuk clusterin dan outlier. Dari hasil visualisasi menggunakan DBSCAN, data yang outlier dari klasternya terlihat dengan baik.

HIERARCHICAL CLUSTERING



Pada scatter plot Hierarchical Clustering mampu menangkap perbedaan tingkat biaya asuransi antar peserta dengan cukup baik, sehingga hasilnya mudah untuk diinterpretasikan.

KESIMPULAN

Secara keseluruhan, ketiga metode clustering menunjukkan bahwa data peserta asuransi tidak homogen dan dapat dikelompokkan berdasarkan kemiripan profil numerik. K-Means memberikan segmentasi yang cukup baik ke dalam kelompok biaya rendah, menengah, dan tinggi, Hierarchical Clustering memberikan struktur segmentasi yang paling jelas dan paling mudah dibaca, sedangkan DBSCAN menegaskan adanya satu pola kepadatan utama dengan beberapa observasi yang menyimpang.

SINTESIS INTEGRASI

KESAMAAN TEMUAN

- Data peserta asuransi tidak homogen
- Classification membedakan peserta menjadi perokok dan bukan perokok
- Regression menunjukkan charges mengikuti pola tertentu
- Clustering membagi peserta ke kelompok biaya tinggi, sedang, dan rendah
- DBSCAN menunjukkan 1 cluster utama + beberapa outlier

HUBUNGAN CLUSTER DENGAN KELAS

CLASSIFICATION DAN NILAI TARGET REGRESSION

- Setiap cluster memiliki kecenderungan nilai charges yang berbeda
- Pada Hierarchical Clustering, C2 memiliki rata-rata biaya tertinggi
- C1, C3, dan C4 memiliki rata-rata biaya lebih rendah
- Clustering lebih kuat menjelaskan target regression (charges)
- Hubungan dengan kelas smoker masih bersifat indikatif, belum langsung

REKOMENDASI KEPADA PEMANGKU KEPENTINGAN

MANAJER BISNIS

- Gunakan clustering untuk segmentasi pelanggan
- Bedakan peserta ke kelompok biaya tinggi, menengah, dan rendah

DATA ANALYST

- Fokus pada variabel yang lebih informatif, seperti usia dan BMI
- Kembangkan model regresi yang lebih fleksibel karena model saat ini belum optimal

AUDITOR

- Nilai model jangan hanya dari 1 metrik
- Perhatikan outlier DBSCAN karena bisa menjadi sinyal risiko atau data ekstrem

CERITA BISNIS

peserta asuransi berasal dari berbagai profil beragam. Segmen-segmen tersebut meliputi peserta dengan status kelas yang mudah dikenali, beberapa di antaranya tercatat sebagai pemegang biaya asuransi yang tinggi, dan beberapa lainnya tercatat sebagai pemegang biaya rendah.

KESIMPULAN

KELAYAKAN DATA

Data layak dianalisis karena tidak ada missing value, hanya ada 1 data duplikat yang dihapus, dan variabel charges terbukti right-skewed dengan kelompok smoker memiliki biaya lebih tinggi.

REGRESSION

Menunjukkan bahwa kemampuan prediksi charges masih terbatas karena nilai R^2 rendah, tetapi pola hubungan antarvariabel tetap terlihat. Variabel yang paling berpengaruh adalah age, diikuti bmi, sedangkan children berpengaruh lemah

CLASSIFICATION

Menunjukkan bahwa status smoker dapat diprediksi dengan baik. Decision Tree paling kuat pada accuracy, precision, recall, dan F1-score, sedangkan Random Forest paling baik dalam membedakan dua kelas dengan AUC 0,989.

CLUSTERING

Menunjukkan bahwa peserta asuransi tidak homogen. K-Means dan Hierarchical Clustering sama-sama membentuk 4 cluster yang memisahkan kelompok biaya rendah, menengah, dan tinggi, sedangkan DBSCAN menunjukkan 1 cluster utama dengan beberapa outlier.



Saran & Refleksi

REFLEKSI

- Pada Confusion Matrix, True Positive terletak pada True Negative yang menyebabkan distorsi informasi
- Kurangnya informasi pengarahan dalam penggunaan beberapa widget di aplikasi Orange
- Pada saat melakukan silhouette score sudah dipilih score yang tertinggi, tetapi data dari silhouette plot masih menunjukkan adanya titik yang tumpang tindih antar clusternya.

SARAN

- Perlu adanya penambahan variabel relevan lebih banyak lagi supaya memperkuat analisis dan juga dalam menginterpretasikan datanya
- Perlu adanya pengembangan model penelitian yang lebih lanjut untuk memberikan gambaran yang komprehensif
- Perlu adanya peningkatan interpretabilitas kluster agar hasil segmentasi menjadi mudah diamati.



Fakultas Ekonomi dan Bisnis
UPN “Veteran” Jakarta

Thank You

Kelompok 5:

Fadli Ahmad Ikhsanto - 2310112095

Muhammad Zackri - 2310112103

Zahwa Rakhshanda Afif - 2310112075