

ANALISIS HARGA RUMAH DAN SEGMENTASI PROPERTI MENGGUNAKAN PENDEKATAN MACHINE LEARNING BERBASIS ORANGE DATA MINING

Laporan ini Disusun Untuk Memenuhi Projek Mata Kuliah Analisis Big Data

Disusun Oleh:

- Desty Indarti 2310112159
- Linda Dwi Anggraini 2310112161
- Nanda Yuliawati 2310112183

Dosen Pengampu

Dr. Donny Maha Putra, M.Ak

PROGRAM STUDI SARJANA AKUNTANSI UNIVERSITAS PEMBANGUNAN
NASIONAL “VETERAN” JAKARTA 2026



Latar Belakang

Rumah merupakan kebutuhan dasar yang berfungsi sebagai tempat tinggal serta pusat aktivitas dan interaksi keluarga. Kepemilikan rumah yang terjangkau menjadi aspek penting karena berhubungan langsung dengan kemampuan masyarakat dalam memenuhi kebutuhan hunian. Harga rumah ditentukan oleh berbagai faktor, antara lain lokasi, ukuran dan kondisi bangunan, fasilitas, serta kondisi ekonomi seperti tingkat pendapatan dan kepadatan penduduk.

Analisis data dapat dilakukan secara lebih sistematis melalui pendekatan data mining. Dataset yang digunakan menunjukkan adanya hubungan antara variabel seperti harga, jumlah kamar, dan luas bangunan yang relevan untuk dianalisis lebih lanjut. Selain itu, segmentasi pasar perumahan menjadi penting untuk memahami perbedaan karakteristik konsumen, yang dapat dilakukan melalui teknik clustering, seperti algoritma K-Means, guna mengelompokkan data berdasarkan kemiripan karakteristik.



Deskripsi Dataset

Dataset yang digunakan dalam analisis ini adalah House Sales Prediction & Classification, yang berisi informasi terkait kondisi dan karakteristik rumah di suatu wilayah.

Jumlah datanya lebih dari 21.000 baris, dengan 21 variabel yang menggambarkan berbagai aspek properti. Variabel yang digunakan antara lain Price (harga rumah), bedrooms (jumlah kamar tidur), bathrooms (jumlah kamar mandi), sqft_living (luas bangunan), sqft_lot (luas tanah), floors (jumlah lantai), condition (kondisi rumah), grade (kualitas bangunan), serta beberapa variabel pendukung lainnya.

Dataset ini dipilih karena dapat digunakan untuk tiga jenis analisis sekaligus. Untuk regression, variabel price dapat digunakan untuk memprediksi harga rumah. Untuk classification, nilai tersebut bisa dibagi kedalam beberapa kategori, misalnya harga rendah, sedang, dan tinggi. Sementara untuk clustering, beberapa variabel numerik bisa digunakan untuk mengelompokkan data berdasarkan kemiripan karakteristiknya.

Rumusan Masalah

1

Bagaimana mengklasifikasikan kategori harga rumah berdasarkan karakteristik yang dimiliki menggunakan metode classification?

2

Apa saja faktor yang memengaruhi nilai harga rumah dan bagaimana memprediksi nilainya menggunakan metode regression?

3

Bagaimana segmentasi pasar perumahan dapat dibentuk berdasarkan karakteristik data menggunakan metode clustering?

Metode Analisis



K-Nearest Neighbor (KNN)

Klasifikasi berdasarkan Kemiripan jarak dengan tetangga terdekat

Decision Ttree

Memprdiksi masa depan dengan struktur pohon

Naive Bayes

Mengasumsikan independensi antar atribut

Random Forest Classification

Menggabungkan banyak decision tree untuk meningkatkan akurasi prediksi

Linear Regression

Menganalisa hubungan garis lurus antara variabel terikat & bebas

Random Forest Regression

Menggabungkan banyak pohon keputusan untuk prediksi akurat


K-Means Clustering

Mengelompokkan data dengan nilai rata-rata terdekat

Hierarchical Clustering


Membentuk tingkatan dari kumpulan data sesuai dengan karakteristiknya

Analisis Klasifikasi



Hasil Analisis Klasifikasi

TEST AND SCORE: AUC, CA, F1-SCORE, PRECISION, RECALL,



Random Forest menunjukkan hasil terbaik dengan nilai AUC sebesar 0,826 serta accuracy sebesar 0,654, yang menandakan model ini paling baik dalam membedakan kelas harga rumah dan memberikan prediksi yang relatif stabil.

Decision Tree juga memiliki performa yang cukup baik dengan nilai AUC sebesar 0,814 dan accuracy sebesar 0,650, sehingga masih dapat dijadikan alternatif model yang cukup efektif.


KNN memiliki performa yang cukup dengan nilai accuracy sebesar 0,620, namun masih berada di bawah Decision Tree dan Random Forest.

Sementara itu, Naive Bayes memiliki performa paling rendah dengan accuracy sebesar 0,577 dan F1-score sebesar 0,565, yang menunjukkan bahwa model ini kurang mampu menangkap pola data dengan baik.

Dapat disimpulkan bahwa Random Forest merupakan model yang paling optimal dalam penelitian ini, sedangkan Naive Bayes menjadi model dengan performa terendah.


Hasil Analisis Klasifikasi

CONFUSION MATRIX KNN



Model KNN cukup baik mengklasifikasikan harga rumah kategori low (71,0%) dan high (70,2%), sehingga data ekstrem lebih mudah dikenali. Namun, pada kategori middle akurasi rendah (45,0%) karena banyak data salah diklasifikasikan ke low (36,2%) dan high (18,8%). Hal ini menunjukkan bahwa kategori harga sedang sulit dibedakan karena memiliki kemiripan dengan kedua kategori lainnya.


CONFUSION MATRIX TREE



Pada model Decision Tree, hasil confusion matrix menunjukkan bahwa model cukup baik dalam mengklasifikasikan harga rumah kategori rendah dan tinggi, dengan tingkat ketepatan masing-masing sebesar 69,9% dan 73,3%. Namun, pada kategori harga sedang, akurasi hanya 51,8%, yang menunjukkan masih banyak kesalahan klasifikasi. Kesalahan paling sering terjadi pada data kategori sedang yang diprediksi sebagai rendah.


Hasil Analisis Klasifikasi

CONFUSION MATRIX RANDOM FOREST



Pada model Random Forest, performa klasifikasi terlihat lebih stabil dibandingkan model lainnya. Tingkat ketepatan untuk kategori rendah sebesar 69,9%, kategori sedang 49,8%, dan kategori tinggi mencapai 76,6%, yang merupakan nilai tertinggi untuk kelas high. Hal ini menunjukkan bahwa Random Forest sangat baik dalam mengenali rumah dengan harga tinggi. Meskipun demikian, kategori sedang masih menjadi tantangan karena cukup banyak yang salah diklasifikasikan ke kategori lain. Secara keseluruhan, model ini paling konsisten dalam menangkap pola data.


CONFUSION MATRIX NAIVE BAYES



Pada model Naive Bayes, performa klasifikasi terlihat lebih rendah dibandingkan model lainnya. Untuk kategori rendah, tingkat ketepatan sebesar 68,3%, sedangkan kategori sedang hanya 33,1%, yang menunjukkan bahwa sebagian besar data pada kategori ini salah diklasifikasikan. Untuk kategori tinggi, tingkat ketepatannya sebesar 71,7%, namun masih di bawah Random Forest. Banyaknya kesalahan pada kategori sedang menunjukkan bahwa model ini kurang mampu menangkap hubungan antar variabel dalam data harga rumah.


Hasil Analisis Klasifikasi

ROC ANALYSIS - LOW



Pada ROC untuk kategori harga rendah, semua model menunjukkan performa yang cukup baik karena kurva berada jauh di atas garis diagonal, yang berarti model mampu membedakan data dengan baik. Random Forest dan Decision Tree memiliki kurva yang paling tinggi, sehingga menunjukkan kemampuan terbaik dalam mengenali rumah dengan harga rendah. KNN juga cukup baik meskipun sedikit di bawah kedua model tersebut, sedangkan Naive Bayes memiliki performa paling rendah. Hal ini menunjukkan bahwa rumah dengan harga rendah relatif lebih mudah diklasifikasikan dibanding kategori lainnya.


ROC ANALYSIS - MIDDLE



Pada kategori harga sedang, performa semua model terlihat menurun dibandingkan kategori lainnya. Kurva ROC cenderung lebih dekat ke garis diagonal, yang menunjukkan kemampuan klasifikasi yang lebih lemah. Random Forest dan Decision Tree masih menunjukkan performa terbaik, namun tidak terlalu jauh berbeda dengan KNN. Naive Bayes kembali menjadi model dengan performa paling rendah. Hal ini menunjukkan bahwa kategori harga sedang paling sulit dibedakan karena memiliki karakteristik yang mirip dengan kategori rendah maupun tinggi.


Hasil Analisis Klasifikasi

ROC ANALYSIS - HIGH



Pada kategori harga tinggi, performa model kembali meningkat. Kurva ROC berada jauh di atas garis diagonal, menunjukkan bahwa model mampu mengenali rumah mahal dengan cukup baik. Random Forest kembali menjadi model terbaik, diikuti oleh Decision Tree dan KNN. Naive Bayes tetap memiliki performa paling rendah, meskipun masih berada pada kategori cukup baik. Hal ini menunjukkan bahwa harga rumah tinggi lebih mudah dikenali dibandingkan harga sedang.

Analisis Regression



Hasil Analisis Regression

TABEL METRIK R², RMSE, MAE, MAPE

Cross validation

Number of folds: 5

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Model	MSE	RMSE	MAE	MAPE	R ²
Linear Regression (1)	48516665601.212	220264.990	140759.859	29.272	0.652
Random Forest (1)	37265524907.487	193042.806	120200.142	24.470	0.733
Gradient Boosting (1)	35630770704.825	188761.147	121783.456	25.377	0.744

Compare models by: Mean square error

☐ Negligible diff.: 0.1

	Random Forest (1)	Linear Regression (1)	Gradient Boosting (1)
Random Forest (1)		0.003	0.826
Linear Regression (1)	0.997		0.995
Gradient Boosting (1)	0.174	0.005	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

17.3k | -

17.3k | 3×17291

Stratification is ignored for regression

Berdasarkan hasil evaluasi menggunakan metode 5-Fold Cross Validation, ketiga model regresi menunjukkan performa yang berbeda-beda dalam memprediksi harga rumah (price) pada dataset King County House Sales.


Gradient Boosting menjadi model terbaik dengan nilai $R^2 = 0.744$, artinya model ini mampumenjelaskan 74.4% variasi harga rumah dari data. Nilai RMSE sebesar 188.761 dan MAE sebesar 121.783 menunjukkan rata-rata selisih prediksi dengan harga aktual cukup wajarmengingat rentang harga properti di King County yang sangat lebar. MAPE sebesar 25.377% mengindikasikan rata-rata persentase kesalahan prediksi sekitar 25%.

Random Forest berada di posisi kedua dengan $R^2 = 0.733$, sedikit di bawah Gradient Boosting. Meskipun nilai RMSE dan MAE-nya sedikit lebih tinggi, selisihnya tidak terlalusignifikan sehingga kedua model ini dapat dianggap setara dalam performa.

Linear Regression menunjukkan performa paling rendah dengan $R^2 = 0.652$, RMSE 220.264, dan MAPE 29.272%. Hal ini mengindikasikan bahwa hubungan antara fitur-fitur propertidengan harga rumah bersifat non-linear, sehingga algoritma berbasis pohon seperti Gradient Boosting dan Random Forest lebih mampu menangkap pola kompleks dalam data.

Hasil Analisis Regression


PREDICTED VS ACTUAL PLOT (SCATTER PLOT)



Model Random Forest menunjukkan hasil yang paling baik dibandingkan dua model lainnya. Titik-titik data membentuk pola diagonal dari kiri bawah ke kanan atas yang cukup konsisten, mengindikasikan bahwa nilai prediksi model mendekati nilai harga rumah yang sebenarnya.

Plot Predicted vs Actual model Random Forest menunjukkan hasil terbaik dibanding dua model lainnya, dengan titik-titik yang membentuk pola diagonal paling konsisten dan terkonsentrasi terutama pada rentang harga 0 - 1.500.000. Berbeda dengan Linear Regression yang menghasilkan prediksi bernilai negatif dan Gradient Boosting yang sebarannya lebih jarang, Random Forest tidak menghasilkan prediksi di bawah nol sehingga lebih masuk akal secara bisnis. Kelemahan yang masih terlihat adalah penyimpangan prediksi pada harga di atas 3.000.000, namun hal ini wajar karena data pada rentang harga tersebut sangat sedikit.

INTERPRETASI RESIDUAL PLOT



Plot Predicted vs Actual model Random Forest menunjukkan hasil terbaik dibanding dua model lainnya, dengan titik-titik yang membentuk pola diagonal paling konsisten dan terkonsentrasi terutama pada rentang harga 0 - 1.500.000. Berbeda dengan Linear Regression yang menghasilkan prediksi bernilai negatif dan Gradient Boosting yang sebarannya lebih jarang, Random Forest tidak menghasilkan prediksi di bawah nol sehingga lebih masuk akal secara bisnis. Kelemahan yang masih terlihat adalah penyimpangan prediksi pada harga di atas 3.000.000, namun hal ini wajar karena data pada rentang harga tersebut sangat sedikit.

Hasil Analisis Regression

INTERPRETASI 3 VARIABEL PALING BERPENGARUH


Rank (1) - Orange

		#	Univar. reg.	RReliefF
1	sqft_living		21001.910	0.020
2	grade		17360.635	0.016
3	sqft_above		12514.061	0.024
4	sqft_living15		11265.865	0.036
5	bathrooms		8228.943	0.038
6	view		4050.459	0.000
7	sqft_basement		2531.506	0.023
8	bedrooms		2270.655	0.017
9	waterfront		1650.463	0.000
10	floors		1525.706	0.001
11	sqft_lot		175.140	0.004
12	sqft_lot15		147.907	0.006
13	yr_built		63.229	0.035
14	condition		28.611	0.000


≡ ? | 21.6k | - 21.6k | 14 | 5

- sqft_living (21.001)** merupakan variabel paling dominan, yaitu luas area bangunan yang dapat dihuni. Semakin luas rumah, semakin tinggi harga jualnya. Hal ini sangat logis karena pembeli properti umumnya menjadikan luas bangunan sebagai pertimbangan utama dalam menentukan nilai suatu properti.
- grade (17.360)** adalah variabel kedua paling berpengaruh, yang merepresentasikan kualitas konstruksi dan desain rumah berdasarkan sistem penilaian King County. Rumah dengan grade tinggi mencerminkan material premium dan desain yang lebih baik sehingga nilainya jauh lebih tinggi di pasar properti.
- sqft_above (12.514)** merupakan luas lantai di atas tanah tidak termasuk basement. Variabel ini berkorelasi kuat dengan harga karena luas lantai utama yang besar mencerminkan ukuran rumah yang lebih besar dan nyaman untuk dihuni.


Analisis Clustering



Hasil Analisis Clustering




Untuk menentukan jumlah cluster yang optimal. K-Means di setting dengan format From 2 to 8. Dari hasil diatas, nilai silhouette tertinggi berada pada K=2 dengan skor 0,308, namun pembagian menjadi 2 kelompok ini dinilai kurang menggambarkan segmentasi pasar, sehingga kami memilih K=3




Dari hasil Silhouette diatas menggambarkan 3 kelompok dengan warna yang berbeda-beda. Cluster 1 dengan warna biru berada dibagian paling atas dengan nilai silhouette rata rata 0,081 dimana nilai ini tergolong rendah yang berarti beberapa bagian dari cluster ini kurang optimal karena jaraknya ke cluster lain tidak berbeda jauh. Cluster C2 berwarna merah dengan nilai silhouette rata -rata 0,172 dimana ini dinilai cukup merata. Sedangkan cluster C3 berwarna hijau menjadi paling unggul diantara cluster yang lainnya dengan nilai 0,258.

Hasil Analisis Clustering



Dari Scatter plot yang dihasilkan cluster C2 (Merah) mengelompok rapat di bagian kiri bawah grafik yang berarti properti dengan luas bangunan yang kecil dan harga yang murah. Cluster C2 (Biru) menyebar di bagian tengah sampai kanan grafik yang berarti properti dengan luas bangunan yang sedang hingga besar. Sementara cluster C3 (Hijau) hanya diwakili oleh sedikit titik yang berada di area harga yang tinggi, yang berarti kelompok properti premium dengan harga jauh diatas rata-rata



Hasil Hierarchical Clustering dengan metode Ward linkage membentuk tiga cluster yang terlihat jelas pada dendrogram. Cluster C1 (biru) memiliki anggota paling banyak dengan cabang yang padat, menggambarkan bahwa data di dalamnya cukup mirip satu sama lain. Cluster C2 (merah) memiliki anggota paling sedikit tapi seragam sehingga pengelompokannya paling ketat. Sedangkan Cluster C3 (hijau) memiliki jumlah anggota yang cukup banyak dengan variasi data yang lebih beragam dibanding C2.

Sintesis dan Implikasi Terintegrasi

Dari ketiga analisis yang sudah kami lakukan, ketiganya secara konsisten menunjuk pada variabel yang sama sebagai faktor paling berpengaruh terhadap harga rumah, yaitu sqft_living, grade, dan sqft_above. Random Forest dan Gradient Boosting menjadi model terbaik di classification maupun regression karena data harga rumah memang tidak punya pola yang sederhana sehingga model yang lebih fleksibel lebih cocok dipakai. Dari clustering, tiga segmen pasar terbentuk dengan jelas mulai dari properti murah, menengah, sampai premium, dan hasilnya konsisten antara K-Means maupun Hierarchical Clustering.

Dari hasil ini, ada tiga rekomendasi yang bisa kami berikan. Pertama, developer properti sebaiknya fokus meningkatkan kualitas konstruksi dan luas bangunan karena itu yang paling langsung berdampak ke harga jual. Kedua, segmentasi dari clustering bisa dijadikan dasar strategi pemasaran yang lebih terarah sesuai karakteristik tiap kelompok properti. Ketiga, model prediksi harga yang sudah dibangun bisa dikembangkan jadi alat bantu estimasi harga untuk agen properti maupun pihak bank."

Kesimpulan

Dari ketiga analisis yang sudah kami lakukan, semuanya secara konsisten menunjuk pada sqft_living, grade, dan sqft_above sebagai variabel paling berpengaruh terhadap harga rumah. Random Forest jadi model terbaik di classification dengan AUC 0,826, Gradient Boosting dan Random Forest sama-sama unggul di regression dengan R^2 di atas 0,73, dan di clustering tiga kelompok properti terbentuk dengan jelas mulai dari yang murah, menengah, sampai premium.

Saran

Untuk pengembangan analisis, model klasifikasi bisa dicoba ditingkatkan dengan XGBoost atau SMOTE, dan untuk regresi bisa ditambahkan variabel eksternal seperti jarak ke fasilitas umum supaya prediksinya lebih akurat. Untuk pelaku bisnis properti, sebaiknya fokus meningkatkan kualitas dan luas bangunan, memanfaatkan segmentasi clustering sebagai panduan strategi pemasaran, dan model prediksi yang sudah dibangun bisa dikembangkan jadi alat bantu estimasi harga untuk agen properti maupun pihak bank.



Thank you for your Attention !

