



KELOMPOK 07



Kampus
Merdeka
INDONESIA JAYA

ANALISIS MARKETING CAMPAIGN RESPONSE MENGUNAKAN ORANGE DATA MINING

ANGGOTA KELOMPOK:

2310112007 Tiara Fajria Rahma

2310112037 Amanda Maheswari Fatima Diaz

2310112081 Yan Delon Simatupang



Dosen Pengampu : Dr. Donny Maha Putra



PENDAHULUAN

Kampanye pemasaran deposito tidak dapat dilakukan kepada seluruh nasabah dengan pendekatan yang sama, karena setiap nasabah memiliki peluang respons yang berbeda. Jika targeting tidak tepat, biaya promosi, waktu, dan upaya pemasaran menjadi kurang efisien. Oleh karena itu, diperlukan analisis berbasis data untuk membantu bank mengidentifikasi nasabah yang berpotensi merespons positif, memahami faktor yang berkaitan dengan nilai saldo, serta membentuk segmentasi nasabah untuk mendukung strategi pemasaran yang lebih tepat sasaran.

RUMUSAN MASALAH:

1. Bagaimana analisis classification digunakan untuk memprediksi respons nasabah terhadap penawaran deposito?
2. Bagaimana analisis regression digunakan untuk melihat faktor yang berkaitan dengan nilai saldo nasabah?
3. Bagaimana analisis clustering digunakan untuk membentuk segmentasi nasabah berdasarkan karakteristik yang dimiliki?



EDA DAN DATA PREPARATION

- **Exploratory Data Analysis (EDA)**

EDA (Analisis Data Eksploratori) merupakan tahap awal untuk memahami data yang dipilih dari sumber-sumber seperti Kaggle. Data yang digunakan yaitu “Bank Marketing Dataset” oleh Janio Martinez Bachman, berisi 11.162 baris dan 17 kolom yang berkaitan dengan tanggapan nasabah bank terhadap penawaran deposito. Kumpulan data ini terdiri dari dua jenis variabel: variabel independen, yang menggambarkan karakteristik nasabah (age, job, education, marital, housing, dan lain sebagainya), dan variabel dependen merupakan variabel hasil yang ingin diprediksi, yaitu apakah nasabah menerima penawaran deposito atau tidak. Tipe data disini ada 2 jenis yaitu numeric dan categorical. Data dengan jenis numeric yaitu age, balance, day, duration, campaign pdays, previous, sedangkan data berjenis categorical yaitu job, marital, education, default, housing, loan, contact, month, poutcome, dan deposit

- **Data Preparation**

Setelah memahami dan mengenal isi data dari bank marketing dataset, kami melakukan data preparation, yang dimana data ini cek dulu apakah ada data yang berduplikat, jika ada data duplikat maka akan dihapus agar data lebih konsisten. Dalam memilih data set ini, dipastikan bahwa variabel yang dimiliki jelas namanya dan sesuai. Hal ini dilakukan karna agar olah datanya menjadi efektif dan optimal.

ANALISIS CLASSIFICATION

Dataset : Bank Marketing → 11.162 data nasabah
Software : Orange Data Mining
Target Prediksi : “deposit” (Yes / No)

Variabel Target (Y) → deposit


- Yes = nasabah berlangganan deposito
- No = nasabah menolak / tidak merespons

Tujuan Metode : Untuk memprediksi respon nasabah terhadap produk deposito ("Yes" vs "No") untuk efisiensi Marketing Campaign.

Variabel Fitur (X)

- | | | |
|-------------|-----------|------------|
| • age | • balance | • month |
| • job | • housing | • campaign |
| • marital | • loan | • pdays |
| • education | • contact | • previous |
| • default | • day | • poutcome |

WORKFLOW ANALISIS CLASSIFICATION



Tahapan Workflow

- **Step 1** → File : input dataset
- **Step 2** → Select Columns : memilih target dan fitur
- **Step 3** → Preprocess : normalisasi data
- **Step 4** → Data Sampler : split training 80% dan testing 20%
- **Step 5** → Hubungkan dengan model (kNN, Tree, Random Forest, Naive Bayes, dan AdaBoost)
- **Step 6** → Test & Score : evaluasi model
- **Step 7** → Confusion Matrix & ROC Analysis
- **Step 8** → Predictions : simulasi prediksi data baru

ANALAYZING BANK MARKETING

HASIL ANALISIS

TEST AND SCORE

Model	AUC	AC (Accuracy)	F1-Score	Precision	Recall
Random Forest	0.784	0.729	0.727	0.732	0.729
KNN	0.739	0.691	0.689	0.693	0.691
Naive Bayes	0.740	0.688	0.685	0.689	0.688
Decision Tree	0.640	0.649	0.648	0.648	0.649
AdaBoost	0.633	0.634	0.634	0.634	0.634

Tabel 4.1 Komparasi matrik antar algoritma

Dari hasil uji menggunakan metode 10-fold Cross Validation, menunjukkan adanya variasi performa yang signifikan antar model. Model **Random Forest** lebih unggul dari seluruh algoritma dengan **Accuracy (CA) 0,729** dan **AUC 0,784**, membuktikan ketangguhannya dalam menangani kompleksitas data perbankan. Di posisi berikutnya, **kNN (n=7)** dan **Naive Bayes** menunjukkan hasil yang kompetitif dengan akurasi di kisaran **68,8% - 69,1%**, yang menandakan bahwa pola profil nasabah cukup konsisten. Sebaliknya, model **Decision Tree (64,9%)** dan **AdaBoost (63,4%)** memberikan hasil paling rendah, mengindikasikan bahwa model tunggal atau teknik boosting sederhana kurang mampu meredam noise pada dataset ini dibandingkan pendekatan ensemble berbasis hutan (forest).

ANALYZING BANK MARKETING

HASIL ANALISIS

CONFUSION MATRIX

✓ Random Forest

Actual	Predicted		
	no	yes	
	no	yes	Σ
no	71.6 %	25.1 %	4707
yes	28.4 %	74.9 %	4222
Σ	5305	3624	8929

✓ k-NN

Actual	Predicted		
	no	yes	
	no	yes	Σ
no	68.3 %	29.7 %	4707
yes	31.7 %	70.3 %	4222
Σ	5322	3607	8929


Analisis melalui Confusion Matrix dilakukan untuk mengukur seberapa besar tingkat kepercayaan bank saat model memprediksi nasabah akan mengambil deposito (Target "**Yes**"). Nilai yang dihasilkan dari model **Random Forest** menunjukkan keunggulan dengan presisi tertinggi sebesar **74,9%**, yang secara nyata mampu meminimalisir risiko biaya pemasaran sia-sia. Model **kNN (n=7)** mengikuti dengan tingkat ketepatan **70,3%**, memberikan alternatif prediksi yang cukup reliabel. Sementara itu, model **Naive Bayes** dan **Decision Tree** berada di rentang **63% - 69%**, dan **AdaBoost** memberikan hasil terendah di angka **61,4%**. Jadi kesimpulannya, penggunaan Random Forest atau kNN sangat direkomendasikan untuk memastikan efisiensi kampanye agar lebih tepat sasaran pada nasabah potensial.

ANALYZING BANK MARKETING

HASIL ANALISIS

ROC ANALYSIS

Kurva ROC ini memvisualisasikan kemampuan model dalam membedakan nasabah yang benar-benar berminat ("**Yes**") dari yang tidak berminat ("**No**"). Secara visual, garis kurva **Random Forest** memiliki nilai **paling ideal** (paling mendekati sudut kiri atas) dengan skor **AUC 0,784**, membuktikan **akurasi** ilmiah sebesar **78,4%** dalam pemisahan kelas. Kurva **kNN** dan **Naive Bayes** menunjukkan performa yang cukup stabil di atas garis diagonal dengan nilai **AUC** sekitar **0,74**. Namun, kurva **AdaBoost** dan **Decision Tree** terlihat paling mendekati **garis diagonal tengah**, yang mengonfirmasi bahwa kedua model tersebut kurang efektif dalam membedakan karakteristik nasabah pada dataset kampanye pemasaran bank ini.



ANALISIS REGRESSION

Dataset : Bank Marketing → 11.162 data nasabah
Software : Orange Data Mining
Target Prediksi : “Balance”

→ Variabel Target (Y) → Balance


- Yes = nasabah berlangganan deposito
- No = nasabah menolak / tidak merespons

Tujuan Metode : Untuk mengetahui faktor apa saja yang mempengaruhi saldo nasabah (balance)

→ Variabel Fitur (X)

- | | | |
|-------------|------------|------------|
| • age | • deposito | • month |
| • job | • housing | • campaign |
| • marital | • loan | • pdays |
| • education | • contact | • previous |
| • default | • day | • poutcome |

WORKFLOW ANALISIS REGRESSION



- **Step 1** : File → Input Dataset
- **Step 2** : Select Columns → klasifikasikan target dan features
- **Step 3** : Rank → untuk melihat hasil dari 3 variabel
- **Step 4** : Hubungkan dengan 3 model (Linear regression, tree dan random forest)
- **Step 5** : Test and Score
- **Step 6** : Predictions
- **Step 7** : Scatter Plot → grafik dengan X : balance, dan Y: Linear Regression



HASIL ANALISIS

TEST AND SCORE

Pada test and score ini kami setting number of folds menjadi 10, sehingga kami dapat melihat model mana yang paling tinggi. Nah di widget itu menunjukkan bahwa “Linear regression” merupakan model yang paling tinggi, karena model ini menjelaskan 3,7% variasi saldo nasabah. Sedangkan regression tree dan random forest itu memiliki nilai yang lebih rendah sehingga model tersebut sulit untuk memprediksi saldo yang dimiliki nasabah. Jadi dapat disimpulkan R^2 yang paling akurat dalam prediksi yaitu linear regression. Rendahnya nilai R^2 secara keseluruhan menunjukkan bahwa variabel dalam dataset bank marketing memiliki variasi yang tinggi, sehingga sulit untuk melakukan prediksi secara akurat.

Plot Predicted vs Actual

Berdasarkan Plot predicted vs actual, kami gunakan x itu “balance” dan y “linear regression”. kenapa pilih begitu, karena balance kan memang nilai nyata dari dataset, sedangkan linear regression itu salah satu model yang digunakan untuk memprediksi hasil. Nah melalui plot predicted vs actual ini kami dapat melihat bahwa model linear regression cenderung memiliki kumpulan prediksi dengan saldo rendah.



HASIL ANALISIS

Residual Plot

Untuk melihat residual plot (sis), maka bisa dilihat dari kolom pertama yaitu di balance ada nilai asli sebesar 2476, dan di kolom linear regression sebesar 1524.03. Nah jadi residualnya adalah $2476 - 1524.03 = 951.97$, sehingga jika angka ini di pindahkan ke grafik maka titik tersebut berada jauh dari atas garis nol, sehingga hasil menunjukkan bahwa model linear regression belum kuat untuk memprediksi saldo nasabah secara akurat

Rank → interpretasi 3 variabel

- Job ini memiliki korelasi atau pengaruh paling kuat terhadap variabel target (balance) atau nilai saldo.
- Month ini sangat berpengaruh terhadap saldo nasabah (balance).
- Education itu berpengaruh terhadap saldo yang dimiliki nasabah (balance).

Predictions - Orange

File

View

Window

Help

Shown regression error: Difference

Restore Original Order


	balance	Linear Regression	Tree	Random Forest	Fold	age	job	marital	education	default	housing	loan	contact	day	c
2476	1524.03	1273.97	1235.08	1	55	services	married	secondary	no	yes	no	unknown	5	579	
703	1690.76	1375.64	1979.9	1	31	technician	single	tertiary	no	yes	no	unknown	8	943	
10	1280.11	928.524	1591.5	1	40	blue-collar	married	secondary	no	yes	no	unknown	9	1692	
311	1823.29	1375.64	2682.44	1	32	management	single	tertiary	no	no	no	unknown	12	757	
4	1130.17	928.524	781.531	1	23	entrepreneur	single	primary	no	yes	no	unknown	13	395	
1949	1968.7	1375.64	2303.04	1	48	management	married	tertiary	no	yes	no	unknown	13	683	
3923	1421.68	1273.97	1704.77	1	52	housemaid	married	secondary	no	yes	no	unknown	14	942	
1618	1585.75	928.524	1681.04	1	41	blue-collar	single	primary	no	yes	no	unknown	14	1553	
313	2027.57	1273.97	960.489	1	60	services	single	primary	no	yes	no	unknown	15	920	
92	1001.29	928.524	1099.51	1	31	blue-collar	married	secondary	no	yes	no	unknown	16	688	
695	693.079	487.948	450.064	1	34	blue-collar	married	primary	no	yes	yes	unknown	16	1064	
122	1475.08	2653.9	2907.76	1	37	management	divorced	tertiary	no	yes	no	unknown	19	1622	
880	1253.35	1375.64	610.653	1	30	technician	single	tertiary	no	yes	yes	unknown	19	967	
102	1268.04	928.524	1156.45	1	35	blue-collar	married	primary	no	yes	no	unknown	20	1334	
408	773.564	487.948	534.365	1	36	blue-collar	married	primary	no	yes	yes	unknown	20	1063	
4499	1517.73	928.524	2228.24	1	34	retired	married	primary	no	no	no	unknown	21	1681	
5773	1871.58	1375.64	1782.6	1	44	management	divorced	tertiary	no	no	no	unknown	23	597	
1262	1517.35	928.524	1278.85	1	44	technician	divorced	secondary	no	yes	no	unknown	26	788	
0	964.04	487.948	1487.88	1	30	entrepreneur	single	primary	no	yes	yes	unknown	27	1051	
589	2093.41	1273.97	1402.91	1	56	technician	married	secondary	no	yes	no	unknown	29	535	
-20	1222.62	928.524	1120.22	1	29	blue-collar	single	secondary	no	yes	no	unknown	29	814	
1279	1556.7	1618.64	847.321	1	32	technician	single	secondary	no	yes	no	unknown	3	1173	
-754	-51.3523	854.874	21.1378	1	40	self-employed	married	secondary	yes	yes	yes	unknown	3	941	
178	1275.55	1618.64	938.612	1	27	management	single	secondary	no	yes	no	unknown	3	732	
416	1931.74	1618.64	1375.53	1	50	technician	married	secondary	no	yes	no	unknown	5	494	
319	928.054	1618.64	1148.6	1	37	services	divorced	secondary	no	yes	no	unknown	6	467	
-46	1639.91	1618.64	1786.99	1	49	management	divorced	secondary	no	yes	no	unknown	9	1055	

Scoring Methods				
☒	Univariate Regression			
☒	RReliefF			
	#	Univar. reg.	RReliefF	
1	N age	NA	0.090	
2	C job	12	0.220	
3	C marital	3	0.059	
4	C education	4	0.159	
5	C default	2	0.000	
6	C housing	2	0.037	
7	C loan	2	0.041	
8	C contact	3	0.053	
9	N day	NA	0.124	
10	N duration	NA	0.056	
11	C month	12	0.204	
12	N campaign	NA	0.018	
13	N pdays	NA	0.021	
14	N previous	NA	0.007	
15	C poutcome	4	0.079	
16	C deposit	2	0.055	

ANALISIS CLUSTERING

WORKFLOW:

- Dimulai dari Input dataset melalui widget file.
- Setelah itu file dihubungkan ke widget select columns dan pindahkan variabel kategorikal ke ignored.
- Kemudian masukkan widget data sampler, dan setting fixed sample size dengan instances 5000 (batas max. K-means). Hubungkan dengan select columns.
- Tambahkan Widget K-means dan widget visualisasinya menggunakan scatter plot dan silhouette plot. Hubungkan k-means dengan data sampler dan scatter plot.
- Tambahkan Widget distances untuk menghubungkan widget hierarchical clustering dengan data sampler, dan widget visualisasinya menggunakan box plot.
- Tambahkan Widget DBSCAN dan visualisainya menggunakan scatter plot.



HASIL ANALISIS K-MEANS

Silhouette Scores

Pada analisis K-Means clustering kami menggunakan 2 Cluster. Karena silhouette score menunjukkan nilai tertinggi pada K=2, yaitu sebesar 0,829. Artinya hasil pemisahan data terbaik ketika nasabah dibagi dalam 2 cluster.

Scatter Plot K-Means




Pada Scatter plot kami menggunakan variabel age sebagai sumbu (X) dan balance sebagai sumbu (Y). Age menunjukkan umur nasabah, Sementara balance menunjukkan saldo nasabah.

Interpretasi Cluster:

1. C1 dapat dibaca sebagai kelompok nasabah dengan saldo rendah hingga menengah.
2. C2 dapat dibaca sebagai kelompok nasabah dengan saldo lebih tinggi.

Scatter Plot DBSCAN

Hasil scatter plot DBSCAN kurang lebih sama dengan K-Means




HASIL ANALISIS HIERARCHICAL

Scatter Plot Hierarchical

Pada Scatter plot kami menggunakan variabel age sebagai sumbu (X) dan balance sebagai sumbu (Y). Age menunjukkan umur nasabah, Sementara balance menunjukkan saldo nasabah.

Interpretasi Cluster:

1. C1 dapat dibaca sebagai kelompok nasabah dengan saldo sangat tinggi atau nasabah bernilai tinggi bagi bank.
2. C2 menggambarkan kelompok umum nasabah yang saldo rekeningnya tidak terlalu tinggi.



KESIMPULAN ANALISIS CLUSTERING

Ketiga metode clustering sama-sama menunjukkan bahwa data nasabah membentuk 2 segmen. Kelompok mayoritas nasabah dengan saldo rendah hingga menengah dan kelompok yang lebih kecil dengan saldo lebih tinggi. Maka dari itu, hasil analisis clustering ini menekankan pada perbedaan saldo nasabah dibanding variabel/karakteristik lainnya.

SINTESIS TERINTEGRASI

Kesamaan Temuan:

Classification, regression, dan clustering menunjukkan pola yang saling mendukung dalam membaca perilaku nasabah.

Fitur Konsisten:

Fitur yang paling sering muncul sebagai penentu adalah balance, duration, dan poutcome.

Keterkaitan Clustering:

Hasil clustering membentuk 2 segmen utama, yaitu kelompok mayoritas nasabah dengan saldo rendah–menengah dan kelompok kecil dengan saldo lebih tinggi.

Rekomendasi Bisnis:

Bank dapat menggabungkan hasil classification dan clustering untuk menentukan target nasabah dan menyesuaikan pendekatan pemasaran agar lebih efisien dan tepat sasaran.

IMPLIKASI BISNIS

- Strategi kampanye deposito sebaiknya dilakukan secara lebih selektif dan berbasis data
- Bank dapat memprioritaskan nasabah dengan peluang respons lebih tinggi
- Segmentasi nasabah berdasarkan kelompok saldo dapat membantu bank menyesuaikan pendekatan pemasaran
- Penawaran yang berbeda untuk tiap segmen dapat membuat campaign lebih efisien dan lebih tepat sasaran
- Analisis regresi lebih tepat digunakan sebagai pendukung interpretasi, bukan alat utama penentuan target



KELOMPOK 07

TERIMA KASIH

