

Project Orange Data Mining

SALES AND REVENUE PREDICTION ANALYSIS

Kelompok 8



Hanifah Nabilah
2310112049



Abyan Mumtaz Z
2310112151



Rizma Fathonah
2310112215

PENDAHULUAN

Perusahaan yang berdiri di bidang retail menghasilkan ratusan bahkan ribuan transaksi setiap harinya, terutama transaksi terkait penjualan (*Sales*). Data terkait penjualan ini memiliki berbagai informasi seperti informasi pelanggan, harga jual, pendapatan bersih, diskon, dan lain sebagainya. Dengan banyaknya informasi yang terkandung, data-data mentah yang ada tidak memiliki nilai strategis apabila tidak diolah menjadi informasi yang berguna dan bermakna. Namun, dalam mengelola data yang ada pun, perusahaan retail tidak bisa hanya mengandalkan analisis manual dalam mengambil keputusan, perlu adanya pendekatan analitis yang mampu menggali pola tersembunyi dari data dalam jumlah banyak.

Rumusan Masalah

1. Bagaimana data terkait penjualan dan pendapat di perusahaan retail dapat dianalisis menggunakan teknik *data mining*?
2. Bagaimana metode *classification*, *regression*, dan *clustering* dapat diterapkan pada dataset yang ada?
3. Bagaimana hasil analisis dan sintesis dari ketiga metode yang dipakai dapat menghasilkan *insight* untuk pengambilan keputusan pada bisnis retail?



KAJIAN PUSTAKA DAN METODE

Data Mining

Data mining adalah proses analisis data yang banyak digunakan untuk menemukan pola atau hubungan serta informasi yang tidak ditampilkan secara eksplisit namun memiliki nilai guna.

Hadirnya data mining ini bertujuan untuk mengubah data mentah sehingga bisa dijadikan informasi yang dapat dimanfaatkan dalam pengambilan keputusan dengan cara yang lebih efisien dan berbasis data

Machine Learning

Machine learning adalah bagian dari kecerdasan buatan (*artificial intelligence*) yang dimana sistem tersebut belajar melalui data dan kemudian meningkatkan performansi tanpa perlu dikodekan dengan cara manual



Metode

Menggunakan Orange Data Mining sebagai platform. Dan menggunakan 3 model yaitu *classification*, *regression*, dan *clustering*.

EDA & DATA PREPARATION

Dataset yang digunakan dalam penelitian ini merupakan dataset sintetik yang merepresentasikan informasi penjualan komprehensif dari sebuah perusahaan, mencakup 5.000 entri transaksi



Atribut dalam Dataset

- Order No
- Order Date
- Customer Name
- Address
- City
- State
- Customer Type
- Account Manager
- Order Priority
- Product Name
- Product Category
- Product Container
- Ship Mode
- Ship Date
- Retail Price
- Profit Margin
- Quantity
- Sub Total
- Discount %
- Discount \$
- Order Total
- Shipping Cost
- Total

CLASSIFICATION



Hasil Data yang berhasil diprediksi dengan benar (Confussion Matrix)

- KNN: 1.748 data dari 3.500 data (menggunakan sampling 70:30)
- Decision Tree: 4.318 data dari 15.000 data
- Random Forest: 3.816 data dari 15.000 data
- Naive Bayes: 3.464 data dari 15.000 data
- AdaBoost: 4.287 data dari 15.000 data

Jika melihat dari besar angka maka Decison Tree merupakan algoritma yang menghasilkan prediksi data benar paling banyak. Tapi jika dilihat dari perbandingan data per algoritma maka yang paling akurat adalah KNN dengan angka akurat 49,9%

CLASSIFICATION

Algoritma	AUC	CA	F1	Prec	Recall	MCC
KNN	0,831	0,499	0,498	0,506	0,499	0,375
Decision Tree	0,580	0,288	0,287	0,293	0,288	0,110
Random Forest	0,564	0,254	0,254	0,253	0,254	0,064
Naive Bayes	0,533	0,231	0,219	0,223	0,231	0,028
AdaBoost	0,566	0,286	0,286	0,287	0,286	0,105

Algoritma dengan performa terbaik ialah KNN, dengan nilai AUC sebesar 0,831 serta didukung oleh accuracy, precision, recall, dan F1-score yang relatif lebih tinggi dibandingkan algoritma lainnya. Hal ini menunjukkan bahwa KNN lebih mampu membedakan kelas dan menghasilkan prediksi yang lebih seimbang, meskipun akurasi masih pada level menengah.

Hasil Test & Score

Naive Bayes memiliki performa paling rendah, dengan nilai AUC sebesar 0,533, accuracy 0,231, F1-score 0,219, precision 0,223, dan recall 0,231. Nilai tersebut menunjukkan bahwa model kurang mampu menangkap pola data dengan baik, sehingga hasil klasifikasinya cenderung kurang akurat.

REGRESSION

Tujuan

Mengestimasi nilai pendapatan total (Total) secara kontinu berdasarkan tren data historis.

Variabel Target

Total.

Variabel Fitur Utama

Cost Price, Retail Price, Profit Margin, Order Quantity, Sub Total, dan Shipping Cost.

Metode Pengujian

10-fold Cross Validation dengan rasio data 70:30.

Tabel Perbandingan Metrik

Algoritma Model	Mean Absolute Error (MAE)	Root Mean Squared Error (RMSE)	R-Squared (R2)
Gradient Boosting	0,000	0,000	1,000
Linear Regression	16,610	34,923	0,841
Random Forest	44,792	59,604	0,536
Tree (Regression Tree)	45,391	60,774	0,517

CLUSTERING


Mengelompokkan data transaksi berdasarkan pola pembelian pelanggan.

Variabel data: Order Quantity, Retail Price, dan Order Total

Mengambil sampel 30% dari 5.000 data (1.500 data)


A. ANALISIS K-MEANS

Scatter Plot




- Cluster 1 (biru): Mewakili pembelian dalam jumlah besar
- Cluster 2 (merah): Mewakili pembelian produk premium
- Cluster 3 (hijau): Mewakili pembelian paling umum dengan kepadatan tertinggi

Box Plot




Box plot menunjukkan distribusi cluster tidak merata (Cluster 1 terbesar, Cluster 3 berikutnya, Cluster 2 terkecil), yang berpotensi memengaruhi kualitas clustering, dengan Cluster 2 mencerminkan kelompok transaksi bernilai tinggi.

Silhouette Plot




Kualitas clustering belum optimal karena Cluster 1 (biru) dan Cluster 2 (merah) didominasi nilai negatif (menandakan overlap dan pemisahan kurang baik/stabil), sedangkan Cluster 3 (hijau) memiliki mayoritas nilai positif sehingga menjadi cluster dengan kualitas pemisahan terbaik.

B. ANALISIS HIERARCHICAL CLUSTERING



Metode Ward membagi data menjadi tiga cluster utama dengan karakteristik berbeda, yaitu Cluster 1 terbesar dan paling bervariasi, Cluster 2 kecil dengan kemiripan tinggi, dan Cluster 3 cukup besar dengan variasi sedang, yang didominasi Office Supplies serta menunjukkan hubungan kedekatan antar data melalui dendrogram yang tidak terlihat pada K-Means.

Box Plot



Box plot menunjukkan bahwa pada semua tingkat Order Priority, kategori Office Supplies mendominasi ($\pm 70\text{--}80\%$), diikuti Technology ($\pm 15\text{--}25\%$) dan Furniture paling kecil, sehingga mengindikasikan bahwa distribusi kategori produk relatif konsisten dan tidak terlalu dipengaruhi oleh prioritas pesanan.

SINTESIS TERINTEGRASI

Faktor Utama

Pendapatan dipengaruhi oleh Retail Price, Order Quantity, dan Product Category

Pola Penjualan

Produk dengan harga rendah (terutama Office Supplies) cenderung dibeli dalam jumlah besar sehingga menghasilkan volume transaksi tinggi, sedangkan produk dengan harga lebih tinggi dibeli dalam jumlah lebih sedikit namun memberikan kontribusi revenue yang besar

Hasil Analisis Model

- Linear Regression : memprediksi pendapatan dengan baik
- Classification : masih belum optimal karena adanya tumpang tindih antar kelas
- Clustering : menunjukkan pola yang sejalan dengan hasil regression

Ringkasan Pola Data

Terdapat dua karakter utama dalam penjualan:

- high volume–low price
- low volume–high value

Saran Manajerial

Perusahaan perlu fokus meningkatkan volume pada produk berharga rendah serta memberikan perhatian lebih pada produk berharga tinggi karena potensinya dalam meningkatkan revenue

»»» KESIMPULAN

Setelah melewati seluruh rangkaian tahapan mulai dari prapemr mendalam pada setiap algoritma, penelitian kelompok kami berhasil n melalui tiga sudut pandang analitis yang berbeda. Kesimpulan utama ini adalah adanya potensi prediksi pendapatan yang sangat akurat, di ditemukan bahwa variabel harga retail dan jumlah pesanan memiliki p terhadap total pendapatan. Algoritma Gradient Boosting menunjukka nilai R^2 sebesar 1,000, meskipun untuk kebutuhan bisnis harian, Line sebesar 0,841 dinilai lebih stabil dan mudah dipahami oleh pihak manajemen karena sirat hubungannya yang konsisten.

Di sisi lain, terdapat tantangan nyata dalam klasifikasi prioritas pesanan yang menunjukkan hasil belum optimal, di mana algoritma KNN menjadi yang terbaik di kelasnya dengan nilai AUC 0,831, namun akurasi masih berada di level menengah sebesar 49,9% dikarenakan adanya tumpang tindih karakteristik antar tingkat urgensi pesanan dalam data transaksi. Terakhir, melalui analisis segmentasi yang kontras pada tahap Clustering, kami berhasil mengidentifikasi dua pola perilaku belanja yang dominan, yaitu kelompok pembeli barang murah dalam jumlah banyak (volume tinggi) dan kelompok pembeli produk premium dengan nilai transaksi besar namun frekuensi lebih sedikit. Temuan ini mempertegas hasil regresi bahwa struktur pendapatan perusahaan memang ditopang secara kuat oleh kombinasi antara volume penjualan dan harga jual produk.



IMPLIKASI

Berdasarkan temuan-temuan tersebut, kami merekomendasikan beberapa hal yang dapat dipertimbangkan oleh pemangku kepentingan untuk kemajuan perusahaan. Perusahaan sangat disarankan untuk melakukan implementasi model yang menggunakan Linear Regression sebagai instrumen utama dalam pengambilan keputusan bulanan. Mengingat model ini mampu menangkap 84,1% variansi data, maka simulasi kenaikan harga atau volume pesanan untuk melihat dampaknya dapat dilakukan secara lebih ilmiah dan terukur.

Selain itu, diperlukan strategi pemasaran berbasis segmen untuk meningkatkan laba dengan membedakan perlakuan antara segmen pelanggan "Volume Tinggi" dan segmen "Premium". Produk kategori Office Supplies yang mendominasi transaksi (70%-80%) sebaiknya difokuskan pada efisiensi biaya kirim dan ketersediaan stok, sementara produk kategori Technology yang bernilai tinggi membutuhkan promosi khusus karena berpotensi memberikan kontribusi pendapatan yang besar dalam satu kali transaksi. Terakhir, perlu adanya penyempurnaan dalam sistem pencatatan data prioritas karena rendahnya akurasi model klasifikasi mengindikasikan bahwa kriteria Order Priority saat ini mungkin masih terlalu subjektif. Kami menyarankan agar departemen operasional merumuskan kembali kriteria urgensi pesanan berdasarkan variabel yang lebih kuantitatif agar sistem otomatisasi di masa depan dapat memprediksi prioritas pesanan dengan jauh lebih presisi.



THANK YOU

Kelompok 8
Kelas B - Analisis Big Data