



ORANGE DATA MINING

ANALYSIS DATA FRAUD AND ANOMALY DETECTION HEALTHCARE



Novanda Arinni
(2310112009)



Afifah Afra
(2310112065)



Auliya Zulkhaida Yachya
(2310112213)

Indikasi fraud atau kecurangan data tidak hanya terjadi di perusahaan manufaktur saja, tetapi ada juga pada pelayanan kesehatan. Hal tersebut menjadi masalah yang cukup serius karena terus mengalami peningkatan bersamaan dengan melebarnya sistem jaminan kesehatan dan digitalisasi data klaim. Penipuan, penyalahgunaan dalam layanan kesehatan dapat merugikan perusahaan asuransi, orang lain atau lingkungan sekitar. Dengan bertambahnya jumlah peserta dalam program layanan kesehatan, dan biaya yang tidak sedikit, semakin memicu peluang bagi praktik penipuan yang semakin pintar. Maka dari itu, dibuatlah sistem teknologi bernama Machine Learning (ML) dan algoritma deteksi anomali untuk mendeteksi adanya kemungkinan fraud. Sistem ini bekerja untuk menganalisa data dalam jumlah yang banyak dan dapat mendeteksi pola-pola transaksi yang tidak biasa atau pola yang aneh sehingga dianggap sebagai solusi efektif dan efisien.




Rumusan Masalah:

1. Bagaimana karakteristik data klaim kesehatan yang berpotensi menunjukkan pola fraud atau anomali?
2. Dari model algoritma yang sudah dilakukan, model algoritma data mining manakah yang memberikan hasil optimal dalam mendeteksi dan memprediksi fraud?
3. Sejauh mana model anomaly detection membedakan antara klaim yang benar dan klaim yang berpotensi fraud?

Tujuan Penelitian:

1. Untuk mengidentifikasi dan menganalisis karakteristik dan data klaim kesehatan yang berpotensi menunjukkan pola fraud atau anomali.
2. Untuk membandingkan dan mengevaluasi model algoritma data mining yang memberikan hasil optimal dalam mendeteksi dan memprediksi fraud.
3. Untuk mengetahui model anomaly detection yang dapat membedakan antara klaim yang benar dan klaim yang berpotensi fraud.



EDA & DATA PREPARATION

Dataset yang digunakan adalah dataset klaim asuransi kesehatan yang bersumber dari Kaggle dan telah berlisensi. Pada sumber aslinya, dataset ini berisi 10.000 data, namun dalam olah data ini digunakan 5.000 data untuk menyesuaikan proses analisis clustering, khususnya saat menggunakan K-Means di Orange Data Mining.

➤ Dataset kerja yang digunakan terdiri dari 20 atribut :

- | | |
|--------------------------|--|
| 1. Provider_ID | 11. Days_Between_Service_and_Claim |
| 2. Claim_ID | 12. Number_of_Claims_Per_Provider_Monthly |
| 3. Claim_Submission_Date | 13. Provider_Specialty: spesialisasi provider. |
| 4. Patient_Age | 14. Patient_State |
| 5. Patient_Gender | 15. Claim_Status |
| 6. Diagnosis_Code | 16. Is_Fraud |
| 7. Procedure_Code | 17. Length_of_Stay |
| 8. Claim_Amount | 18. Visit_Type |
| 9. Approved_Amount | 19. Chronic_Condition_Flag |
| 10. Insurance_Type | 20. Prior_Visits_12m |





Kajian Pustaka & Metode



Fraud

Fraud merupakan tindakan penipuan sengaja melalui manipulasi informasi untuk memperoleh keuntungan finansial secara melawan hukum, baik di sektor perbankan, perdagangan online, maupun layanan kesehatan.

Anomali Detection

Deteksi anomali adalah metode di mana dilakukan untuk mengidentifikasi data yang polanya berpotensi fraud dengan pelaku yang dianggap normal. Bisa terjadi saat transaksi online maupun transaksi secara langsung.


Metode Penelitian

- Menggunakan pendekatan kuantitatif dengan menggunakan aplikasi orange data mining.
- Orange data mining ini akan digunakan untuk melakukan Classification (mengelompokkan data), Regression (memprediksi nilai), dan Clustering (mengelompokkan data ke dalam beberapa kelompok).
- Classification (KNN, Decision Tree, Random Forest); Regresi (Linear Regression dan Random Forest Regression); dan Clustering (K-Means Clustering dan Hierarchical Clustering)





Classification



Berdasarkan Confusion Matrix menggunakan ketiga algoritma yaitu KNN, Decision Tree, dan Random Forest menunjukkan angka yang berbeda-beda. Hasil Confusion Matrix menggunakan model KNN untuk yang diklaim dan berhasil mendeteksi fraud dengan benar sebanyak 220 klaim, sedangkan model Decision Tree sebanyak 348 klaim, dan model Random Forest sebanyak 271 klaim. Dari ketiga model yang dilakukan, model algoritma Decision Tree dianggap akurat dalam mendeteksi fraud yang tepat dengan benar.



Classification

Evaluation results for target (None, show average over classes)


Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.936	0.961	0.955	0.962	0.961	0.711
Random Forest	0.958	0.958	0.956	0.955	0.958	0.700
Tree	0.952	0.979	0.979	0.979	0.979	0.861

Dilihat dari hasil model ketiga algoritma, berdasarkan tingkat akurasi, model Decision Tree lebih unggul dengan nilai 0,979 daripada model lain untuk mendeteksi klaim fraud. Lalu berdasarkan precision (presisi) model Decision Tree juga lebih unggul dengan nilai 0,979, berdasarkan recall, lagi-lagi model Decision Tree lebih unggul dengan nilai 0,979. Berdasarkan F1-Score Decision Tree memperoleh nilai 0,979. Akan tetapi, jika dari nilai AUC, Random Forest disini lebih tinggi dengan nilai 0,958. Meski begitu, hanya berbeda sedikit dengan Decision Tree.


Berdasarkan tabel komparasi metrik antar algoritma dengan ketiga model dan kelima tingkat akurasi yang sama, kesimpulannya menunjukkan kalau dari tingkat Accuracy, Precision, Recall, dan F1-Score, model Decision Tree memang yang paling unggul. Sedangkan pada tingkat ROC-AUC, model Random Forest yang paling unggul. Yang artinya tiap model algoritma ini memiliki tingkat ketepatan, keseimbangan dalam mengklaim sesuatu fraud dengan cara yang berbeda-beda.



REGRESSION




Random Forest Regression → Gabung dengan Linear Regression





Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	16786.097	129.561	71.863	13.226	13.267	0.897
Random Forest	19704.648	140.373	70.760	11.685	11.469	0.879
Gradient Boosting	15644.838	125.079	64.354	10.814	10.685	0.904

Model yang terbaik adalah model Gradient Boosting, di mana nilai R2 tertinggi (0,904) artinya kemampuan yang baik untuk menangkap hubungan pada pola *fraud*. Nilai RMSE terendah (125.079), Nilai MAE terendah (64.354), dan nilai MAPE terkecil (10.7%), menggambarkan kesalahan prediksi yang lebih sedikit dibandingkan model lainnya.





Visualisasi ini menunjukkan pola yang terjadi antara approved_amount dengan claim_amount. variabel ini berpengaruh secara positif.

Data ini menggambarkan semakin titiknya menjauh dari garis yang banyak titiknya, maka semakin tinggi resiko fraudnya dan harus diinvestigasi oleh pihak asuransi tersebut.

ANALISIS REGRESSION

Visualisasi ini menunjukkan pola yang terjadi antara days_between_service_and_claim dengan claim_amount. Variabel ini berpengaruh secara negatif. Karena data yang digambarkan dengan realitanya tidak sejalan. Pada saat pengajuan klaim dan saat itu juga disetujui, ini berpotensi *fraud*.



Visualisasi ini menunjukkan pola yang terjadi antara number_of_claims_per_provider_monthly dengan claim_amount. variabel ini berpengaruh secara positif.

Kalau bulan lalu kantor asuransi ini melayani 50 klaim, namun bulan ini melonjak menjadi 500 klaim tanpa adanya alasan yang logis dan jelas, maka ada kemungkinan indikasi *fraud* yang terjadi di kantor asuransi tersebut.



Clustering

Tahapan Algoritma K- Means

Memasukkan
Dataset

Widget : File

Penerapan Model
K-Means

Widget: K-Means

Visualisasi
Persebaran
Data

Widget: Scatter Plot

Evaluasi
Kualitas Cluster

Widget: Silhouette Plot

Tahapan Hierarchical Clustering

Mengatur Jarak
Data

Widget : Distances

Penerapan
Hierarchical
Clustering

Widget: Hierarchical
Clustering

Pengaturan
Hierarchical
Clustering

Max Depth = 5
Height Ratio = 75%.

Analisis
Karakteristik
Cluster

Widget: Box Plot

Tahapan DBSCAN

Penerapan Model
DBSCAN


Widget : DBSCAN

Analisis Data Inti
dan Non Core

Widget : Box plot



K-means (Scatter Plot)




Data terbagi menjadi 3 cluster utama:

- Cluster 1 (Biru): klaim rendah hingga menengah dengan jeda pengajuan lebih lama ($\pm 0-1.000$; 15-29 hari).
- Cluster 2 (Merah): klaim bernilai tinggi dengan persebaran paling luas (± 1.000 hingga > 5.000 ; 0-29 hari), cluster yang paling perlu diperhatikan dalam konteks fraud.
- Cluster 3 (Hijau): klaim bernilai rendah jeda pengajuan lebih singkat ($\pm 0-1.000$; 0-15 hari), dianggap sebagai kelompok klaim rutin.


ANALISIS CLUSTERING

K-means (SilhouettePlot)



- Cluster 1 (Biru) : rata-rata 0,040, menjadi cluster yang paling mendekati baik.
- Cluster 2 (Merah): rata-rata -0,020, kualitas pengelompokannya masih kurang baik.
- Cluster 3 (Hijau): rata-rata -0,116, menjadi cluster dengan kualitas pengelompokan paling lemah.


Hierarchical Clustering



Hasil hierarchical clustering melalui Box Plot Claim_Amount menunjukkan perbedaan rata-rata nilai klaim pada tiap cluster:

- C1: rata-rata tertinggi (1069,63) dan persebaran paling luas
- C2: rata-rata terendah (421,66)
- C3: rata-rata 544,44
- C4: rata-rata 594,82

DBSCAN



Box Plot dengan variabel Claim_Amount dan subgroup DBSCAN Core menunjukkan adanya perbedaan antara core point dan non-core point.

- Core point (1): rata-rata Claim_Amount = 555,91 dengan persebaran lebih kecil
- Non-core point (0): rata-rata Claim_Amount = 1935,37 dengan persebaran lebih luas



Universitas Pembangunan Nasional
"Veteran" Jakarta

SINTESIS TERINTEGRASI

➤ Apa Kesamaan Temuan antara Classification, Regression, dan Clustering?

Kesamaan yang dihasilkan dari olah data pada Classification, Regression, dan Clustering adalah pada keseragamannya dalam mengenali data claim amount (Jumlah yang diajukan) dan days between service and claim (jeda waktu pengajuan klaim asuransi). Kesamaannya dapat kita lihat dari hasil classification yang akurat dengan model decision tree (Classification Accuracy = 0.979) dan hasil regression gradient boosting (Koefisien Determinasi = 0.904). Bisa disimpulkan dengan adanya pengajuan asuransi dengan nominal tinggi dan waktu yang terlalu singkat adalah sinyal adanya fraud yang terjadi baik dari pasien maupun dari pihak penyedia layanannya.

➤ Apakah Fitur Penting di Satu Analisis Juga Penting di Analisis Lain?

Iya, ada beberapa fitur yang penting di lebih dari satu analisis. Dari hasil yang diperoleh, Claim_Amount jadi fitur yang paling konsisten karena muncul penting di analisis classification, regression, dan clustering. Selain itu, Days_Between_Service_and_Claim dan Number_of_Claims_Per_Provider_Monthly juga cukup berpengaruh karena berkaitan dengan pola klaim yang cepat diajukan dan jumlah klaim provider. Jadi, walaupun tiap analisis punya fokus yang berbeda, ada beberapa fitur yang tetap sama-sama penting, terutama fitur Claim_Amount.

CORPORATE
AUDIT





Universitas Pembangunan Nasional
"Veteran" Jakarta

SINTESIS TERINTEGRASI

➤ Apakah Cluster yang Terbentuk Memiliki Kecenderungan Kelas atau Target Tertentu?

Ya, cluster yang terbentuk ini memiliki kecenderungan kelas atau target tertentu yang berdasarkan nilai Claim_Amount dan karakteristik yang lain. Pada hasil analisis K-Means Clustering yang divisualisasikan melalui scatter plot dengan sumbu X = Claim_Amount dan sumbu Y = Days_Between_Service_and_Claim, terbagi menjadi 3 cluster. Pada cluster pertama didominasi oleh klaim dengan nominal rendah hingga menengah, cluster kedua memiliki persebaran paling luas dan menempati area klaim dengan nominal lebih besar sehingga berpotensi fraud. Dan pada cluster ketiga, menunjukkan rentang Claim_Amount 0 sampai 1000 yang relatif rendah nilai klaimnya.

➤ Rekomendasi Bisnis Apa yang Muncul dari Sintesis Ketiga Analisis?

Perusahaan yang bergerak di bidang pelayanan atau jasa kesehatan perlu fokus pada peningkatan alat penggunaan deteksi klaim dengan nilai yang tinggi dan hanya butuh waktu yang singkat untuk menangkap sinyal yang berpotensi fraud. Pada hasil analisis yang telah dilakukan, penggunaan algoritma Decision Tree dan Regression Gradient Boosting, memiliki nilai klaim yang tinggi (hampir mendekati 1) sehingga akurat untuk mendeteksi fraud dibandingkan dengan algoritma yang lain meski hanya berbeda sedikit.





KESIMPULAN & SARAN

KESIMPULAN



Klaim asuransi dengan nilai yang tinggi memiliki peluang yang besar untuk mendeteksi fraud. Model klasifikasi seperti Decision Tree dan Regresi Gradient Boosting mampu mendeteksi pola fraud dengan akurasi yang tinggi. Pada hasil analisis Clustering juga berhasil dalam memisahkan mana klaim yang normal dan yang aneh. Variabel utama disini yang berpengaruh adalah Claim_Amount dan Days_Between_Service_and_Claim. Maka dari itu, perusahaan di bidang pelayanan asuransi atau kesehatan, perlu untuk menggabungkan ketiga metode ini yaitu Classification, Regression, dan Clustering ke dalam sistem pengawasan perusahaan untuk meningkatkan keberhasilan dalam melacak fraud dan mengurangi atau jika bisa, menghilangkan risiko kerugian finansial yang tinggi.

SARAN

Mendeteksi fraud bisa menggunakan algoritma Classification dengan model yaitu Decision Tree pada software Orange Data Mining karena model ini mempunyai tingkat akurasi yang tinggi untuk klasifikasi klaim dan meminimalisir terjadinya fraud yang lolos. Penelitian selanjutnya yang menggunakan dataset yang sama bisa membandingkan pengolahan data dengan menggunakan algoritma yang sama dengan penelitian dan bisa mengembangkan pengolahan data dengan model algoritma yang berbeda dengan penelitian, agar bisa dibandingkan model algoritma yang ada pada penelitian ini dengan model yang berbeda.



Universitas Pembangunan Nasional
"Veteran" Jakarta



Kelompok 9

THANK YOU