



Kelompok 10

Ujian Tengah Semester Project

Education & Student Performance

Dosen Pengampu :

Dr. Donny Maha Putra, M.Ak.

Anggota Kelompok:

Kharisma Adi Meylani


2310112005

Aleluya Cinta Putri Andma

2310112141

Nadya Wulandari

2310112211





BAB 1 PENDAHULUAN

Latar Belakang

Performa akademik siswa dipengaruhi oleh berbagai faktor internal dan eksternal yang kompleks. Analisis secara manual sulit dilakukan, sehingga diperlukan pendekatan data mining. Melalui teknik seperti classification, regression, dan clustering, data dapat dianalisis untuk mendukung pengambilan keputusan yang lebih efektif dalam pendidikan.

Rumusan Masalah

Bagaimana model klasifikasi dapat memprediksi kategori performa siswa?

Bagaimana model regresi dimanfaatkan untuk memprediksi nilai atau tingkat performa akademik serta mengidentifikasi faktor yang berpengaruh?

Bagaimana clustering mengelompokkan siswa ke dalam beberapa segmen dan bagaimana keterkaitannya dengan hasil model klasifikasi dan regresi?





BAB 2

TINJAUAN TEORI & METODE

Tinjauan Teori

Data mining merupakan proses ekstraksi pola dan informasi penting dari data dalam jumlah besar menggunakan teknik statistik dan machine learning. Dalam bidang pendidikan, penerapannya dikenal sebagai Educational Data Mining (EDM) untuk menganalisis dan meningkatkan proses pembelajaran. Teknik utama yang digunakan meliputi classification, regression, dan clustering untuk mendukung analisis dan pengambilan keputusan.

Metode

Penelitian menggunakan pendekatan *data mining* menggunakan tools *Orange Data Mining*. dataset yang digunakan adalah data performa akademik siswa. tahapan meliputi *data preprocessing*, eksplorasi data, pemodelan data, dan evaluasi model. Teknik yang digunakan adalah *classification*, *regression*, dan *clustering*.





BAB 3 EDA & DATA PREPARATION

Data yang kami gunakan dalam project ini adalah Student Performance Data Set. Data ini membahas prestasi siswa tingkat menengah dari dua sekolah di Portugal. Terdapat 649 baris dan 33 kolom dalam data set ini, dengan rincian kolom:

Nama	Keterangan	Tipe Data
Schoolsup	dukungan sekolah tambahan	categorical
Famsup	adanya dukungan dari keluarga	categorical
Paid	kursus tambahan yang berbayaran	categorical
Activities	kegiatan ekstrakurikuler	categorical
Nursery	pernah masuk taman kanak kanak	categorical
Higher	ingin kuliah setelah lulus sekolah	categorical
Internet	akses internet di rumah	categorical
Romantic	sedang memiliki hubungan	categorical
Famrel	kualitas hubungan keluarga	categorical
Addres	Menjelaskan lokasi tempat tinggal	categorical
School	Sekolah siswa yaitu GP dan MS	categorical
Sex	Jenis kelamin siswa	categorical
Famsize	Jumlah anggota keluarga	categorical
Pstatus	Status orang tua yang tinggal bersama	categorical
Mjob	Pekerjaan ibu	categorical
Fjob	pekerjaan ayah	categorical
Reason	alasan memilih sekolah	categorical
Guardian	wali utama	categorical


Nama	Keterangan	Tipe Data
Medu	Pendidikan ibu (0-4)	numeric
Fedu	pendidikan ayah (0-4)	numeric
Travel Time	waktu perjalanan ke sekolah	numeric
Failures	jumlah kegagalan yang pernah dilalui	numeric
Freetime	qaktu luang setelah sekolah	numeric
Goout	frekuensi keluar dengan teman	numeric
Dalc	konsumsi alkohol di hari kerja	numeric
Walc	konsumsi alhokol di akhir pekan	numeric
Health	kondisi kesehatan saat ini	numeric
Absences	jumlah ketidakhadiran sekolah	numeric
G1	nilai kuartal pertama	numeric
G2	nilai kuartal kedua	numeric
G3	nilai akhir	numeric
G3	nilai akhir	numeric
Age	Usia siswa	numeric
Studytime	jam belajar per minggu (1-4)	numeric

Target yang digunakan:
Paid dan
Absence



BAB 4 CLASSIFICATION


Target yang digunakan:
Paid






CONFUSION MATRIX

CONFUSION MATRIX 1 (TERHUBUNG DENGAN RANDOM FOREST)




memprediksi bahwa jumlah “no” yaitu siswa yang tidak mengikuti kursus berbayar dengan benar memiliki total 361 dari 378 kasus

CONFUSION MATRIX 2 (TERHUBUNG DENGAN NAIVE BAYES, KNN DAN TREE)



confusion matrix naive bayes jika dilihat jumlah salah yang positif ada 92 siswa yang sebenarnya “no” diprediksi “yes”,


CONFUSION MATRIX 3 (TERHUBUNG DENGAN KNN)




KNN cukup baik memprediksi siswa yang negatif atau “no”



TEST AND SCORE



ROC-AUC




Naive Bayes mencatat nilai AUC tertinggi, yaitu 0,647 menjadi yang paling efektif dalam membedakan kedua kelas dibandingkan model yang lain. **kNN** mendapat nilai sebesar 0,533 dan **Decision Tree** sebesar 0,523 jadi kedua model tersebut masih dinilai cukup lemah. Berdasarkan metrics ROC-AUC, Naive Bayes lebih unggul.


1. **Accuracy**, KNN memiliki akurasi tertinggi yaitu 0,923 yang artinya 92,3% prediksi target Paid tepat.
2. **Precision**, untuk mengukur proporsi “yes” yang benar benar tepat. Nilai tertinggi tetap dicapai oleh KNN dengan nilai 0,883
3. **Recall**, KNN memiliki recall tertinggi 0,923 yang berarti KNN menjadi model paling efektif dalam mendeteksi siswa yang benar benar mengikuti kursus berbayar.
4. **F1-Score**, rata rata dari precision dan recall sehingga menyeimbangkan prediksi, KNN mencapai F1-Score tertinggi 0,983 menunjukkan hasil terbaik secara keseluruhan.



BAB 5 REGRESSION ANALYSIS


Absences (ketidakhadiran siswa)





Linear Regression

Proporsional dan menyebar



Random Forest

Overaging atau tidak menyebar

Plot Predicted vs Actual

Absences (ketidakhadiran siswa)

Linear Regression > Random Forest

Linear Regression memberikan sebaran prediksi yang lebih proporsional dan realistis dari ujung ke ujung dibandingkan Random Forest.

Analisis Numerik Linear Regression

- R² atau Koefisien Determinasi**
Linear Regression menghasilkan nilai R² sebesar **-0.005**, lebih tinggi dibandingkan Random Forest yaitu **-0.038**.
- RMSE atau Root Mean Squared Error**
Linear Regression menghasilkan nilai RMSE sebesar **4.649**, lebih rendah dibandingkan Random Forest yaitu **4.723**.
- MAE atau Mean Absolute Error**
Linear Regression menghasilkan nilai MAE sebesar **3.442**, lebih rendah dibandingkan Random Forest yaitu **3.460**.
- MAPE atau Mean Absolute Percentage Error**
Keduanya menghasilkan inf/infinity sehingga digunakannya **sMAPE** sebagai alternatif. Linear Regression menghasilkan sMAPE sebesar **112.679%**, yang secara persentase tingkat kesalahannya masih lebih rendah dan lebih baik dibandingkan Random Forest yang mencapai **115.337%**.

n. Linear Regression lebih optimal dibandingkan Random Forest

Compare models by: Mean square error						
Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	21.613	4.649	3.442	inf	112.679	-0.005
Random Forest (1)	22.310	4.723	3.460	inf	115.337	-0.038

Compare models by: Mean square error		
Linear Regression	Linear Regr...	Random Fo...
	0.148	
Random Forest (1)	0.852	




Grafik Residual Plot di atas digunakan untuk mengevaluasi kelayakan dan tingkat kesalahan hasil prediksi dari model Linear Regression. Secara keseluruhan, Residual Plot ini menghasilkan data dengan pola asimetris dan sebaran error yang tidak konstan. Hal ini mengonfirmasi hasil matrik R^2 pada evaluasi sebelumnya yang bernilai negatif. Karakteristik data perilaku ketidakhadiran siswa yang sangat acak dan memiliki banyak siswa yang sangat sering bolos membuat asumsi dasar regresi linier klasik sulit terpenuhi dengan sempurna pada dataset ini.

Interpretasi 3 variabel paling berpengaruh

- Male Job (Pekerjaan Ayah) dengan Skor 0.387
- Reason atau alasan memilih sekolah dengan Skor 0.364
- Female Job (Pekerjaan Ibu) dengan Skor 0.363


Residual Plot






BAB 6 CLUSTER ANALYSIS

Ujian Tengah Semester Project



Elbow Method (menentukan K optimal)

k-Means menunjukkan bahwa **K=2** merupakan pilihan yang lebih baik dengan skor tertinggi sebesar **0.113** dibandingkan **K=3 (0.066)**, analisis ini akan tetap menggunakan **K=3** sebagai jumlah cluster yang optimal secara analitis. Keputusan ini didasarkan pada pertimbangan bahwa membagi populasi hanya ke dalam dua kelompok (K=2) akan menghasilkan segmentasi yang terlalu umum, sedangkan penggunaan K=3 memungkinkan model untuk mengidentifikasi kapabilitas klasifikasi dan perilaku siswa secara jauh lebih spesifik dan relevan untuk kebutuhan evaluasi di dunia pendidikan.



01 Identifikasi 3 Persona Siswa

- **Cluster 2** : Kelompok mayoritas yang disiplin dengan absen rendah dan memiliki performa akademik stabil.
- **Cluster 3** : Kelompok siswa yang mengalami kendala belajar dengan jumlah kegagalan failures tinggi.
- **Cluster 1** : Kelompok kecil yang terdeteksi sebagai outlier dengan tingkat ketidakhadiran ekstrem >30 hari.


Evaluasi Silhouette Plot

02 Skor yang rendah (**0.066**) dan adanya area negatif menunjukkan bahwa karakteristik perilaku siswa sangat beragam dan saling beririsan (overlap), sehingga tidak ada batas pemisah yang kaku antar kelompok.

03 Temuan Pendukung (Informative Projection)

Visualisasi Scatter Plot mengungkap bahwa pendidikan ibu (**Mother's Education**) yang tinggi merupakan salah satu faktor yang mendukung siswa dalam untuk teridentifikasi kedalam cluster berprestasi tinggi.

Hasil Analisis Cluster





BAB 7

SINTESIS TERINTEGRASI

- Performa akademik dipengaruhi oleh faktor internal dan eksternal yang saling berkaitan
- Model classification (KNN) memberikan akurasi terbaik, namun masih terbatas pada data tidak seimbang
- Model regression menunjukkan bahwa absensi sulit diprediksi secara akurat
- Clustering mengelompokkan siswa menjadi beberapa kategori (tinggi, sedang, berisiko)
- Faktor utama yang berpengaruh: latar belakang keluarga, motivasi, dan kehadiran
- Data mining membantu memahami pola dan mendukung pengambilan keputusan pendidikan





BAB 8 CONCLUSION

Kesimpulan

Berdasarkan hasil analisis, performa akademik siswa dipengaruhi oleh berbagai faktor internal dan eksternal yang saling berkaitan. Model classification dengan KNN menunjukkan performa terbaik meskipun masih memiliki keterbatasan, sementara model regression kurang optimal dalam memprediksi absensi. Di sisi lain, teknik clustering berhasil mengelompokkan siswa berdasarkan karakteristiknya. Secara keseluruhan, penerapan data mining terbukti efektif dalam membantu memahami pola dan mendukung pengambilan keputusan dalam bidang pendidikan.

Saran:

1. Peningkatan pemanfaatan data dalam pengambilan keputusan
2. Pengembangan sistem deteksi dini siswa berisiko
3. Peningkatan keterlibatan orang tua





Thank You For Your Attention

Data is not about numbers, it's
about understanding

